

基于线性规划与对偶分析的微网计划购电策略

摘 要

(占位)摘要待问题 2–4 完成后统一撰写。本问已备妥的数值结论: 全天购电 59482.7 kWh、购电费 35126.85 元, 较无储能运行节省 26.9%; 充放电启停受阈值 $1/0.81 \approx 1.235$ 支配; 规则式策略较线性规划最优贵 11.71%。

关键词: 微网; 分时电价; 储能调度; 线性规划; 对偶分析

1 问题重述

1.1 问题背景

微网是一种小型发用电系统, 其快速发展缘于可帮助光伏发电等分布式能源的本地消纳, 以及一定程度上减轻大规模并网压力。

而本题的微网与外部电网并联运行, 在外网购电的基础上调和储能储电、光伏出力与小区负载。由于外网电价通常按分时电价进行结算, 在一天之内存在峰谷。微网要在这种情况下决定每个时段向外网购入多少电、储能何时充电何时放电, 使自身提供的电能既能满足小区负载, 又尽可能节省购电费用。

低价时段存电、高价时段放电是它压降购电费的主要手段, 但同时带来的必要储能也存在能量损耗。在规划过程中还需要平衡光伏和负载在时间上的一些错位。

1.2 问题要求

本文需基于电价、光伏发电和负载数据, 在他们分别表现为固定和时变的各搭配中, 依次为四问建立并求解微网的购电及充放电策略。本题四个问均要求在每天 0:00 制定当天的策略, 在不同的小问中计划时能获取的当天信息不同。第一问可获得所有数据, 第二问开始负载和光伏只能看到日前数据, 第四问中电价也出现了波动。且第三问提出了多次预报下的初步计划与调整的问题, 并被第四问继承。

题目要求在各输入情况下建模并对指定时间进行求解, 存入指定位置。

2 问题分析

2.1 第一小问分析

第一问给出了当天电价、负载与光伏发电功率的完整曲线, 并要求微网供电不低于负载、储能设备在 0:00 与 24:00 的储电量相同。也就是说, 制定计划时全天信息都是已知的, 本问不含任何不确定性, 需求仅仅是在全已知的情况下通过最优的购电及充放电策略达到精确的最小成本。

从形式上看, 供电平衡、光伏的分流去向、储电量演化与界限、充放电功率上限都可以写成决策量的线性关系, 购电费也是电价与购电量的线性组合, 因此本问可建为线性规划模型。充分分析电能流并准确的描述限制, 即可完成 LP。考虑到本题数据规模小, 可直接用求解器求出精确解。考虑到该模型的最优解本身还带有对偶信息, 我们拟

进一步尝试对偶分析,可能可以从最优解中分析出更多可解释信息。同时,我们关注到本题直接给定最大充放电功率及储能设备效率等的恒定值,这虽方便求解,但考虑到实际场景确实可能出现波动或偏差,我们拟再对其做灵敏度分析,尝试检验上述策略的稳定性。

2.2 第二小问分析

第二问保持电价不变,但让负载与光伏发电功率随时间变化,这使得二者的当日真值在制定计划时并不可知。而一旦供电低于负载,缺口会导致 5 倍电价的高额惩罚。本问由此从完全信息下的确定性 LP 优化,转成先预测、再计划的决策过程。

负载和光伏两个预测目标的性质并不相同。负载初步设想可能带有强烈的周周期,工作日与周末之间存在明显的差异;光伏则受气候与天气共同影响,日内起落规律稳定,主要噪声来自云量等。这样的差异说明用一套结构同时拟合两条曲线并不合适,单一模型也很难在全年各个季节都保持精度。本文据此拟构造两套由不同成员模型组成的模型池,并通过逐日更新的时变权重将其组合进行预测。在构建模型池的时候将尽可能依照预测目标的特性进行选择,减少具有相同特征学习倾向的模型累积,尽可能做到学习优势互补。

预测后进入优化部分。由于购电代价的两侧并不对称,少购要惩罚紧急费用,多购只按原价结算且余量还能存入储能,因此计划量应当适度偏多,以提升优化性能。初步考虑在预测输入进入优化之前做偏向保守的分位修正。但过度保守一定会导致低买高用的策略受到影响,需要找到平衡,故修正幅度通过遍历,完全交由数据表现决定。

本文同时需要接触午夜储电量的限制,这会直接让优化每一天成本的 LP 在午夜前将电几乎放完。但是在更长的时间上看,这违背最优策略、一定非最优,故考虑将储电量以当前电价在成本中减去,从原理上保证了 LP 在每日上的优化表现。

2.3 第三小问分析

第三问在第二问的基础上进一步调整两处。首先,光伏预报在四个时间各发布一次未来 24 小时的光伏预报,考虑发布时间越晚、提前量越短、预报越准。微网可以在这些时刻修改当天余下时段的购电与充放电策略。与此同时,午夜定下的策略可以调整,成交偏离计划的部分需补偿 0.5 倍电价。决策于是从一次性的确定性优化,变成先定全天计划、再随预报逐次调整的多阶段决策,后几次调整的使用方式与价值,可能成为总费用优化的关键。

若把四次预报带来的信息看成四个阶段、把光伏与负载的实际走势看成随机量,本问就是在这条信息链上求一份期望费用最低的购电与充放电策略。我们认为采用随机规划的思路来刻画本问及其合适。新成本由计划购电费,紧急购电费,调整相关费用构成可直接对应随机规划中第一阶段成本与追索成本的划分。同时,四次预报依次到达,决策随信息逐步修正的时间结构正是多阶段随机规划的刻画对象。此外,随机规划可评估各次预报的信息价值,可以定量回答是否需要引入其他时刻预报。

据此,本文考虑随机规划,即先由历史数据学习各时刻预报的误差结构,用一组情景刻画次日的可能情况,再在情景上联立计划与各次调整、最小化期望总费用,最后分

解各次预报的信息价值，分析其他时刻汇报必要性。

2.4 第四小问分析

3 模型假设

1. 储能设备按照充、放电效率各取 90%，往返效率 81% 的思路理解。
2. 功率上限按照 5000 kW 指储能设备并网侧而非电池侧理解，即考虑为其充、放电功率在发生电能损失之前的最大功率。这是行业内的常见理解，但会使得我们的最低成本较电池侧的理解的稍大。
3. 购电量与放电量均非负，不向外网反送电；光伏盈余只能充电或弃掉，弃光不计费用，以与题面“购电量”的记账方向一致。

4 符号说明

5 问题 1 模型的建立与求解

对于电价、负载和光伏发电量等所有数据已知的第一问，我们分析题目和数据信息，建立了简单的 LP 模型并求解严格最优解。在完成了最优解的结果分析后，我们还通过对偶分析和最优性证明，以及本场景恰当的灵敏度分析保证了模型的合理和稳健。具体流程如下图所示：




图 1: 问题 1 的建模与求解流程

5.1 LP 模型建立

首先可对附件 1 中的数据做简要预分析。

本题把每日划成 144 个时段 $I_k = [10(k-1), 10k) \text{ min}$, $k = 1, \dots, 144$ 。 I_1 取附件的第 144 行，该行标记的是次日 0:00 起的 10 分钟，由数据的日周期性，其数值与当日 0:00 至 0:10 相同； I_2 至 I_{144} 依次取当天的第 1 至第 143 行。可以简要分析出，电价在深夜与午间各有一个低谷，早 8 时前后与 19 时至 22 时各有一个高峰，双谷双峰的形态给储能低充高放留出了空间。

在本问的微网为小区负载的场景下，构建每个时刻的电能流是理解各购电、充放电和供电的关键所在：

符号说明			
Δt	单时段 10 min	R_t	实际总供给
I_k	第 k 个时段	e_t	供电缺口
λ_t	外网电价	C_t^e	紧急购电费
L_t	小区负载	$E_0^{(d)}, E_{144}^{(d)}$	日初/末储电量
P_t^{pv}	光伏预测功率	d	日序号
a_t, b_t	购电中直供/充电	$F^{(d)}$	日计划购电费
g_t, c_t	光伏中直供/充电	$w_{t,i}$	EGD 集成权重
q_t	弃光功率	α	权重重初始化系数
d_t	储能放电功率	N, T	成员数与评估天数
E_t	时段末储电量	τ	最优分位数
S_t	净充电累计量	C_u, C_o	低估/高估单位成本
η	充放电效率	p_t	0:00 计划购电量
$E_0, E_{\min}, E_{\max}$	储电量初值与上下限	u_t	最终成交购电量
$P_{\max}$	并网侧功率上限	κ_t	时段总费用
γ_t, σ_t	节点价值/供电成本	A	光伏逐时真值
η_t, θ_t	储电量界限对偶变量	C_s	会话预测中心
F	全天购电费	ε_0	0:00 中心整日偏差
$\hat{L}_t, \hat{P}_t$	分位修正负载/光伏预测	G_s	会话间修正量
$y_t, \hat{y}_t$	实际值与预测值	ω	情景标号
Q_q	残差经验分位数	Q_t^n, D_t^n	节点购电/发电量
P_t	光伏实际功率	g_t^r	实际光伏直供

外网购电 作为最基本的电能来源，可以规划从外界直接购入的购电量，并在较长的时间窗口满足外界总购电量略多于总负载的用电量，稍多的部分会在储能设备转化时损耗。外网购电可能根据存贮计划分流，一部分可转向储电设备并以 90% 的效率存储 b_t ，另一部分考虑可以直接转向小区负载供电 a_t 以减少损耗率；

光伏发电 类似的，小区内光伏发电的功率同样进行拆分，拆成直供负载的 g_t 与储能充电 c_t 两路，后者同样存在 90% 效率的能量转换。而由于光伏发电为被动来源，在储能设备几乎存满且负载低的极端情况下，可能出现废弃的光能功率，光伏与储能的协同调度正是处理这类消纳问题的常见框架 [2]。

储能供电 储能设备可以将通过外购和光伏存入的能量再以 90% 的效率输出，为小区负载供电。我们记放电总功率为 d_t 。同时，每个时刻的储电量 E_t 由充放电累计得到全天购电费为各段电价乘以购电量之和，针对购电成本的目标函数为

$$\min F = \sum_{t=1}^{144} \lambda_t (a_t + b_t) \Delta t. \quad (1)$$

本场景中涉及的基本约束包括：

供电平衡 考虑到微网供给不得低于负载，又由于多供无益。在所有时刻维持总供电刚好满足需求负载，取等式

$$a_t + g_t + d_t = L_t. \quad (2)$$

光伏电量平衡 根据电能流的梳理，光伏发电分流到直供负载、储电以及极端情况

的废弃量，即

$$g_t + c_t + q_t = P_t^{\text{PV}}. \quad (3)$$

储能动态 对于储能设备而言，每一个时刻的储电量变化需考虑所有充放电路径。由于其充放电效率为 90%，迭代时注意存在损耗，即

$$E_t = E_{t-1} + 0.9(b_t + c_t)\Delta t - \frac{d_t}{0.9}\Delta t, \quad (4)$$

储电量约束 为保护设备在长期运转的健康水平，每个时刻的储电量需要避免过高或过低

$$1200 \leq E_t \leq 10800 \quad (5)$$

同时，充放电在单位时间的功率也存在界限，采用行业常用的并网侧约束，即损耗之前进行约束 $b_t + c_t \leq 5000$ 、 $d_t \leq 5000$ kW。

周期边界条件 场景已经给定 2025 年 1 月 1 日 0:00 的储电量为 6000 kWh，且要求每天储能设备在 0:00 与 24:00 的储电量相同，故每晚午夜储电量均为 6000 kWh，计划逐日执行时第 k 天 0:00 的节点 E_{144k} 都取该值；罐内储电量本身仍随充放电在界限内波动，该要求在单日模型中表现为首末两端

$$E_0 = E_{144} = 6000 \text{ kWh}. \quad (6)$$

其中，变量非负隐含 $d_t \leq L_t$ ，放电不会超过负载，不发生向外的反送。

合并式 (1) 至式 (6)，问题一的完整 LP 为：

$$\begin{aligned} \min \quad & F = \sum_{t=1}^{144} \lambda_t (a_t + b_t) \Delta t \\ \text{s.t.} \quad & a_t + g_t + d_t = L_t, \quad g_t + c_t + q_t = P_t^{\text{PV}}, \\ & E_t = E_{t-1} + 0.9(b_t + c_t)\Delta t - \frac{d_t}{0.9}\Delta t, \\ & 1200 \leq E_t \leq 10800, \quad b_t + c_t \leq 5000, \quad d_t \leq 5000, \\ & E_0 = E_{144} = 6000, \quad a_t, b_t, g_t, c_t, d_t, q_t \geq 0, \\ & t = 1, \dots, 144. \end{aligned} \quad (7)$$

5.2 LP 模型求解

式 (4) 中的储电量 E_t 并非独立的决策量，任一时刻的储电量都由之前的充放电决策唯一确定，求解时把它消去，改记业内常见的净充电累计量 SOC

$$S_t = \sum_{s \leq t} \left[0.9(b_s + c_s) - d_s/0.9 \right] \Delta t, \quad (8)$$

以 $E_t = 6000 + S_t$ 代入, 容量界限与终端条件都化为对 S_t 的直接约束。这一消元可提前省去 144 个状态变量及其对应的 144 条递推等式。虽然 S_t 的界限行带前缀求和, 非零元随时段增多, 约束矩阵变得更稠密, 但这在 144 段的规模下不构成负担。

最终交给求解器的是 864 个决策量、289 个等式约束与 576 个不等式约束。在实际求解中, 容量界限行与终端归零行的对偶变量合成了各时点的节点边际价值, 5.4 节的 γ 递推将直接构造自这组输出。求解调用 `scipy.optimize.linprog` 接口的 HiGHS 求解器, 容差沿用默认设置, 单次求解约 0.25 s。

求解器在返回最优解的同时给出全部对偶变量, 5.4 节的影子价格直接取自这一输出; 求解前后还通过了以下三类自检:

全天能量守恒 购电量加光伏发电量应等于负载、弃光、充电损耗与放电损耗之和, 两侧相差 1.5×10^{-11} kWh, 即恒等式累积误差完全为运算精度误差;

购电策略合理 最优的购电策略应该是利用本题数据的双谷双峰形态, 在低电价时购入并存储并在高电价时取用, 这导致解的外网购电存在分块特征。具体分析见 5.3 节的表 2 与图 2;

无同时充放电记录 同时充放电这一理论上绝非最优的策略在解中并未出现。从实际情况考虑, 对储能设备同时充放电更易由于总功率较高而造成损伤; 同时从优化模型上考虑, 发生同时充放电时将其相互抵消, 即可省下存储 90% 所带来的能量损失, 这在理论上可降低成本, 严格的论证见 5.4 节。

5.3 模型结果分析

全天购电 59482.7 kWh、购电费 35126.85 元; 无储能运行时按逐段缺口 $\max(0, L_t - P_t^{\text{PV}})\Delta t$ 购电需 48052.05 元, 储能低充高放节省 12925.20 元、降幅 26.9%, 数据见表 1。六个指定时段里, 10:00-10:10、14:00-14:10 与 20:00-20:10 的购电量均为 0, 这些时刻光伏加储能足以覆盖负载。

计划购电量按模板逐行填写, 第 2 至第 144 行依次对应 I_2 至 I_{144} , 末行填 I_1 的数值, 即次日首段的计划。

表 1: 微网指定时间段微网购电量及全天购电情况

时间段	购电量/kWh	时间段	购电量/kWh
10:00-10:10	0.00	16:00-16:10	394.93
12:00-12:10	486.40	18:00-18:10	636.98
14:00-14:10	0.00	20:00-20:10	0.00
全天购电量	59482.7	全天购电费/元	35126.85

表 2 按四小时块汇总, 汇总块来自 I_{24k+1} 至 I_{24k+24} 逐段统计。

表中可见, 充电集中在 0:00-4:00、12:00-16:00 与 20:00-24:00 三个块, 放电主力在 4:00-8:00 与 16:00-20:00; 这一特征结果高度符合数据分析中描述的峰谷特征, 该策略为 LP 的核心特征。

下图给出了储能设备的储电量变动情况与各时段功率。日循环呈两充两放结构, 0:00-1:00 以 5000 kW 顶格充电 4500 kWh, 5:40-5:50 抓住全日最低价 0.3713 元/kWh 补

表 2: 储能设备在指定时间段的充放电量及 0:00 和 24:00 的储电量

时间段	充电量/kWh	放电量/kWh
0:00-4:00	4500.00	0.00
4:00-8:00	833.33	5947.42
8:00-12:00	3954.63	2121.42
12:00-16:00	6119.37	91.10
16:00-20:00	0.00	5068.69
20:00-24:00	5333.33	3571.31
0:00 与 24:00 储电量	6000	

充 833.3 kWh, 储电量触及上限 10800 kWh; 早峰 6:00-9:40 放电 8068.8 kWh, 恰好覆盖全部负载, 这三个多小时内购电为零; 午间由光伏盈余充电并在低价段补购; 晚峰 18:50-20:50 放电 8530.7 kWh, 电价最高的 1.3952 元/kWh 时段购电为零; 22 时起分批回充, 24:00 回到 6000 kWh 闭环。特别的, 外购充电全部落在 0.371 至 0.479 元/kWh 的时段里, 放电时段的电价最低也有 0.690 元/kWh; 另外, 全天弃光为零, 光伏发电量被负载与储能完全使用。




图 2: 解的储能状态与各时段购电、充电及放电功率

5.4 对偶分析及最优性证明

LP 的对偶变量给出比数值解更深一层的解释。我们给各类约束挂上影子价格, 据此定义节点边际价值 γ_t : 在时段 t 末白得 1 kWh 储能, 全天购电费能省下多少。 γ 沿时间轴满足递推

$$\gamma_t = \gamma_{t+1} - \eta_t + \theta_t, \quad (9)$$

其中 η_t 、 θ_t 是储电量上、下限约束的对偶变量。内点节点上 γ 逐段不变, 能量躺在罐里不生息; 满罐节点 γ 下移 η_t , 空罐节点 γ 上移 θ_t 。由 KKT 互补松弛条件可得充放电

的三条启停判据，对偶理论见文献 [5]。充电段满足 $\lambda_t = 0.9\gamma_t$ ，功率顶格段另加正的影子溢价；放电段满足 $\sigma_t = \gamma_t/0.9$ ， σ_t 为该段边际供电成本；空闲段的价格落在 $0.9\gamma_t$ 与 $\gamma_t/0.9$ 之间的迟滞带内。把充、放电段的等式联立，可得跨窗口搬运能量的门槛，放电价与充电价之比须不低于

$$\frac{1}{0.81} \approx 1.235. \quad (10)$$

说白了，价差比不到 1.235 的两段之间，LP 一千瓦时也不会搬。同一段内边充边放的情形可以先用损耗的账排除。取充分小的 δ ，若某段同时有 $b_t > 0$ 与 $d_t > 0$ ，把充电减 δ 、放电减 0.81δ 、直购增 0.81δ ，储电量轨迹逐点不变，购电费净省 $0.19\lambda_t\delta\Delta t$ ，只要电价为正，原解就还不是最优。对偶条件给出同一结论，边充边放要求 $\lambda_t = 0.9\gamma_t$ 与 $\lambda_t = \gamma_t/0.9$ 同时成立，推出 $\gamma_t = 0$ 且 $\lambda_t = 0$ ，与恒正的电价矛盾。故最优解中不存在同段充放，无需为排除该行为引入 0-1 变量，这与文献 [1] 用状态变量处理储能充放互斥的做法形成对照。

图 3 画出 γ 与 λ 的全天对比，底色可区分出充放电窗口，有以下两处结构值得讨论。

首先是，两个放电大窗口 6:00-9:40 与 18:50-20:50 内 σ 分别为 0.591 与 1.256 元/kWh，都低于当时的电价，储能把两个价格峰完全削平，窗口内购电为零。

其次是，15:10-18:30 储电量顶在 10800 kWh 的平台期， γ 从 0.733 爬升至 1.130 元/kWh，每经过一个满罐节点上移一点，罐容稀缺的影子价随放电临近在累积。最优性方面，互补松弛条件在全时段的违约不超过 1.4×10^{-17} 元/kWh，节点价值的有限差分重解与对偶值偏差为 1.2×10^{-12} ，两条独立途径相互印证。




图 3: 储能节点边际价值 γ 与电价 λ 的全天对比

5.5 模型灵敏度分析

除了对本 LP 结果的理论分析，还可以从灵敏度进行评价。

本问选择了 $\eta, P_{\max}$ 这两个行业内通常不固定的指标，尝试进行灵敏度分析。虽然本题给定了具体数值，但我们认为如果在给定值的邻域波动参数也能通过灵敏度检验，则可以较好的说明模型稳健性；其次，我们选择了问题在业界的常见方案做结果的对比，以体现模型的优越性。

充放电效率 η ，本题在储能设备参数处给定 $\eta = 90\%$ ，但是在实际生产中同一批储能设备的参数都可能存在误差，且在使用、老化的过程中，电机的效率损失几乎是必然的；此外，该参数在模型的求解过程中及其重要。由于 η 决定套利阈值 $1/\eta^2$ ，效率越低，值得搬运能量的价差组合越少，解的结构就会随之改变。

所以本文围绕 90%，扫描取 0.85 至 0.95 共五档，每档重新求解完整的规划，结果见表 3。成本随 η 单调下降，每提高 0.01 仅约降 0.8%，并未出现较大敏感波动。

失效边界在 $\eta \approx 0.841$ 。早峰 6:00-9:40 需要储能送出 8068.8 kWh，满电自 10800 kWh 放至下限 1200 kWh 最多送出 9600 kWh， η 低于 8068.8/9600 ≈ 0.841 后单个日循环放不满早峰缺口，必须在午间以更高的电价二次回充，成本曲线在此转陡。

表 3: 充放电效率 η 的敏感性扫描

η	阈值 $1/\eta^2$	购电费/元	较 $\eta = 0.90$
0.85	1.384	36603.21	+4.20%
0.88	1.291	35696.82	+1.62%
0.90	1.235	35126.85	题面取值
0.92	1.182	34575.53	-1.57%
0.95	1.108	33767.02	-3.87%

功率上限 $P_{\max}$ 分析可得，解中有 19 个时段的充电功率顶在 5000 kW，该约束频繁激活，值得单独查验。把 $P_{\max}$ 放宽到 6000 kW 重解，成本仅降 0.12%。其看可能的原因是低价时段的总电量足以把储能设备充满，上限改变的只是充电在时段之间的分布，而不是充入的总量；放电峰值功率 4294 kW 从未触顶，两个方向中只有充电侧受到约束。而假设 2 中我们对于 $P_{\max}$ 的并网侧理解与“电池侧”，认为时电池实际存入或输出的功率可达 $P_{\max}$ ，对结果的影响同样被限制在这一量级。

6 问题 2 模型的建立与求解

问题 2 继承了问题 1 构建的 LP 模型，但是有三个条件改动。

日前预测必要性 负载与光伏逐日变化，考虑当日真实值在制定计划时不可知，这里便衍生出了基于日前信息进行时间序列预测的需求。同时，考虑到负载和光伏发电数据的波动特征等可能存在差异，在建模时需要通过不同的方法学习不同特征。

紧急购电 由于计划依据的数据来源于预测，执行过程中因误差导致的若供电不足，须按交易时刻电价的 5 倍向外网紧急购电。

取消日起储能限制 当第二问不再要求每天 24:00 匹配 00:00 的 6000kWh 电量，跨度为每日的 LP 模型一定会在午夜之前将储能电量全部放完以最小化当日成本，但这在长期看来是绝对不可取的。午夜之前的低价时段不外购充电，反而放电，该策略是完全不符微网场景逻辑的。但由于每天的预测和计划独立，不能直接将 LP 的时间跨度提到一年。故，文本将储电量根据当前电价，作为减项折算到成本中。这可以从 LP 根本上杜绝其自发在午夜前放电的行为。

据此，本问的求解框架分为日前预测部分及 LP 求解部分，具体流程如下图。




图 4: 问题 2 的建模与求解流程

6.1 日前预测模型的建立

预测层需在每日 0:00 时刻，利用截止前一日的全部历史数据，对当日 144 个 10 分钟间隔时点的小区负载功率与光伏发电实际功率进行日前预测。同一天预测值不考虑带回增量训练以避免误差累积。

考虑到从 31 天数据的冷启动到后期数百天的数据跨度，以及季节性的峰值等特征可能漂移，我们认为预测层实际的关键在于在不同数据量情况、两种不同预测目标特征、季节性趋势明显、特殊的噪声和信号识别上的高自适应能力，该模型同时还需要兼顾短时天气变化的快速响应。可见，这种多环境的自适应需求很难由单 ML 模型满足，故我们拟采用多模型互补的思路，通过高度灵活的方法调整模型权重，尝试达到在不同场景的高预测性能。

6.1.1 两目标时序特性分析

在多模型的组合构建前，需要分别分析小区负载和光伏发电量的时序特性，方便后续进行更加具备科学性的模型选择。纳入不足或者偏向明显的组合，可能导致模型池不擅长一些情境的信息捕捉；而纳入过多各类模型，会使得求解效率低下，而同类模型特性互相叠加影响，类似共线性的效应严重影响求解效率。

小区负载 对其日总量的自相关分析显示，滞后 7 阶自相关系数达 0.988，滞后 1 阶仅 0.374、滞后 2 阶为负，表明周周期为首要周期成分。此外观察到周内模式呈现显著分化，周一至周四及周日日均负荷约 5165 kW，但周五、周六骤降 36.8% 至 3265 kW，反映了工作日与周末的居民用电行为差异，符合生活常识。而在日级别方差分解中，周季节成分占 89.3%，趋势占 14.1%，残差仅 4.4%，进一步验证了周周期的主导地位。日内峰谷比在 [1.80, 2.11] 中，峰值时点存在季节漂移，由 1 月 09:00 对应早高峰的峰值，7 月漂移至 17:30 对应晚高峰，月度均值极值比为 1.23。

光伏发电 类似的，日总量滞后 1 阶自相关系数为 0.964、滞后 2 阶仍有 0.957，而滞后 7 阶为 0.878，表明日连续性远强于周周期，不同于负载特征。同时，工作日与周末的表现无显著差异，符合自然特征。月度均值极值比达 1.93，这由气候缘故决定。且光伏发电的物理约束明确，即夜间功率恒为 0、峰值恒在 12:00 前后，日出日落时点由天文规律确定。故，天气是主要噪声来源，且日间变异系数在区间 [0.06, 0.11]。

上述特性直接驱动了模型选型策略。负载需重点建模周周期与季节漂移，光伏需重

点建模日连续与年周期，并利用物理约束强制夜间置零。考虑到两个序列的显著时序特性差异，采用独立模型组合而非统一模型池。

6.1.2 异构模型池构建

负载模型池

a. 季节朴素法 (SeasonalNaive) 取上周同一时点的实际值, 不设参数。

这一朴素取法是最佳的体现周周期的方法。对于小区负载的场景，工作日和周末的用电人数、用电量一定会出现显著差异；且周周期在数据中也体现明显，所有样本中周五、周六日均比工作日低 36.8%。本方法在具有良好的周周期响应性的同时，选用最近一次以保留同季特征。

b. 月度均值预测 (HistMean) 取近 4 周同一时点的平均。对一个月的观测取均值可抹平随机的单日噪声，可以体现近一个月的平滑趋势。

简要分析可得，负载日总量的变异系数为 19.6%，极值日 7 月 3 日与 4 月 18 日的日总量相差 1.98 倍，这些跳变多来自用电随机性与测量误差，而月度平均作为平滑模型，可最直接的抑制这类扰动。

c. STL 作为时间序列经典方法，其以 7 天为周期把历史序列分解为趋势、季节与残差三部分，趋势分量以阻尼系数 0.8 外推，季节取上一周同相位值，残差置零。其具备专门处理月度均值学不到的水平迁移的能力，趋势项阻尼外推既能跟进漂移，又不受单日异常影响。

d. kNN 该方法以昨日完整曲线为基准，在近 60 天历史中取归一化欧氏距离最近的 3 个同星期几的日子，按距离倒数加权搬用它们的次日曲线 [11]。此方法可以降低次日曲线单步 MAE，小区负载常出现相同用电结构在不同的时间出现，直接通过 kNN 匹配相似日可以很好的处理这种情况。

e. LightGBM 池中唯一的非线性模型，其强大的机器学习能力用于捕捉突发事件等引发的非线性信息，树结构可以表达特征之间的交互，空调季、周末、午间三者组合出的模式是周期模型写不出的。我们对其的训练结果如下：用 18 维日历与滞后特征训练梯度提升树，取强正则，共 600 棵树、学习率 0.03、叶数 15、最小叶样本 30、子采样与列采样 0.7、L1 与 L2 惩罚 1.0 与 5.0、早停 50 轮，防止小样本过拟合。

光伏模型池

a. Persistence 该方法取昨日同刻值。光伏的日连续性远强于负载，取昨日曲线即可跟上天气惯性，此处不做平滑反而对阴晴突变响应最快。

b. kNN 沿用负载模型池中的做法，但不限定星期几，光伏不受作息支配。天气在光伏上留下的痕迹比在负载上清楚得多。

c. STL 分量预测沿用负载模型池中的分解逻辑。与负载不同，这里趋势项承担的是辐照水平的季节缓升缓降，在日总量方差中占 87.1%，而周季节仅 2.9%。附件中月度日均从 12 月的 1514 kW 升到 8 月的 2916 kW，相差 1.93 倍，其中 6 月因梅雨回落到 2370 kW、低于 7 月的 2723 kW，这种爬升只有趋势项跟得住，光伏侧的水平分量因此选它。

d. FPCA 对近 14 天的白天曲线做低秩重构，再把公共形态与最近一日的偏差按阻

尼系数 0.4 融合, 预测值截断为非负。它只跟踪少数几个模态的幅度, 就能兼顾曲线共性与近期天气, 可以清晰刻画光伏模型池的形状主线。

e.LightGBM 特征工程与负载模型池中的一致, 光伏侧的非线性部分也补在这里。

另外, 两个模型池中的 STL 都选用经典 STL, 而非 CEEMDAN、VMD 等模态分解方法。后者需要在全局数据集上分解, 滚动设定下会把预测日之后的信息带进训练窗。但在本题中日前预测不应使用未来信息。

6.1.3 EGD 时变权重集成

在完成了两预测指标的模型池搭建后, 需要为池中的各成员分配合适的权重。考虑到不同阶段的主导因素并不相同, 使得夏季空调负荷期最可信赖的成员与秋季平稳周期里最可信赖的成员并不一样, 一组全年不变的权重向量本身无法随阶段切换; 若改用一个能力强大的元学习器按全期误差定一组权重, 全期误差又只是各阶段表现的平均, 同样无法给出当前由哪类因素主导的答案。

故, 我们考虑动态地为成员赋权: 权重逐日在线更新、完全由近期数据驱动, 使模型池在所有场景下自动机动调整预测倾向。

指数梯度下降的权重更新 记第 t 日模型 i 的权重为 $w_{t,i}$, 当日预测误差结算完毕后按指数梯度下降更新

$$w_{t+1,i} = \frac{w_{t,i} \exp(-\mu \tilde{\ell}_{t,i})}{\sum_j w_{t,j} \exp(-\mu \tilde{\ell}_{t,j})}, \quad (11)$$

其中 $\tilde{\ell}_{t,i}$ 为模型 i 的局部核加权损失; 且学习率 μ 不作搜索遍历, 而是按指数加权策略的理论, 取最优量级 $\mu^* = \ln N/T$ 。在本场景中, $N = 5$ 为池内成员数、 $T = 334$ 为评估天数, $\ln 5/334 \approx 0.0048$, 故取 $\mu = 0.005$ 。

通过 EGD 的指数梯度下降逻辑, 当日误差大的模型被指数地压低了, 使误差小的成员模型权重上升, 并将分母归一化以保证权重始终构成一个概率分布。其中, 学习率取得较小, 以保证让权重随时间的漂移速度不能过快, 避免偶然大误差瞬间某个成员模型的权重。

该时变权重集成的框架来自于在线学习里 Hedge 算法的指数加权策略 [15], 且其已经被证明具有最优 regret 界 [12]。在该框架下, 累积损失至多比事后最优的成员多出 $O(\sqrt{T \log N})$ 量级。所以, 即使伴随季节切换及其引发的权重迁移, EGD 时变赋权下的总损失与日前已知当日数据的理想情形, 只存在一个随天数缓慢增长的小量差距, 这对赋权提供了极佳的稳健性支撑。

损失的局部核加权 考虑到单日误差的噪声有较大波动, 直接拿当日损失更新权重可能引发权重随天气等波动特征产生严重波动。故采用 EGD 将最近 30 天的窗口内对历史损失做指数衰减加权

$$\tilde{\ell}_{t,i} = \frac{\sum_{s=t-29}^t 0.95^{t-s} \ell_{s,i}}{\sum_{s=t-29}^t 0.95^{t-s}}, \quad \ell_{s,i} = \text{MAE}(y_s, \hat{y}_{s,i}), \quad (12)$$

其中, 衰减系数取 0.95 会导致当天的权重约为 30 天前的四倍。这可以让模型池更倾向

通过近期的场景特征来选择赋权策略，同时也保留稍远时点，如一两周前的影响。这一局部窗加权的思路取自时变模型平均 TVJMA [16]，它用每个时点附近的局部信息挑选合成权重，而不是在全样本上定一套固定权重，与我们逐日更新的需求达成好匹配。

在算出日均损失后对每日做归一化，以避免在光伏误差整体偏大的阴雨月份，损失的量级主导权重更新，从而直接覆盖模型池成员之间的相对优劣。

周期性的重初始化 这一套 EGD 持续更新权重也存在代价，权重可能会停留在旧模式里，无法做出积极的策略变化。若某个成员模型在夏季被压到很低的份额，此后即便秋天的数据重新对它有利，指数更新也较缓慢的只能把它往回拉，这不能满足一些情况下的快速响应需求。为此，我们每隔 7 天将模型重训：

$$w_t \leftarrow \alpha w_{\text{init}} + (1 - \alpha) w_t, \quad \alpha = \max(0.05, 0.5 \exp(-(d - 35)/60)), \quad (13)$$

其中， d 为已训练天数。在最初的冷启动阶段，由于数据太少 $d < 35$ ， α 偏大权重被拉回一个偏向简单方法的起点；而随着数据量的增加啊，后续的 α 衰减到 0.05 的下限，只保留一点微弱的复位，不再打扰已经学稳的权重。即长线的在线更新负责跟踪学习，周期性的复位负责切换 [15]

冷启动权重与滚动训练 在初始训练时只有 31 天数据，机器学习成员模型学习效果不佳，而简单平均在高不确定性下反而更稳 [13]。故据此让初始权重偏向简单方法，具体冷启动结果见下表。

表 4: 冷启动阶段两模型池的初始权重

模型成员	负载池	光伏池
季节朴素法 / Persistence	0.25	0.30
月度均值预测 / kNN	0.20	0.20
STL 分量预测	0.20	0.15
kNN / FPCA	0.20	0.15
LightGBM	0.15	0.20

结合上文周期性重初始化考量，将 LightGBM 每 7 天重训一次，与上面的权重复位同步；而在训练过程中我们不考虑将训练出来的当日时间预测值作为新输入，增量训练并预测当日后时间的目标。这会极大程度上扩大噪声，尤其在本题时间点分段较多的场景下。

6.1.4 预测模型检验

训练数据取自附件 2 全年 365 天、每天 144 个时点的记录，2025 年 1 月的 31 天作初始训练数据，滚动预测点逐天预测。

对于性能的评价，本文取指标 MAE、RMSE 与 MAPE，光伏另计仅统计 06:00–20:00 的白天 MAPE，排除夜间零值对百分比的失真。

同时，我们还选取了两模型池中涉及的所有单个模型进行指标对比，以证明模型池的优异表现并不是单个强大模型主导的，而是不同特征模型的搭配互补。

集成优于单模型 这一验证使模型池方法涉及的核心。从表 5 中可以分析出，对池内成员，负载集成 162.99 把最优单模型 LightGBM 的 172.71 再降 9.72，优于全部成员，光伏集成 165.96 虽高于最优单模型 FPCA 的 160.71，但优于其余全部成员。光伏白天 MAPE 由 7.83% 升至 8.85%，是 5 6 月阴雨月份误差结构变化所致，全期 MAE 仍明显占优。

表 5: 池内单模型与 EGD 集成的全期 MAE

负载模型	MAE	光伏模型	MAE
LightGBM	172.71	FPCA	160.71
SeasonalNaive	176.80	Persistence	185.35
STL	178.59	LightGBM	192.14
kNN	188.80	kNN	205.04
HistMean	188.88	STL	212.73
EGD 集成	162.99	EGD 集成	165.96

LSTM 对比 为更加直接的表明本日前预测模型的优越性，我们直接选用了工程上的常用 ML 模型 LSTM，对相同的数据集进行训练。

其训练结果表现明显更差，负载 MAE 为 682.1，为本模型的 4.2 倍，光伏 MAE 443.4 为 2.7 倍，在 6 7 月与 10 11 月的季节变更厂家下 MAE 也出现了明显的短期激增。其可能问题在于纯序列缺少星期几、季节这类日历特征，即使 LSTM 拥有长期记忆识别和短期预测的优秀能力，其固定的训练窗口也跟不上季节模式的切换。而本文特征工程后基于 EGD 加权的模型池，在小数据与一些信息漂移的场景里反而稳健。

消融实验 通过控制变量下除去特定模型，可以直观反映池内五个模型成员是否都有存在理由。

逐一移除成员并重跑 EGD 权重更新，结果见表 6。负载池的答案是 STL 与 LightGBM 不可或缺，移除后 MAE 分别上升 4.75 与 2.52；季节朴素法与历史均值移除后集成反而略优 0.13 与 0.35，但二者是周周期的强基准与对照，保留的代价不足 0.4。光伏池中 FPCA 一家独大，移除后 MAE 上升 18.56，其余成员的贡献都不超过 1：光伏各模型间的误差相关性高达 0.984 0.998，天气噪声主导下所有模型在同样的日子犯错，其余成员的价值在于 FPCA 失效的极端天气日提供修正。

表 6: 预测模型池消融实验（MAE 单位 kW，变化为相对完整模型的差值）

负载消融方案	负载 MAE	变化	光伏消融方案	光伏 MAE	变化
完整 5 模型	162.82	基准	完整 5 模型	159.77	基准
去掉 STL	167.57	+4.75	去掉 FPCA	178.33	+18.56
去掉 LightGBM	165.34	+2.52	去掉 Persistence	160.55	+0.78
去掉 kNN	163.00	+0.18	去掉 STL	160.32	+0.55
去掉 SeasonalNaive	162.69	-0.13	去掉 kNN	159.71	-0.06
去掉 HistMean	162.47	-0.35	去掉 LightGBM	159.60	-0.17

响应月度及季节检验 首先，可以分析出的是数据中存在大量与月份或季节相关的特征差异。如负载 MAE 在 6、7、9 月达 208.5、272.9 与 256.7，对应夏季空调高峰与季

节转换期，而 4 月、11 月仅 97.4 与 106.6，对应模式稳定的春秋季节；光伏在 5、6 月阴雨期达 201.9 与 236.7，12 月天气稳定且功率本身低使其最低至 82.6。

面对这样的起伏，EGD 权重的轨迹显示模型确实在换挡，负载 LightGBM 权重夏季升至 0.80 左右，以更好学习其非线性，并在秋季自动回落，由权重 0.41 的 STL 与 0.38 的季节朴素预测主导模型池；而对于光伏，FPCA 全年 0.89 0.99 稳定主导。

过拟合检验 较优的结果也可能来自对评估数据的记忆，本文把这一疑虑拆成参数、权重与设计三层，分别给出证据。

参数层 用时序切分查验机器学习成员是否记住了训练噪声：前 70% 训练、后 30% 测试，负载训练与测试 MAE 为 261.6 对 321.3，比值 1.23，光伏为 190.0 对 207.6，比值 1.09；不加正则的历史配置过拟合比达 4.83，强正则加 50 轮早停把它压低约 75%。作为补充，把叶数上限从 15 放宽到 31 重新滚动全年，负载全期 MAE 仅从 162.99 变为 163.80——放宽容量并未换来记住更多噪声的收益，记忆训练噪声并非性能来源。其余成员为无参数或低参数的统计模型，无此风险。

权重层 权重更新只使用截止前一日的误差，这里再用一个信息上界做机械性核验（图 5）：倘若每天都能在事后从池中挑出当日最优成员——这是任何在线方案都无法企及的理想情形——其全期 MAE 也不过 139.6（负载）与 140.2（光伏）；本文集成的 162.99 与 165.96 距该上界尚有 17%–18% 的差距。偷看未来的集成只会向上界逼近，绝不可能比它差出这么多，这从机制上排除了权重更新泄漏未来信息的可能。再对优于对照的结论做统计检验：与 XGBoost、LSTM 的按日损失差经 Newey–West HAC（lag 7）修正后做 Diebold–Mariano 检验，四个对比全部显著——光伏对 XGBoost $p \approx 1.0 \times 10^{-4}$ ，负载对 XGBoost $p = 0.024$ ，对 LSTM 两对象均 $p < 10^{-24}$ 。

设计层 最难自证清白的是设计阶段的自由度：超参数与池构成都是在看过全年表现之后敲定的，直接报告的指标因此带有选择性乐观。本文的处理是先诚实声明，再量化其影响。超参数可分三类：学习率 μ 由 $\ln N/T$ 从问题维度推出，STL 周期 7、光伏夜间置零等由数据结构与物理规律决定，均不含人为自由度；其余常数（kNN 的 k 与窗口、FPCA 阻尼、LightGBM 正则）取保守中庸值。随后做两项复核：其一，把负载池恢复为精简前的 7 模型重新滚动全年，5–12 月 MAE 仅从 179.6 变为 180.6（+0.6%），说明池构成的精简并未按答案挑成绩；其二，对上述常数逐项拧偏一档重跑全年，样本外（5–12 月）MAE 的相对变化全部落在 $\pm 2\%$ 内（图 6），不存在只有看完整年答案才能找到的针尖参数。三层合看，本方法的较优表现来自池内机制互补与保守稳健的常数取值，而非对评估数据的记忆。

6.2 考虑紧急购电的 LP 模型

6.2.1 分位数预测的必要性

从计价规则看，购电预测误差的惩罚具有明显的非对称性。购电不足时，缺口需通过紧急购电弥补，其电价为交易时刻电价的 5 倍，构成高额惩罚；购电过剩时，仍是按正常电价支付，且在储能容量与充放电功率允许的范围内，多余的购电或光伏还能充入储能，留待后续时段使用。





图 5: 泄漏核检：逐日事后最优成员构成信息上界

图 6: 设计层敏感性：关键常数逐项拧偏一档后，样本外（5–12月）MAE 相对基准的变化全部在 $\pm 2\%$ 内（左：负载，右：光伏）

因此，在本场景下的最优情况应当适度偏多购电，这无法由 LP 显示地完成，故考虑通过调整预测结果来间接影响 LP 最优解。

分位修正只作用于本问 LP 的输入，不改变光伏模型池和负载模型池的预测本身。对每个时点，修正量取该时点过去 30 天预测残差的经验分位数，修正后的预测为

$$\hat{y}_t^{(q)} = \hat{y}_t + Q_q(\{y_s - \hat{y}_s\}_{s=t-30}^{t-1}), \quad (14)$$

其中 Q_q 为该时点残差样本的 q 分位数。考虑到购电惩罚的不对称性，低估负载功率或是高估光伏功率都可能触发紧急购电，因此负载和光伏分别向上取较高分位或向下取较低分位，以减少触发紧急购电的概率。

随着分位数的提升，负载预测通常增大，而光伏预测减小。这会反而导致总体成本的增加，与减少紧急购电的影响方向相反，故需要在二者之间寻找分位数平衡点。

而由于该平衡点理论上与不平衡的惩罚机制强相关，可提前对最优分位数平衡点提出预测。考虑设低估 1 kWh 的边际代价为 $C_u = 5\lambda_t$ ，高估 1 kWh 的边际代价为 $C_o = \lambda_t$ ，则代价比对应的参考分位为

$$q^{\text{ref}} = \frac{C_u}{C_u + C_o} = \frac{5\lambda_t}{5\lambda_t + \lambda_t} = \frac{5}{6} \approx 0.833. \quad (15)$$

6.2.2 紧急购电与结算

在本文中, 额外需要考虑当计划供给不足时, 缺口由紧急购电补足。记实际光伏功率为 P_t , 计划光伏直供为 g_t , 实际供给量为

$$R_t = a_t + g_t^r + d_t, \quad g_t^r = \min(g_t, P_t), \quad (16)$$

其中 P_t 为该时段光伏实际功率, g_t^r 表示实际光伏中按计划直供的部分, 实际光伏低于该计划量的部分构成缺口。缺口与紧急购电费为

$$e_t = \max(0, L_t - R_t), \quad C_t^e = 5\lambda_t e_t \Delta t, \quad (17)$$

6.2.3 调整 LP 模型

本问 LP 模型沿用问题 1 的供需平衡、光伏分流和储能动态关系及众多约束。不同之处在于不再考虑对每天 24:00 的储电量的约束。由于日末储能仍可供后续时段使用, 但是 LP 的时间窗口只有当天, 其最优解一定 LP 为了压低当日成本而在午夜前放空储能, 这与长期节约成本的策略相悖。故, 考虑将储能设备中的储电量折算为部分已投资成本, 在成本目标函数中减去。

即, 若记 $E_0^{(d)}$ 为第 d 天初始储电量, 按日末时刻电价与 90% 的可利用率估计其价值 $0.9\lambda_{144}E_{144}^{(d)}$, 并从当日计划购电成本中扣除。

另外, 将把本问的分位数修正预测 $\hat{L}_t$ 、 $\hat{P}_t$ 替换问题一的真值, 可得完整的日前计划 LP 为

$$\begin{aligned} \min \quad & F^{(d)} = \sum_{t=1}^{144} \lambda_t (a_t + b_t) \Delta t - 0.9 \lambda_{144} E_{144}^{(d)} \\ \text{s.t.} \quad & a_t + g_t + d_t = \hat{L}_t, \quad g_t + c_t + q_t = \hat{P}_t^{\text{pv}}, \\ & E_t = E_{t-1} + 0.9 (b_t + c_t) \Delta t - \frac{d_t}{0.9} \Delta t, \\ & 1200 \leq E_t \leq 10800, \quad b_t + c_t \leq 5000, \quad d_t \leq 5000, \\ & E_0 = E_0^{(d)}, \quad a_t, b_t, g_t, c_t, d_t, q_t \geq 0, \\ & t = 1, \dots, 144. \end{aligned} \quad (18)$$

6.2.4 求解与决策分位的确定

在前文对最优分位数的预期张, 式 (15) 得到的参考分位仅考虑了单个时段的惩罚, 没有包含储能跨时段传递、光伏弃电、SOC 上下限与日末存量价值等, 因此真实最优值最在其 0.833 基础上存在差异, 故其最终取值通过一系列梯度的遍历确定, 完全取自于优化情境下的数据特征。

遍历时, 令负载取 P_τ 、光伏取 $P_{1-\tau}$, 对每个候选 τ 重新执行 2025 年 2 月 1 日至 12 月 31 日共 334 天计划求解与实际数据结算。以 0.833 为中心、步长 0.02 遍历 $[0.733, 0.933]$, 再在 0.78 0.86 内进一步以 0.01 为步长细化。

遍历结果显示, 计划成本在 $\tau = 0.81$ 处最低 1495.38 万元, 故取 $\tau = 0.81$ 作为决策分位。

6.3 模型对比

为检验预测模型性能, 本节设置三组预测来源进行对照: 基于 EGD 的模型池、XGBoost 与 LSTM。三组预测来源使用同一个计划 LP 和同一套实际数据结算规则, 因此表中的费用差异全部取决于预测质量。表 7 比较了三者解的全年计划成本与紧急购电缺口。

表 7: 三组预测来源的全年模型对比 (2025.2.1–12.31, 费用单位: 万元)

方案	紧急费	成本	缺口/kWh
模型池组	413.39	1638.75	953,922
XGBoost 对照组	492.92	1710.30	1,120,334
LSTM 组	1633.96	2829.85	3,661,104

本模型的计划成本最低, 比 XGBoost 对照组低 71.55 万元, 比 LSTM 组低 1191.10 万元。虽然 XGBoost 能直接处理日历、滞后量等表格特征的非线性关系, 但是无法在长时段即使调整相应倾向, 较本模型为升本略有上升; 而 LSTM 虽具备提取长短期序列依赖的能力, 但纯时序基线缺少日历特征、训练窗口固定, 在 6—7 月与 10—11 月的季节切换期误差进一步放大, 导致计划层系统性少购电。其计划购电费虽为三组中最低, 却因缺口多付了数倍于计划费节省的紧急费用, 成本反而最高。

为三组预测来源的月度紧急购电费用. 可见, 即使三组的紧急费都随月份波动趋势相同, 但是本模型在 2 月, 6 月等换季时间点上具有对于 Xgboost 与 LSTM 的显著优势。




图 7: 三组预测来源的月度紧急购电费用对比

7 问题 3 模型的建立与求解

本问通过给出白天 0:00、6:00、12:00、18:00 的 24 小时光伏预报，微网可以在初次拟定计划后调整计划，成交与原始计划不等的部分另行计价构成惩罚。根据本问的问题分析，我们将模型也从确定性 LP 优化变为在多阶段信息链上求期望费用最小的随机规划。通过随机规划模型，将量化这三次调整的价值，并讨论是否还需要引入别的预报。

本随机规划模型的困难主要有两点。首先，预报本身的质量十分关键，但附件 3 提供的预报带有随发布时刻与提前步长变化的系统误差，直接充当情景中心会把偏差带入决策，故可能需要矫正并与第二问中构建的预测模型相融合；另外，需要着重考虑随机量的刻画与误差分布如何得到，光伏与负载由同一批天气驱动而彼此相关，四次预报又各自只能看到自己的过去，若把实际走势压缩成独立的正态扰动，两侧同时变坏所触发的紧急购电尾部会被系统性低估。

据此，把求解分为三层，先对预报做校正与融合得到各会话的采用中心，再以整日历史路径为样本搭出情景树，最后把计划与三次调整放进同一份期望费用联合求解，并在解出之后单独衡量每一次预报的信息价值。具体流程如下图所示。




图 8: 问题 3 的随机规划建模与求解流程

7.1 光伏预报的校正与融合

本问可用于决策的光伏信息有两个来源，一是附件 3 给出的整点预报，二是问题 2 已经建好的 EGD 集成预测，而负载仍沿用 EGD 的结果。这两个来源都不能直接充当情景的中心。首先附件 3 的预报带有明显的系统性偏差，早晨偏高、午后偏低，偏差还随发布时刻与提前步长一起变化，按会话与步长分层统计，其平方项占原始预报均方误差的 33.7% ~ 74.2%。这说明需要处理的是预报误差的主项，不可忽略。其次，可直观分析，两个来源的误差有概率互补，预报可以很好的弥补 EGD 模型无法感知当日极近时间点的情况，EGD 模型的预测也可以弥补预报未体现过去时序经验的问题。

故，我们考虑先对预报数据进行修正，再与 EGD 模型预测数据融合。

预报矫正 对附件的预报数据，按 4 个会话与 24 个步长分成 96 层进行去偏，每天只用当天之前 28 天的已实现残差估计各层偏差并从预报中扣除，随季节漂移滚动更新。窗长由 14 ~ 42 天的一组试验确定，我们取其中平台段的中点 28 天，不关注窗口内误差的极小点，以免把噪声当成信号。矫正后白天整点 MAE 由 566.6 降到 341.5 kW，在 334 天的窗口上由 581.0 降到 350.3 kW。

数据融合 考虑把矫正后的附件 3 与 EGD 按会话加权。由于两数据源误差的相关系数只有 0.081，认为误差近乎独立，从数据上说明预测和预报融合合理。在这一前提下，按逆均方误差定权是使融合方差最小的解析解，逐日滚动估计该权重，得到 0:00 为 0.36、6:00 为 0.55、12:00 为 0.74。权重随会话递增，是由于与预报提前量随会话增加、精度自然提高。具体表现见表 8，其中的绑定段指会话发布的预报真正覆盖、且进入本问决策的目标时段。

表 8: 年平均各会话绑定段的整点 MAE

会话	绑定段	矫正附件 3	EGD	会话融合	较优单源降幅
0:00	5:00–19:00	332.9	249.5	206.7	17.2%
6:00	6:00–19:00	221.5	253.9	173.0	21.9%
12:00	12:00–19:00	128.6	216.0	124.8	2.9%
18:00	18:00–23:00	6.4	3.5	4.2	退化

从表中易分析出融合对性能的提升。三个会话的融合结果都优于任一单一来源，0:00 与 6:00 的改善最大，12:00 由于附件 3 本身已经较准，融合只再降 2.9%。唯一退化的 18:00 绑定段在傍晚，光伏功率本身趋零，两个来源的 MAE 都不到 7 kW，融合无实质增益。

另外，考虑到两个来源的残差均在月尺度上摆动，融合中心的白天残差月度极差达 179 kW，上文的一级矫正窗跟不上这一尺度。所以，我们在矫正层之上再加一层按会话与目标小时分层的尾随矫正。

进一步误差矫正 这一层的增益温和，且固定窗长 14 天与逐会话择优的最大差只有 0.46 kW，说明选窗并不敏感。光伏数据四个会话的样本外 MAE 均有所下降，但负载的情形正好相反，经检验去掉偏差反而更差，白天 MAE 由 162.99 升到 170 左右，故负载沿用未去偏的预测。

7.2 情景树与四阶段随机规划模型

建模前，需确定费用计算方式。

记时段 t 的 0:00 计划购电量为 p_t ，该时段最终成交量为 u_t 。按要求成交低于计划的部分按 $0.5\lambda_t$ 计违约价，高于计划的部分按 $1.5\lambda_t$ 计超购价。若把计划量 p_t 也按 λ_t 全额计入，则成交从计划往下减 1 kWh 只省下 $0.5\lambda_t$ ，向下调整几乎无利可图，本题的 0.5 倍违约价便失去作用。故，本文按偏差电量考核的通行算法，记每时段的费用

$$\kappa_t = \lambda_t u_t + 0.5\lambda_t |u_t - p_t| + 5\lambda_t \text{gap}_t, \quad (19)$$

即成交电量按原价结算，偏离计划的部分不分方向按 $0.5\lambda_t$ 计罚，缺口仍由 $5\lambda_t$ 的紧急购电兜底。成交不低于计划时，这一式与题面完全重合，此时式 (19) 等于 $\lambda_t p_t + 1.5\lambda_t (u_t - p_t)$ ，正是超出部分按 1.5 倍计价的写法。

本问的随机量是光伏与负载的实际走势，两者都由天气驱动而彼此相关。为了充分关注该相关性，我们把一整天当作一个抽样单元，一条历史日就是一条完整路径，含

当天所有时点的光伏残差及同一批的负载残差，每天从日前 28 天的历史日里整日抽取，再按当天各会话中心还原成一条完整走势。这可以保留跨小时、跨会话以及光伏与负载之间的相关信息。

这里，我们没有改用低秩因子或高斯模型压缩的方法，原因在于 5 倍紧急费恰恰由光伏低于中心、负载又高于中心这种两侧同时变坏的联合尾部触发，高斯尾对这一情形的估计偏低。

同时，将预报带来的新信息写为一个递推。记 0:00 中心预报相对真值的整日偏差为 ε_0 ，它在 0:00 已经揭示；此后每个会话把中心从 C_{s-1} 修正到 C_s ，修正量 $G_s = C_s - C_{s-1}$ 为预报新信息，四个量满足恒等式 $A = C_0 + \varepsilon_0$ 与 $C_s = C_0 + \sum_{k \leq s} G_k$ 。

将每天抽出的 28 条历史路径按会话修正量分组，先在 G_1 的主方向上聚 3 支，再按 G_2 和 G_3 对分支继续聚 3 支，逐层嵌套成 $3 \times 3 \times 3$ 的情景树，结构如图 9。树的每个节点对应一个会话的决策层，节点内的情景共享一份申报。储能状态全程逐情景连续推进，0:00 至 6:00 按计划执行并叠加已经实现的光伏与负载，得到 6:00 的实测储电量，此后每个节点都从各自的起点储电量出发。




图 9: 四会话信息结构与 $3 \times 3 \times 3$ 情景树

一个会话开始后、下一个会话到来前，微网无法调整计划，因此该块内的购电与放电只能有一份申报。把四层申报写成一份变量集合，第一层是 0:00 计划 p_t ，覆盖全天 144 段，为 0:00 至 6:00 的成交与其余时段的偏差参照，第二至四层是各节点在自己块内的购电量 Q_t^n 与放电量 D_t^n 。目标为使每日总费用的情景期望最小

$$\min \mathbb{E}_\omega \left[\sum_{t=1}^{144} \lambda_t u_t^\omega + \frac{1}{2} \sum_{t=1}^{144} \lambda_t |u_t^\omega - p_t| + 5 \sum_{t=1}^{144} \lambda_t \text{gap}_t^\omega \right] - 0.9 \lambda_{144} \mathbb{E}[E_{144}^\omega], \quad (20)$$

其中 u_t^ω 为该时段最终成交的申报。约束沿用问题 2 的 LP 内核，即负载平衡、光伏平衡、储能动态与储电量上下界等。

对于该扩展型线性规划，每日约 2.5 万变量、0.8 万等式、1.9 万不等式，HiGHS 单日求解约 1.5 s，全年 334 天逐日串行滚动，次日的储电量初值取当日期末的实测值。

式 (19) 的两侧罚率还能给出一组可以预先推出的分位, 用来与数值解相互印证。计划两侧各罚 $0.5\lambda_t$ 、完全对称, 最优计划应落在真值分布的中位数上。调整的成交在计划之上时边际加价为 $1.5\lambda_t$, 之下时边际省钱 $0.5\lambda_t$, 缺口兜底 $5\lambda_t$, 故最优调整应偏向计划之上, 落在 $0.7 \sim 0.9$ 分位, 将在后文进行验证。

7.3 求解结果与分析

完成本模型求解后, 我们与问题二的日前计划方案进行了对比, 结果见下表。四阶段随机规划把全年总费用降到 1468.63 万元, 比问题 2 的日前计划少 170.12 万元, 降幅 10.4%。另外缺口由 953,922 大幅降到 352,966 kWh, 降幅 63%。

表 9: 问题 3 与问题 2 结果对比

方案	购电费	偏差费	紧急费	合计	缺口/kWh
问题 2 日前计划	1225.41	—	413.39	1638.75	953,922
问题 3 四阶段随机规划	1262.71	20.70	185.22	1468.63	352,966

进一步分析该最优解的费用结构。计划购电费反而比问题 2 高 37.30 万元, 多买的部分既用于对冲波动, 也用于把低价时段的电搬进储能; 新产生的偏差费 20.70 万元, 是成交偏离计划要付的价; 紧急费从 413.39 万元压到 185.22 万元, 省下 228.17 万元。可以看出, 模型宁可让计划阶段多花一点, 也尽量避免最贵的紧急购电。

题面另要求按表 1、表 2、表 3 的格式列出四个指定日期的结果。计划列是 0:00 的申报量, 成交列是最终的结算量, 储能为实测执行的充放电量, 紧急购电为实测缺口按连续时段合并。三张表依次见表 10 至表 12。注, 在本结果求解时取 2025.2.1-12.31 的 334 天作为时间窗口。

表 10: 指定日期的购电量/(kWh) 与购电费/(元)

时间段	3 月 20 日		6 月 21 日		9 月 23 日		12 月 21 日	
	计划	成交	计划	成交	计划	成交	计划	成交
10:00-10:10	0.00	0.00	0.00	0.00	0.00	0.00	208.37	208.37
12:00-12:10	518.40	508.22	0.00	0.00	397.49	397.49	878.32	888.48
14:00-14:10	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00
16:00-16:10	505.82	505.82	124.97	124.97	604.20	604.20	875.77	875.77
18:00-18:10	675.26	675.26	0.00	0.00	669.26	669.26	622.56	622.56
20:00-20:10	12.24	0.00	43.68	0.00	176.49	176.49	59.26	0.00
全天购电量	66835	65163	35514	33914	67991	68239	93898	93785
全天购电费	41039	40108	21174	19159	44875	45145	61251	61033

7.4 信息价值分析

为评估是否需要引入其他时刻的预报, 需要定量计算这三次预报的价值。该指标可分成两个随机规划利用调整会话数与信息预见范围等参数可算的量, 一是每一次预报后的调整在实际执行中赚回了的费用, 二是若这次预报完全准确能值多少。

表 11: 指定日期的储能充放电量/(kWh) 与 0:00、24:00 储电量/(kWh)

时间段	3 月 20 日		6 月 21 日		9 月 23 日		12 月 21 日	
	充电	放电	充电	放电	充电	放电	充电	放电
0:00-4:00	7044.50	0.00	1224.85	0.00	4462.55	0.00	7556.97	0.00
4:00-8:00	2213.60	5069.88	706.08	2067.74	2326.06	3817.73	2894.31	1993.34
8:00-12:00	4480.57	2777.38	9115.07	0.00	4949.88	1896.62	5278.61	6324.97
12:00-16:00	5728.82	254.72	0.00	0.00	3794.35	401.45	7114.57	2224.39
16:00-20:00	112.81	5593.10	38.19	6029.33	7.30	4945.02	0.00	5666.92
20:00-24:00	372.59	2796.02	1568.13	2381.22	1120.15	2743.01	471.00	2841.05
0:00 储电量	1859.03		3156.08		3613.05		1954.09	
24:00 储电量	1493.19		2900.63		3269.72		1770.59	

表 12: 指定日期的紧急购电时段与购电量/(kWh)

3 月 20 日		6 月 21 日		9 月 23 日		12 月 21 日	
时间段	购电量	时间段	购电量	时间段	购电量	时间段	购电量
3:10-3:30	9.89	3:10-3:20	10.10	5:00-5:10	10.70	3:30-3:50	68.73
16:00-16:10	46.07	5:00-5:10	19.83	14:30-14:40	4.63	10:40-10:50	13.57
16:40-16:50	0.04	6:00-6:20	42.70	15:50-16:00	3.41	12:50-13:00	8.29
18:10-18:30	36.35	18:50-19:20	112.96	18:10-18:30	19.86	16:50-17:00	1.27
18:40-19:20	176.89	19:40-19:50	0.95	20:50-21:00	14.60	18:00-19:00	155.41
19:30-19:40	19.65	20:10-20:40	106.89	21:20-21:30	8.85	19:20-20:00	62.70
20:00-20:20	56.89	21:20-21:30	51.18			20:30-20:40	6.59
20:30-20:50	94.61					21:30-21:50	36.43
21:10-21:50	145.91						
23:30-23:50	56.73						

价值度量的基准 随机规划原生的几个指标可作为量化价值的基准，等待观望解 WS，追索问题 RP，解的期望结果 EEV。WS 假设每条情景的真值提前揭晓，是任何策略都无法逾越的费用下界；EEV 无视不确定性，按初始计划并冻结执行。构造差值 $EVPI=RP-WS$ 描述不考虑不确定性带来的收益上界， $VSS=EEV-RP$ 描述充分考虑不确定性比朴素决策实际节省成本。根据这两个差值，可界定 RP 范围。

本场景下，令 RP 为四阶段随机规划的最优期望费用，WS 为每个情景预先知道真值时的最优费用，EEV 为由 0:00 中心预报拍一份确定性计划、此后冻结执行的费用。在 306 天窗口上按样本内的时间跨度，可得 RP 为 1167.53 万元，WS 为 1084.12 万元，EEV 为 1345.35 万元。故，完美信息价值 $EVPI = 83.42$ 万元，随机优的价值 $VSS = 177.82$ 万元。VSS 较大进一步说明本随机规划的有效性。

EVPI 完美价值分解 将 EVPI 按会话拆开，可得每一次预报的信息价值上限。我们在主模型上逐次放开完美预见，得到一族后缀解 $W_0 = RP$ 、 $W_4 = WS$ ，第 s 次预报的价值即 $W_{s-1} - W_s$ ，四段之和恰好等于 EVPI。306 天窗口中，EVPI 结果为 6:00 预报 15.72 万元、12:00 预报 18.65 万元、18:00 预报 9.63 万元、0:00 计划本身 39.42 万元。0:00 最大十分合理，因为其在全部不确定性下需要决策最长的时间。从 EVPI 按会话分解来看，三次日内预报里以 12:00 价值最高。

真实预报的实际增量 上界描述的是预报完美时的价值，但实际无法达到，实际预报价值由启用族给出。

将日内调整的次数依次增加，同一条模型族的成本严格递减，见表 13。相邻两次的增量即为该次预报的边际价值，从表中可见三次全为正即均有价值。特别的，我们海岸 18:00 一次的实际增量 11.71 万元，略高于它的完美信息价值 9.63 万元，正说明它的价值里有相当一部分来自多一次调整机会本身，而不只是预报更准。

这一指标直接说明了引入 6:00、12:00、18:00 的预报均值得，且以 12:00 预报价值最高。进一步分析结果，两种度量都把 12:00 排在日内第一，其原因可能是 12:00 的预报修正的是午后到晚上，这段含晚峰的高电价，而发布时间不算很近、提前量短而精度高，一次修正能同时改购电量与充放电安排。6:00 的预报看得更远、上界更高，但它离晚峰尚远，之后的会话还会把它覆盖掉，实际兑现的比例因此偏低。18:00 只剩晚间数小时，光伏趋零，故实际增量最低。

表 13: 各会话预报的完美信息价值与实际增量

会话	完美信息价值	实际增量
0:00 计划	39.42	—
6:00	15.72	6.72
12:00	18.65	12.63
18:00	9.63	11.71
合计	83.42	31.06

价值瀑布图分析 下图的价值瀑布将整个问题三的信息统合，清晰的表现各方案的实际求解结果，这也可以说明模型改进的有效性。以问题 2 的日前计划为基线，换用原始附件 3 预报的四阶段模型费用为 1451.00 万元，换上去偏与融合的中心降到 1344.15 万元，均高于完美信息下界 1084.12 万元。这可以体现出，从原始预报到矫正融合中心即预报质量的价值，以及从矫正融合中心到完美信息即残余不确定性的价值。

与问题二的日前预测 LP 方案的结果对比，可以明显看到采用日内调整机制与预报来源的随机规划本身的价值；而本模型中呈现的预报矫正、数据源融合通过提供误差分布更稳定的输入，进一步的扩大了方法优势。

稳健性检查 上述结论还通过了时段与分支两个方向的检验。时段上，本文将 306 天前后均匀切分为两个窗口分别重算，两半区的 EVPI 与 VSS 几乎相同，会话价值的排序也保持一致，说明信息价值的各项结论几乎不依赖所取时段，并非特定季节或月份影响下的偶然结果；分支上，我们也将情景树重新设计到 $5 \times 5 \times 5$ 树并进行对比，样本内费用虽进一步下降，实测路径结算却反而劣化，其根源可能在于有限的供体路径无法支撑更细的叶节点，导致节点决策过拟合单条历史路径，故主模型仍保持 $3 \times 3 \times 3$ ，

另外，当前目标函数控制风险中性，这里对尾部风险进行分析。在最优解上统计逐日实测净费用 P50、P90、P95 为 4.62、6.20、7.41 万元/日，而最差 5% 的日子日均约 8.7 万元，较 P95 仅上升 1.3 万元，说明最差日子内部费用彼此相近、不存在个别极端日把条件均值远超阈值的尾部，策略的低期望费用并不存在极端差解的代价。




图 10: 问题 3 价值瀑布图

8 问题 4 模型的建立与求解

9 模型评价与总结

参考文献

[1] 王先齐, 吕智林, 汤泽琦. 基于分时电价机制的并网型微网多目标动态优化调度 [J]. 电力系统保护与控制, 2017, 45(4). DOI: 10.7667/PSPC160250.

[2] 袁龙. 分布式光伏发电与储能协同调度模型研究 [D]. 济南: 山东大学, 2018.

[3] Sioshansi R, Denholm P, Jenkin T, et al. Estimating the value of electricity storage in PJM: Arbitrage and some welfare effects[J]. Energy Economics, 2009, 31(2): 269-277.

[4] 王凌云, 王晓敏, 胡兴媛, 等. 基于多智能体微网的需求侧分时电价优化调度 [J]. 信息与控制, 2020, 49(4): 429-435.

[5] Boyd S, Vandenberghe L. Convex Optimization[M]. Cambridge: Cambridge University Press, 2004.

[6] 车泉辉, 陈建洪. 光伏功率短期预测方法研究综述 [J]. 电力自动化设备, 2022, 42(10): 12-21.

[7] Arrow K J, Harris T E, Marschak J. Optimal inventory policy[J]. Econometrica, 1951, 19(3): 250-272.

[8] Cleveland R B, Cleveland W S, McRae J E, et al. STL: A seasonal-trend decomposition procedure based on Loess[J]. Journal of Official Statistics, 1990, 6(1): 3-73.

[9] Lu J, Liu A, Dong F, et al. Learning under concept drift: A review[J]. IEEE Transactions on Knowledge and Data Engineering, 2019, 31(12): 2346-2363.

[10] Wagner-Muns I M, Guardiola I G, Samaranayake V A, et al. A functional data analysis approach to traffic volume forecasting[J]. IEEE Transactions on Intelligent Transportation Systems, 2018, 19(3): 878-888.

- [11] Akyurek B O, Akyurek A S, Kleissl J, et al. TESLA: Taylor expanded solar analog forecasting[C]. 2014.
- [12] Mourtada J, Gaïffas S. On the optimality of the Hedge algorithm in the stochastic regime[J]. Journal of Machine Learning Research, 2019, 20(83): 1-46.
- [13] Graefe A, Küchenhoff H, Stierle V, et al. Combining forecasts: Evidence on the relative accuracy of the simple average and Bayesian model averaging[J]. Statistical Modelling, 2015.
- [14] Wang Y, Zhang N, Tan Y, et al. Combining probabilistic load forecasts[J]. IEEE Transactions on Smart Grid, 2019, 10(4): 4477-4489.
- [15] Zhang Y F, Wen Q, Wang X, et al. OneNet: Enhancing time series forecasting models under concept drift by online ensembling[C]//Advances in Neural Information Processing Systems (NeurIPS). 2023.
- [16] Sun Y, Hong Y, Lee T H, et al. Time-varying model averaging[J]. Journal of Econometrics, 2021, 222(2): 974-992.

AI 工具使用声明

（占位）本项按竞赛当期规范填写。