

基于线性规划与对偶分析的微网计划购电策略

摘 要

(占位)摘要待问题 2–4 完成后统一撰写。本问已备妥的数值结论: 全天购电 59482.7 kWh、购电费 35126.85 元, 较无储能运行节省 26.9%; 充放电启停受阈值 $1/0.81 \approx 1.235$ 支配; 规则式策略较线性规划最优贵 11.71%。

关键词: 微网; 分时电价; 储能调度; 线性规划; 对偶分析

1 问题重述

2 问题分析

问题 1 的电价与小区负载每天相同, 光伏发电功率有全天预测, 微网要在每天 0:00 一次性给出当天逐 10 min 的计划购电策略, 供电不得低于负载, 储能设备在 0:00 与 24:00 的储电量相同。电量、负载与光伏三条曲线在一天内峰谷错位, 而电能无法大量囤积, 跨时段的余缺调剂只能经储能完成; 充放效率各为 90%, 1 kWh 电能一进一出只剩 0.81 kWh, 低充高放要有净收益, 充放两段的电价比须跨过 $1/0.81 \approx 1.235$ 的门槛, 这一权衡贯穿全问。附件 1 的电价呈双谷双峰形态, 峰谷价差远超门槛, 低充高放有充足的运作空间; 首末电量相同叠加曲线逐日重复, 全年运行分解为同一个单日问题的逐日重复, 只需对 2025 年 1 月 1 日建立单日模型。购电、光伏与储能三路电能流的逐段分配取值连续, 目标函数与全部约束均为线性, 问题归结为线性规划。求解之外, 我们进一步借对偶变量构造节点边际价值, 用 KKT 条件证明最优性并解释充放电窗口的启停结构, 再对效率与功率上限做灵敏度检验, 对偶分析由此成为本文的特色。

问题 2 的难点集中在负载与光伏两条曲线的不确定性上: 它们随日期变化, 而在每天 0:00 规划当日购电时, 当日的真实情况尚不可知, 能依靠的只有截至前一日的附件 2 历史数据。计划的输入必须先由历史数据预测得到, 本问据此拆成前后相接的两个部分。前一部分做预测: 单一模型难以在全年不同季节同时保持准确, 我们构建机制互补的异构模型池, 让不同模型的优势结合、缺点相互抵消, 并用指数梯度下降在线更新各成员的权重, 使权重向近期误差更小的模型倾斜, 对季节切换保有较快的响应。预测的输出不是单点值, 而是一组分位数梯度曲线, 给后续决策留出保守调整的余地。后一部分做优化: 拿到分位数预测后, 沿用继承自问题 1 的 LP, 补充紧急购电的结算表达式后求解。在这一环节, 预测实际上是为优化服务的, 分位档调高一些, 预估就更保守, 5 倍价的紧急购电就更少被触发; 调得太低则缺口惩罚失控, 调得太高又白白多买, 保守换来的罚金节省与过保守付出的购电增量之间存在一个平衡点, 我们通过遍历分位档组合、以全年总费用回测的方式把它找出来。求解之外, 本文还做了对照实验: 把预测环节换成 XGBoost 与 LSTM 两个强大的时序预测模型, 计划与结算环节保持不变, 比较三组最终的最优成本, 以展现本文预测模型的优越性。

3 模型假设

1. **日周期性：**附件 1 的电价与负载曲线逐日相同，光伏预测为同一日曲线，其中电价在 0.3713 与 1.3952 元/kWh 之间，负载在 3309 至 5959 kW 之间，光伏峰值 7612.3 kW，计划得以逐日复制，这是 5.1 节时段划分的依据。
2. **储能效率口径：**充、放电效率各取 90%，往返效率 81%，损耗只发生在进出储能的路径上，直供负载不打折。设计说明：题面只给”充放电效率为 90%”一个数值，两种记法在文献中都有，文献 [1] 对充、放分别取 93% 与 92%，文献 [3] 把往返效率记在充电侧；本文取前者，若改按”往返合计 90%”重解，成本为 33416.43 元、低 4.87%，差异不影响模型结构，声明口径即可。
3. **功率上限口径：**5000 kW 指储能设备并网侧，即母线端的充、放电功率，两个方向对称；计入效率后电池侧存入不超过 4500 kW、放出不超过 5556 kW，与表 2 的母线计量一致。
4. **不售电：**购电量与放电量均非负，不向外网反送电；光伏盈余只能充电或弃掉，弃光不计费用，以与题面”购电量”的记账方向一致。
5. **完全信息：**0:00 制定计划时全天电价、负载与光伏预测已知且无误差，问题 1 为确定性规划，预测误差与缺电惩罚留给问题 2、3。

4 符号说明

符号	说明
Δt	单时段长度, 10 min
λ_t	时段 t 的外网电价, 元/kWh
L_t	时段 t 的小区负载, kW
P_t^{pv}	时段 t 的光伏发电预测功率, kW
a_t, b_t	时段 t 购电功率中直供部分 / 充电部分, kW
g_t, c_t	时段 t 光伏功率中直供部分 / 充电部分, kW
q_t	时段 t 光伏弃光功率, kW
d_t	时段 t 储能放电功率, kW
E_t	时段 t 末储电量, kWh
S_t	时段 t 末的净充电累计量, $E_t = 6000 + S_t$, kWh
η	充放电效率, 取 0.9
$E_0, E_{\min}, E_{\max}$	储电量初值与界限: 6000、1200、10800 kWh
$P_{\max}$	并网侧充放电功率上限, 5000 kW
γ_t, σ_t	节点边际价值 / 边际供电成本, 元/kWh
$\hat{L}_t, \hat{P}_t$	问题 2 中时段 t 经选定分位档修正的负载 / 光伏预测, kW
P_t	问题 2 结算用的光伏实际功率, kW
g_t^r	问题 2 结算期实际光伏直供功率, $\min(g_t, P_t)$, kW
R_t	问题 2 时段 t 实际总供给, $a_t + g_t^r + d_t$, kW
e_t	问题 2 时段 t 供电缺口, kW
$E_0^{(d)}$	第 d 日 0:00 储电量, 滚动取前一日执行期末值, kWh
$F^{(d)}$	第 d 日计划购电费, 元
$w_{t,i}$	第 t 日模型 i 的 EGD 集成权重
$\tilde{\ell}_{t,i}$	模型 i 第 t 日的局部核加权损失
μ	EGD 权重更新学习率, 取 0.005
α	权重重初始化的混合系数
τ	决策分位, 负载取 P_τ 、光伏取 $P_{1-\tau}$
C_u, C_o	购电低估 / 高估的单位成本, $5\lambda_t / \lambda_t$

5 问题 1 模型的建立与求解

对于电价、负载和光伏发电量等所有数据已知的第一问, 我们分析题目和数据信息, 建立了简单的 LP 模型并求解严格最优解。在完成了最优解的结果分析后, 我们还通过对偶分析和最优性证明, 以及本场景恰当的灵敏度分析保证了模型的合理和稳健。具体流程如下图所示:

5.1 LP 模型建立

首先可对附件 1 中的数据做简要预分析。

本题把每日划成 144 个时段 $I_k = [10(k-1), 10k) \text{ min}$, $k = 1, \dots, 144$ 。 I_1 取附件的第 144 行, 该行标记的是次日 0:00 起的 10 分钟, 由假设 1 的周期性, 其数值与当日 0:00 至 0:10 相同; I_2 至 I_{144} 依次取当天的第 1 至第 143 行。可以简要分析出, 电价在深




图 1: 问题 1 的建模与求解流程

夜与午间各有一个低谷，早 8 时前后与 19 时至 22 时各有一个高峰，双谷双峰的形态给储能低充高放留出了空间。

在本问的微网为小区负载的场景下，构建每个时刻的电能流是理解各购电、充放电和供电的关键所在：

外网购电 作为最基本的电能来源，可以规划从外界直接购入的购电量，并在较长的时间窗口满足外界总购电量略多于总负载的用电量，稍多的部分会在储能设备转化时损耗。外网购电可能根据存贮计划分流，一部分可转向储电设备并以 90% 的效率存储 b_t ，另一部分考虑可以直接转向小区负载供电 a_t 以减少损耗率；

光伏发电 类似的，小区内光伏发电的功率同样进行拆分，拆成直供负载的 g_t 与储能充电 c_t 两路，后者同样存在 90% 效率的能量转换。而由于光伏发电为被动来源，在储能设备几乎存满且负载低的极端情况下，可能出现废弃的光能功率，光伏与储能的协同调度正是处理这类消纳问题的常见框架 [2]。

储能供电 储能设备可以将通过外购和光伏存入的能量再以 90% 的效率输出，为小区负载供电。我们记放电总功率为 d_t 。同时，每个时刻的储电量 E_t 由充放电累计得到全天购电费为各段电价乘以购电量之和，针对购电成本的目标函数为

$$\min F = \sum_{t=1}^{144} \lambda_t (a_t + b_t) \Delta t. \quad (1)$$

本场景中涉及的基本约束包括：

供电平衡 考虑到微网供给不得低于负载，又由于多供无益。在所有时刻维持总供电刚好满足需求负载，取等式

$$a_t + g_t + d_t = L_t. \quad (2)$$

光伏电量平衡 根据电能流的梳理，光伏发电分流到直供负载、储电以及极端情况的废弃量，即

$$g_t + c_t + q_t = P_t^{\text{pv}}. \quad (3)$$

储能动态 对于储能设备而言，每一个时刻的储电量变化需考虑所有充放电路径。由于其充放电效率为 90%，迭代时注意存在损耗，即

$$E_t = E_{t-1} + 0.9 (b_t + c_t) \Delta t - \frac{d_t}{0.9} \Delta t, \quad (4)$$

储电量约束 为保护设备在长期运转的健康水平, 每个时刻的储电量需要避免过高或过低

$$1200 \leq E_t \leq 10800 \quad (5)$$

同时, 充放电在单位时间的功率也存在界限, 采用行业常用的并网侧约束, 即损耗之前进行约束 $b_t + c_t \leq 5000$ 、 $d_t \leq 5000$ kW。

周期边界条件 场景已经给定 2025 年 1 月 1 日 0:00 的储电量为 6000 kWh, 且要求每天储能设备在 0:00 与 24:00 的储电量相同, 故每晚午夜储电量均为 6000 kWh, 计划逐日执行时第 k 天 0:00 的节点 E_{144k} 都取该值; 罐内储电量本身仍随充放电在界限内波动, 该要求在单日模型中表现为首末两端

$$E_0 = E_{144} = 6000 \text{ kWh}. \quad (6)$$

其中, 变量非负隐含 $d_t \leq L_t$, 放电不会超过负载, 不发生向外的反送。

合并式 (1) 至式 (6), 问题一的完整 LP 为:

$$\begin{aligned} \min \quad & F = \sum_{t=1}^{144} \lambda_t (a_t + b_t) \Delta t \\ \text{s.t.} \quad & a_t + g_t + d_t = L_t, \quad g_t + c_t + q_t = P_t^{\text{PV}}, \\ & E_t = E_{t-1} + 0.9 (b_t + c_t) \Delta t - \frac{d_t}{0.9} \Delta t, \\ & 1200 \leq E_t \leq 10800, \quad b_t + c_t \leq 5000, \quad d_t \leq 5000, \\ & E_0 = E_{144} = 6000, \quad a_t, b_t, g_t, c_t, d_t, q_t \geq 0, \\ & t = 1, \dots, 144. \end{aligned} \quad (7)$$

5.2 LP 模型求解

式 (4) 中的储电量 E_t 并非独立的决策量, 任一时刻的储电量都由之前的充放电决策唯一确定, 求解时把它消去, 改记业内常见的净充电累计量 SOC

$$S_t = \sum_{s \leq t} \left[0.9 (b_s + c_s) - d_s / 0.9 \right] \Delta t, \quad (8)$$

以 $E_t = 6000 + S_t$ 代入, 容量界限与终端条件都化为对 S_t 的直接约束。这一消元可提前省去 144 个状态变量及其对应的 144 条递推等式。虽然 S_t 的界限行带前缀求和, 非零元随时段增多, 约束矩阵变得更稠密, 但这在 144 段的规模下不构成负担。

最终交给求解器的是 864 个决策量、289 个等式约束与 576 个不等式约束。在实际求解中, 容量界限行与终端归零行的对偶变量合成了各时点的节点边际价值, 5.4 节的 γ 递推将直接构造自这组输出。求解调用 `scipy.optimize.linprog` 接口的 HiGHS 求解器, 容差沿用默认设置, 单次求解约 0.25 s。

求解器在返回最优解的同时给出全部对偶变量, 5.4 节的影子价格直接取自这一输

出；求解前后还通过了以下三类自检：

全天能量守恒 购电量加光伏发电量应等于负载、弃光、充电损耗与放电损耗之和，两侧相差 1.5×10^{-11} kWh，即恒等式累积误差完全为运算精度误差；

购电策略合理 最优的购电策略应该是利用本题数据的双谷双峰形态，在低电价时购入并存储并在高电价时取用，这导致解的外网购电存在分块特征。具体分析见 5.3 节的表 2 与图 2；

无同时充放电记录 同时充放电这一理论上绝非最优的策略在解中并未出现。从实际情况考虑，对储能设备同时充放电更易由于总功率较高而造成损伤；同时从优化模型上考虑，发生同时充放电时将其相互抵消，即可省下存储 90% 所带来的能量损失，这在理论上可降低成本，严格的论证见 5.4 节。

5.3 模型结果分析

全天购电 59482.7 kWh、购电费 35126.85 元；无储能运行时按逐段缺口 $\max(0, L_t - P_t^{\text{PV}})\Delta t$ 购电需 48052.05 元，储能低充高放节省 12925.20 元、降幅 26.9%，数据见表 1。六个指定时段里，10:00-10:10、14:00-14:10 与 20:00-20:10 的购电量均为 0，这些时刻光伏加储能足以覆盖负载。

计划购电量按模板逐行填写，第 2 至第 144 行依次对应 I_2 至 I_{144} ，末行填 I_1 的数值，即次日首段的计划。

表 1: 微网指定时间段微网购电量及全天购电情况

时间段	购电量/kWh	时间段	购电量/kWh
10:00-10:10	0.00	16:00-16:10	394.93
12:00-12:10	486.40	18:00-18:10	636.98
14:00-14:10	0.00	20:00-20:10	0.00
全天购电量	59482.7	全天购电费/元	35126.85

表 2 按四小时块汇总，汇总块来自 I_{24k+1} 至 I_{24k+24} 逐段统计。

表中可见，充电集中在 0:00-4:00、12:00-16:00 与 20:00-24:00 三个块，放电主力在 4:00-8:00 与 16:00-20:00；这一特征结果高度符合数据分析中描述的峰谷特征，该策略为 LP 的核心特征。

表 2: 储能设备在指定时间段的充放电量及 0:00 和 24:00 的储电量

时间段	充电量/kWh	放电量/kWh
0:00-4:00	4500.00	0.00
4:00-8:00	833.33	5947.42
8:00-12:00	3954.63	2121.42
12:00-16:00	6119.37	91.10
16:00-20:00	0.00	5068.69
20:00-24:00	5333.33	3571.31
0:00 与 24:00 储电量	6000	

下图给出了储能设备的储电量变动情况与各时段功率。日循环呈两充两放结构, 0:00-1:00 以 5000 kW 顶格充电 4500 kWh, 5:40-5:50 抓住全日最低价 0.3713 元/kWh 补充 833.3 kWh, 储电量触及上限 10800 kWh; 早峰 6:00-9:40 放电 8068.8 kWh, 恰好覆盖全部负载, 这三个多小时内购电为零; 午间由光伏盈余充电并在低价段补购; 晚峰 18:50-20:50 放电 8530.7 kWh, 电价最高的 1.3952 元/kWh 时段购电为零; 22 时起分批回充, 24:00 回到 6000 kWh 闭环。特别的, 外购充电全部落在 0.371 至 0.479 元/kWh 的时段里, 放电时段的电价最低也有 0.690 元/kWh; 另外, 全天弃光为零, 光伏发电量被负载与储能完全使用。




图 2: 解的储能状态与各时段购电、充电及放电功率

5.4 对偶分析及最优性证明

LP 的对偶变量给出比数值解更深一层的解释。我们给各类约束挂上影子价格, 据此定义节点边际价值 γ_t : 在时段 t 末白得 1 kWh 储能, 全天购电费能省下多少。 γ 沿时间轴满足递推

$$\gamma_t = \gamma_{t+1} - \eta_t + \theta_t, \quad (9)$$

其中 η_t 、 θ_t 是储电量上、下限约束的对偶变量。内点节点上 γ 逐段不变, 能量躺在罐里不生息; 满罐节点 γ 下移 η_t , 空罐节点 γ 上移 θ_t 。由 KKT 互补松弛条件可得充放电的三条启停判据, 对偶理论见文献 [5]。充电段满足 $\lambda_t = 0.9\gamma_t$, 功率顶格段另加正的影子溢价; 放电段满足 $\sigma_t = \gamma_t/0.9$, σ_t 为该段边际供电成本; 空闲段的价格落在 $0.9\gamma_t$ 与 $\gamma_t/0.9$ 之间的迟滞带内。把充、放电段的等式联立, 可得跨窗口搬运能量的门槛, 放电价与充电价之比须不低于

$$\frac{1}{0.81} \approx 1.235. \quad (10)$$

说白了，价差比不到 1.235 的两段之间，LP 一千瓦时也不会搬。同一段内边充边放的情形可以先用损耗的账排除。取充分小的 δ ，若某段同时有 $b_t > 0$ 与 $d_t > 0$ ，把充电减 δ 、放电减 0.81δ 、直购增 0.81δ ，储电量轨迹逐点不变，购电费净省 $0.19\lambda_t\delta\Delta t$ ，只要电价为正，原解就还不是最优。对偶条件给出同一结论，边充边放要求 $\lambda_t = 0.9\gamma_t$ 与 $\lambda_t = \gamma_t/0.9$ 同时成立，推出 $\gamma_t = 0$ 且 $\lambda_t = 0$ ，与恒正的电价矛盾。故最优解中不存在同段充放，无需为排除该行为引入 0-1 变量，这与文献 [1] 用状态变量处理储能充放互斥的做法形成对照。

图 3 画出 γ 与 λ 的全天对比，底色可区分出充放电窗口，有以下两处结构值得讨论。

首先是，两个放电大窗口 6:00-9:40 与 18:50-20:50 内 σ 分别为 0.591 与 1.256 元/kWh，都低于当时的电价，储能把两个价格峰完全削平，窗口内购电为零。

其次是，15:10-18:30 储电量顶在 10800 kWh 的平台期， γ 从 0.733 爬升至 1.130 元/kWh，每经过一个满罐节点上移一点，罐容稀缺的影子价随放电极近在累积。最优性方面，互补松弛条件在全时段的违约不超过 1.4×10^{-17} 元/kWh，节点价值的有限差分重解与对偶值偏差为 1.2×10^{-12} ，两条独立途径相互印证。




图 3: 储能节点边际价值 γ 与电价 λ 的全天对比

5.5 模型灵敏度分析

除了对本 LP 结果的理论分析，还可以从灵敏度进行评价。

本问选择了 $\eta, P_{\max}$ 这两个行业内通常不固定的指标，尝试进行灵敏度分析。虽然本题给定了具体数值，但我们认为如果在给定值的邻域波动参数也能通过灵敏度检验，则可以较好的说明模型稳健性；其次，我们选择了问题在业界的常见方案做结果的对比，以体现模型的优越性。

充放电效率 η ， 本题在储能设备参数处给定 $\eta = 90\%$ ，但是在实际生产中同一批储能设备的参数都可能存在误差，且在使用、老化的过程中，电机的效率损失几乎是必然的；此外，该参数在模型的求解过程中及其重要。由于 η 决定套利阈值 $1/\eta^2$ ，效率越低，值得搬运能量的价差组合越少，解的结构就会随之改变。

所以本文围绕 90%，扫描取 0.85 至 0.95 共五档，每档重新求解完整的规划，结果见表 3。成本随 η 单调下降，每提高 0.01 仅约降 0.8%，并未出现较大敏感波动。

失效边界在 $\eta \approx 0.841$ 。早峰 6:00-9:40 需要储能送出 8068.8 kWh, 满电自 10800 kWh 放至下限 1200 kWh 最多送出 9600η kWh, η 低于 $8068.8/9600 \approx 0.841$ 后单个日循环放不满早峰缺口, 必须在午间以更高的电价二次回充, 成本曲线在此转陡。

表 3: 充放电效率 η 的敏感性扫描

η	阈值 $1/\eta^2$	购电费/元	较 $\eta = 0.90$
0.85	1.384	36603.21	+4.20%
0.88	1.291	35696.82	+1.62%
0.90	1.235	35126.85	题面取值
0.92	1.182	34575.53	-1.57%
0.95	1.108	33767.02	-3.87%

功率上限 $P_{\max}$ 分析可得, 解中有 19 个时段的充电功率顶在 5000 kW, 该约束频繁激活, 值得单独查验。把 $P_{\max}$ 放宽到 6000 kW 重解, 成本仅降 0.12%。其看可能的原因是低价时段的总电量足以把储能设备充满, 上限改变的只是充电在时段之间的分布, 而不是充入的总量; 放电峰值功率 4294 kW 从未触顶, 两个方向中只有充电侧受到约束。而假设 3 中我们对于 $P_{\max}$ 的并网侧理解与“电池侧”, 认为时电池实际存入或输出的功率可达 $P_{\max}$, 对结果的影响同样被限制在这一量级。

6 问题 2 模型的建立与求解

问题 2 继承了问题 1 构建的 LP 模型, 但是有两个条件改动。

日前预测必要性 负载与光伏逐日变化, 考虑当日真实值在制定计划时不可知, 这里便衍生出了基于日前信息进行时间序列预测的需求。同时, 考虑到负载和光伏发电数据的波动特征等可能存在差异, 在建模时需要通过不同的方法学习不同特征。

紧急购电 由于计划依据的数据来源于预测, 执行过程中因误差导致的若供电不足, 须按交易时刻电价的 5 倍向外网紧急购电。

据此, 本问的求解框架分为日前预测部分及 LP 求解部分, 具体流程如下图。




图 4: 问题 2 的建模与求解流程

6.1 日前预测模型的建立

预测层需在每日 0:00 时刻, 利用截止前一日的全部历史数据, 对当日 144 个 10 分钟间隔时点的小区负载功率与光伏发电实际功率进行日前预测。同一天预测值不考虑带回增量训练以避免误差累积。

考虑到从 31 天数据的冷启动到后期数百天的数据跨度, 以及季节性的峰值等特征可能漂移, 我们认为预测层实际的关键在于在不同数据量情况、两种不同预测目标特征、季节性趋势明显、特殊的噪声和信号识别上的高自适应能力, 该模型同时还需要兼顾短时天气变化的快速响应。可见, 这种多环境的自适应需求很难由单 ML 模型满足, 故我们拟采用多模型互补的思路, 通过高度灵活的方法调整模型权重, 尝试达到在不同场景的高预测性能。

6.1.1 两目标时序特性分析

在多模型的组合构建前, 需要分别分析小区负载和光伏发电量的时序特性, 方便后续进行更加具备科学性的模型选择。纳入不足或者偏向明显的组合, 可能导致模型池不擅长一些情境的信息捕捉; 而纳入过多各类模型, 会使得求解效率低下, 而同类模型特性互相叠加影响, 类似共线性的效应严重影响求解效率。

小区负载 对其自相关分析, 结果显示滞后 7 阶自相关系数达 0.971, 而滞后 1 阶仅 0.373, 这表明周周期为首要周期成分。此外观察到周内模式呈现显著分化, 周一至周四及周日日均负荷约 5165 kW, 但周五、周六骤降 37% 至 3265 kW, 反映了工作日与周末的居民用电行为差异, 符合生活常识。而在日级别方差分解中, 周季节成分占 89.3%, 趋势占 14.1%, 残差仅 4.4%, 进一步验证了周周期的主导地位。日内峰谷比在 [1.80, 2.11] 中, 峰值时点存在季节漂移, 由 1 月 09:00 对应早高峰的峰值, 7 月漂移至 17:30 对应晚高峰, 月度均值极值比为 1.23。

光伏发电 类似的, 滞后 1 阶自相关系数为 0.956, 而滞后 7 阶为 0.878, 表明日连续性远强于周周期, 不同于负载特征。同时, 工作日与周末的表现无显著差异, 符合自然特征。月度均值极值比达 1.93, 这由气候缘故决定。且光伏发电的物理约束明确, 即夜间功率恒为 0、峰值恒在 12:00 前后, 日出日落时点由天文规律确定。故, 天气是主要噪声来源, 且日间变异系数在区间 [0.06, 0.11]。

上述特性直接驱动了模型选型策略。负载需重点建模周周期与季节漂移, 光伏需重点建模日连续与年周期, 并利用物理约束强制夜间置零。考虑到两个序列的显著时序特性差异, 采用独立模型组合而非统一模型池。

6.1.2 异构模型池构建

针对“单一模型难以覆盖全年周期特性”的问题, 本文构建机制差异化的异构模型池, 而非依赖单一算法。模型选型遵循三条原则: (1) 每个模型捕捉不同的时序成分(周期/趋势/曲线形态/相似日/非线性); (2) 剔除误差高度相关的冗余模型; (3) 所有模型均在滚动设定下合规运行(不使用未来信息)。

模型池的构建经历了实证精简过程：初始纳入 7 个负载模型，经全量消融实验（见 6.4.3 节）发现函数型主成分分析（FPCA，全期 MAE 258.32）和谐波回归（HarmonicReg，全期 MAE 353.82）的边际贡献为负——移除后集成 MAE 反而略降 0.2 0.4，夏季 6-7 月改善 1 3%。因此最终负载池精简为 5 个模型，光伏池保留 5 个模型。

负载模型池

（1）季节朴素预测：预测值等于上周同一时点的实际值。作为周周期强基准，其全期 MAE 为 176.80。该方法无需训练，在周周期稳定的春秋季节表现优异。

（2）月度均值预测：近 4 周同一时点的算术平均。借鉴 TVJMA（Time-Varying Jackknife Model Averaging）的局部窗思想，对短期波动起平滑作用。全期 MAE 为 188.88。

（3）STL 分量预测：对每个时点的历史日序列做 STL 分解（period=7, seasonal=7, trend=15, robust=True），将序列分解为趋势、季节与残差三部分；趋势分量采用阻尼系数 0.8 线性外推（抑制趋势突变），季节分量取上一周同相位值，残差置零。STL 原文（Cleveland, 1990）的鲁棒局部加权回归可有效抵御异常值。全期 MAE 为 178.59。

方法取舍 选择 STL 而非 CEEMDAN/VMD 等模态分解方法，原因是后者需在全局数据集上分解，在滚动设定下会引入未来信息泄漏；STL 仅在训练窗内分解，完全合规。

（4）kNN 相似日：以昨日完整曲线为查询，在近 60 天历史中寻找归一化欧氏距离最近的 3 个候选日（负载限定同星期几），以距离倒数为权重取候选日次日曲线的加权平均。该方法借鉴 TESLA（Akyurek 等，UCSD）在光伏预测中的相似日框架，文献报告其 RMSE 较 persistence 降低 50%。全期 MAE 为 188.80。

（5）LightGBM：自 XGBoost 改进的梯度提升树，工程上极常用的机器学习模型。构建 18 维特征（日历特征：doy, dow, month, weekend, hour, sin_t, cos_t, sin_dow, cos_dow, time_idx；滞后特征：lag1, lag2, lag7, lag14, lag21, lag28, lag7mean, lag1dmean）。强正则配置：n_estimators=600, learning_rate=0.03, num_leaves=15, min_child_samples=30, subsample=0.7, colsample_bytree=0.7, reg_alpha=1.0, reg_lambda=5.0，早停轮数 50。全期 MAE 为 172.71，为负载最优单模型。

光伏模型池

（1）Persistence：昨日同刻值。本文选择该极简方法，而非在短期做指数平滑或小窗口去噪，是因为希望赋予模型池对于每日的突发气候变化以最快速的响应能力。光伏日形状相对稳定时的强基准，全期 MAE 为 185.35。

（2）kNN 相似日：同负载 kNN 逻辑，但不限定星期几（光伏工作日/周末无差异），全期 MAE 为 205.04。

（3）STL 分量预测：同负载 STL 逻辑，全期 MAE 为 212.73。

（4）FPCA（函数型主成分分析）：近 14 天曲线 SVD 低秩重构，采用阻尼 score persistence（预测曲线 = 均值 + 0.4 × 最近一日主成分得分重构），在保留近期天气信息的同时抑制异常传播。预测值 clip 为非负。全期 MAE 为 160.71，为光伏最优单模型。该方法借鉴 Wagner-Muns 等（2018, IEEE T-ITS）在交通流量 15 分钟粒度预测中的 FPCA 应用。

（5）LightGBM：同负载特征工程，额外强制夜间（hour ≤ 6 或 hour ≥ 20）预测置零。全期 MAE 为 192.14。

6.1.3 EGD 时变权重集成

在完成了两预测指标的模型池搭建后, 需要为池中的各子模型进行合理的加权。若仅通过简单平均或用全期误差定一组固定权重, 本题数据的季节性和及时响应的灵活需求很难被满足; 而若通过一些能力强大的 ML 方法, 如通过一个 LightGBM 根据全期误差进行全年度的赋权, 但由于在夏季空调负荷上的价值和在秋季平稳周期上的价值并不相同, 全期误差是这两段表现的平均, 平均之后无法对不同阶段的预测产生差异化策略, 平均的误差会同时拉低两季的预测表现。

故, 我们考虑动态地为二者进行赋权, 确保在所有场景均具备优秀的自适应性以机动调整预测倾向。这会使得权重逐日在线更新, 把当天的模型池内策略完全由近期数据驱动。

指数梯度下降的权重更新 记第 t 日模型 i 的权重为 $w_{t,i}$, 当日预测误差结算完毕后按指数梯度下降更新

$$w_{t+1,i} = \frac{w_{t,i} \exp(-\mu \tilde{\ell}_{t,i})}{\sum_j w_{t,j} \exp(-\mu \tilde{\ell}_{t,j})}, \quad (11)$$

其中 $\tilde{\ell}_{t,i}$ 为模型 i 的局部核加权损失, 学习率 $\mu = 0.005$ 。

上式的逻辑和效果直白, 即指数地压低当日误差大的成员, 使误差小的成员份额上升, 并将分母归一化以保证权重始终构成一个概率分布。其中, 学习率取得较小, 以保证让权重随时间的漂移速度不能过快, 避免某一日的偶然大误差把某个成员一脚踢出。

这一更新正是在线学习里 Hedge 算法的指数加权策略, OneNet 把它用作时序预测的在线集成框架 [18]。Mourtada 与 Gaïffas 证明了它的最优 regret 界 [15], 累积损失至多比事后最优的那个固定成员多出 $O(\sqrt{T \log N})$ 量级。所以, 无论季节怎么切换、权重怎么迁移, EGD 时变赋权下的总损失与日前已知当日数据的理想情形, 只存在一个随天数缓慢增长的小量差距。这对赋权的稳健性提供了极佳的稳健性支撑。

损失的局部核加权 单日误差的噪声偏大, 直接拿当日损失更新权重, 权重会跟着天气一起抖。我们改为在最近 30 天的窗口内对历史损失做指数衰减加权,

$$\tilde{\ell}_{t,i} = \frac{\sum_{s=t-29}^t 0.95^{t-s} \ell_{s,i}}{\sum_{s=t-29}^t 0.95^{t-s}}, \quad \ell_{s,i} = \text{MAE}(y_s, \hat{y}_{s,i}), \quad (12)$$

其中, 衰减系数取 0.95 会导致当天的权重约为 30 天前的四倍。这可以让模型池更倾向通过近期的场景特征来选择赋权策略, 同时也保留稍远时点, 如一两周前的影响。这一局部窗加权的思路取自时变模型平均 TVJMA [19], 它用每个时点附近的局部信息挑选合成权重, 而不是在全样本上定一套固定权重, 与我们逐日更新的诉求正好匹配。算出的日均损失还要除以当日各成员损失的最大值做一次归一化, 否则在光伏误差整体偏大的阴雨月份, 损失的量级本身就会主导权重更新, 把成员之间的相对好坏盖过去。

周期性的重初始化 持续更新有代价, 权重会陷在旧模式里出不来。若某个成员在夏季被压到很低的份额, 此后即便秋天的数据重新对它有利, 指数更新也只能把它一点点拉回来, 切得太慢。为此我们每隔 7 天, 与模型重训同步, 把当前权重朝初始权重拉

一把

$$w_t \leftarrow \alpha w_{\text{init}} + (1 - \alpha) w_t, \quad \alpha = \max(0.05, 0.5 \exp(-(N - 35)/60)), \quad (13)$$

其中 N 为已训练天数。冷启动阶段数据太少, $N < 35$ 时 α 偏大, 权重被拉回一个偏向简单方法的起点; 数据攒起来以后 α 衰减到 0.05 的下限, 只保留一点微弱的复位, 不再打扰已经学稳的权重。这一招同样出自 OneNet [18], 长程的在线漂移负责跟踪, 周期性的复位负责切换, 两者分工。

冷启动权重与滚动训练 评估期开头只有 31 天数据, 机器学习成员还没训透, 而简单平均在高不确定性下反而更稳 [16], 我们据此让初始权重偏向简单方法, 负载侧取季节朴素法 0.25、历史均值 0.20、STL 0.20、kNN 0.20、LightGBM 0.15, 光伏侧取 Persistence 0.30、kNN 0.20、STL 0.15、FPCA 0.15、LightGBM 0.20。训练本身采用扩展窗口, 历史数据只进不出; LightGBM 每 7 天重训一次, 与上面的权重复位同步; 144 个时点合并训练同一个模型, 靠时点序号特征区分时段, 而不是只训一个一步模型再递归推出全天。递归多步会把每一步的误差滚进下一步的输入, 推满一整天时误差已经放大若干倍, 直接策略省掉了这一环节, 它在长步长负荷与光伏预测中的优势也已被反复验证。

6.1.4 具分位数梯度的预测输出

点预测给出的是条件均值, 直接拿来购电并不合适, 原因是本问的代价结构不对称, 某时段少买 1 kWh, 缺口按 $5\lambda_t$ 紧急购电; 多买 1 kWh 只多付 λ_t , 且盈余还能充入储能回收一部分。多买 1 kWh 的保险成本是 λ_t , 换来的期望收益是 $5\lambda_t P(\text{缺口})$, 只要缺口概率超过 1/5, 这笔保险就划算。实测也印证了这一点, 模型池组的点预测直接喂给计划层时, 全年 48096 个时段中 25451 个出现缺口, 紧急购电费 413.7 万元, 占该组总费用的 25.2%。按均值购电, 系统性低估了缺口的代价。

为此在 EGD 集成点预测上叠加滚动经验分位数: 对每个时点取过去 30 天真实值减预测值的残差经验分位数做加性修正

$$\hat{y}_t^{(q)} = \hat{y}_t + Q_q(\{y_s - \hat{y}_s\}_{s=t-30}^{t-1}), \quad (14)$$

输出 P10、P50、P83.3、P90 四档, 负载与光伏各一条曲线; 光伏预测夜间强制置零, 各档裁剪为非负。该方法不需训练新模型, 思想与保形分位数组合 [17] 一致。档位的意义由报童模型给出 [10]: 取低估成本 $C_u = 5\lambda_t$ 、高估成本 $C_o = \lambda_t$, 临界分位为

$$q^* = \frac{C_u}{C_u + C_o} = \frac{5\lambda_t}{5\lambda_t + \lambda_t} = \frac{5}{6} \approx 0.833, \quad (15)$$

即 P83.3 档是理论上的最优的购电输入, 偏保守的系统性高估用来对冲 5 倍价的缺口。

6.2 模型评估

实验数据取自附件 2 全年 365 天、每天 144 个时点的记录，2025 年 1 月的 31 天作初始训练数据，2 月 1 日至 12 月 31 日共 334 天为评估期，滚动原点逐日预测；指标取 MAE、RMSE 与 MAPE，光伏另计仅统计 06:00–20:00 的白天 MAPE，排除夜间零值对百分比的失真。全部实验在 Python 3.10 下完成，STL 分解用 statsmodels 0.15.0，梯度提升树用 LightGBM，334 天滚动约 35 分钟，时点映射与附件格式严格对齐。检验围绕六个问题展开，依次回答集成是否优于单模型、深度模型为何落选、池的构成是否有据、权重能否跟随季节、机器学习成员是否过拟合、分位区间是否可信。

集成优于单模型，是在线集成这一设计成立的前提。表 4 与表 5 给出两层证据：对精简前的 6 模型树池基线 v4，本文方法把负载 MAE 由 169.37 降至 162.99、光伏由 185.21 降至 165.96，降幅分别为 3.8% 与 10.4%，光伏侧的收益主要来自 FPCA 对日曲线的低秩重构；对池内成员，负载集成 162.99 把最优单模型 LightGBM 的 172.71 再降 9.72，优于全部成员，光伏集成 165.96 虽高于最优单模型 FPCA 的 160.71，但优于其余全部成员。光伏白天 MAPE 由 7.83% 升至 8.85%，是 5 6 月阴雨月份误差结构变化所致，全期 MAE 仍明显占优。

表 4: 预测方法全期性能对比（2025.2.1–12.31，334 天，MAE 与 RMSE 单位 kW）

方法	负载 MAE	负载 RMSE	负载 MAPE	光伏 MAE	光伏 RMSE	白天 MAPE
v4 基线（6 模型树池 +EGD）	169.37	238.34	3.95%	185.21	365.23	7.83%
本文方法（5+5 异构池 +EGD）	162.99	225.84	3.80%	165.96	320.49	8.85%
相对变化	−3.8%	−5.2%	−0.15 百分点	−10.4%	−12.3%	+1.02 百分

表 5: 池内单模型与 EGD 集成的全期 MAE（kW）

负载模型	MAE	光伏模型	MAE
LightGBM	172.71	FPCA	160.71
SeasonalNaive	176.80	Persistence	185.35
STL	178.59	LightGBM	192.14
kNN	188.80	kNN	205.04
HistMean	188.88	STL	212.73
EGD 集成	162.99	EGD 集成	165.96

深度模型为何落选，误差层给出了直接理由。LSTM 在同一滚动设定下作为基线运行，负载 MAE 为 682.1，是本文方法的 4.2 倍，光伏 443.4，为 2.7 倍，在 6 7 月与 10 11 月的概念漂移期更飙至 700 1255。症结不在算力而在输入，纯序列缺少星期几、季节这类日历特征，固定训练窗口也跟不上季节模式的切换。特征工程加异构统计模型加在线权重的组合，在小数据与漂移并存的场景里反而稳健，这一对照也是 6.6 节把 LSTM 列为三组预测来源之一的依据。

池内五个成员是否都有存在理由，由消融实验回答：逐一移除成员并重跑 EGD 权重更新，结果见表 6。负载池的答案是 STL 与 LightGBM 不可或缺，移除后 MAE 分别上升 4.75 与 2.52；季节朴素法与历史均值移除后集成反而略优 0.13 与 0.35，但二者是

周周期的强基准与对照，保留的代价不足 0.4。光伏池中 FPCA 一家独大，移除后 MAE 上升 18.56，其余成员的贡献都不超过 1：光伏各模型间的误差相关性高达 0.984 0.998，天气噪声主导下所有模型在同样的日子犯错，其余成员的价值在于 FPCA 失效的极端天气日提供修正。负载池初始 7 模型剔除 FPCA 与谐波回归的精简决策，同样出自这组数据。

表 6: 预测模型池消融实验 (MAE 单位 kW, 变化为相对完整模型的差值)

负载消融方案	负载 MAE	变化	光伏消融方案	光伏 MAE	变化
完整 5 模型	162.82	基准	完整 5 模型	159.77	基准
去掉 STL	167.57	+4.75	去掉 FPCA	178.33	+18.56
去掉 LightGBM	165.34	+2.52	去掉 Persistence	160.55	+0.78
去掉 kNN	163.00	+0.18	去掉 STL	160.32	+0.55
去掉 SeasonalNaive	162.69	-0.13	去掉 kNN	159.71	-0.06
去掉 HistMean	162.47	-0.35	去掉 LightGBM	159.60	-0.17

权重能否跟随季节，月度误差先给出了漂移存在的证据。负载 MAE 在 6、7、9 月达 208.5、272.9 与 256.7，对应夏季空调高峰与季节转换期，4 月、11 月仅 97.4 与 106.6，对应模式稳定的春秋季节；光伏在 5 6 月阴雨期达 201.9 与 236.7，12 月天气稳定且功率本身低，最低至 82.6。面对这样的起伏，EGD 权重的轨迹显示模型确实在换挡，负载 LightGBM 权重夏季升至 0.80 0.83 抓住空调负荷的非线性，秋季自动回落、由权重 0.41 的 STL 与 0.38 的季节朴素法接管，光伏 FPCA 全年 0.89 0.99 稳定主导。整个切换由式 (11) 自动完成，无需人工干预，这正是选择在线权重而非固定权重的理由。

机器学习成员是否记住了训练噪声，用时序切分查验，前 70% 训练、后 30% 测试、不打乱，负载训练与测试 MAE 为 261.6 对 321.3，比值 1.23，光伏为 190.0 对 207.6，比值 1.09；不加正则的历史配置过拟合比达 4.83，强正则加 50 轮早停把它压低约 75%。其余成员为无参数或低参数的统计模型，不存在此风险。

最后一个问题落在分位数输出本身，区间若严重失准，后文的决策分位便无从谈起。P10-P90 区间对负载与光伏的覆盖率为 75.0% 与 74.3%，名义 80%；真实值超出 P83.3 的比例为 19.3% 与 19.1%，名义 16.7%。概念漂移期残差分布变化使区间略窄、实际分位比名义略激进，这一偏差在 6.6 节的结果中体现为残余缺口并未消失，是本问方法如实承担的代价。

6.3 分位数预测方法及其决策作用

6.3.1 为什么点预测不够

点预测给出的是条件均值：真实值高于预测与低于预测的可能性大致对半。但本问的代价结构不对称：某时段少买 1 kWh，缺口按 $5\lambda_t$ 紧急购电；多买 1 kWh 只多付 λ_t ，且盈余还能充入储能回收一部分。多买 1 kWh 的保险成本为 λ_t ，换来的期望收益是 $5\lambda_t P(\text{缺口})$ ，故只要缺口概率超过 1/5，这笔保险就划算。实测印证了这一点：模型池组点预测直喂时，全年 48096 个时段中 25451 个出现缺口，紧急购电费 413.7 万元，占该组总费用的 25.2%。按均值购电，系统性低估了缺口的代价。

6.3.2 分位数修正的构造与校准

预测层在 EGD 集成点预测上叠加 30 天滚动残差的经验分位数，输出 P10、P50、P83.3、P90 四档：第 τ 档等于点预测加上该时点过去 30 天残差（真实值减预测值）的 τ 分位数，负载与光伏各一条曲线。档位设置对应报童模型的临界分位 [10]：取高估成本 $C_o = \lambda_t$ 、低估成本 $C_u = 5\lambda_t$ ，得

$$q^* = \frac{C_u}{C_u + C_o} = \frac{5\lambda_t}{5\lambda_t + \lambda_t} = \frac{5}{6} \approx 0.833, \quad (16)$$

即 P83.3 档是理论上最优的购电输入。校准方面，P10–P90 区间对负载与光伏的覆盖率分别为 75.0% 与 74.3%（名义 80%），真实值超出 P83.3 的比例为 19.3% 与 19.1

6.3.3 决策分位的选定

分位数曲线到购电量还有一步：负载与光伏各取哪一档。我们按决策分位 τ 组合，负载取 P_τ 、光伏取 $P_{1-\tau}$ ，理由是两个序列的误差方向相反：负载低估、光伏高估都制造缺口，前者要上调、后者要下调，实测光伏白天高估率达 59.5%，是缺口的主要来源。 τ 的取值不由公式拍板，而由全年费用回测选定。这一做法分两步：修正形状由残差分位给出，档位由费用回测选定，与分位数回归平均方法 [6]、概率负荷预测综述 [7] 的思路一致，多模型分位数组合在光伏功率预测中也已有先例 [9]。

6.4 计划购电模型的建立与求解

计划层与问题 1 完全同构：决策变量、供电平衡、光伏平衡、储能动态、容量与功率约束、非负条件全部沿用式 (2) 至式 (6)，目标函数仍为最小化计划购电费。只有三处适配：其一，负载与光伏换成本问的输入 $\hat{L}_t$ 与 $\hat{P}_t$ ，即选定分位档的修正预测；其二，初始储电量 $E_0^{(d)}$ 改为滚动值，取前一日执行期末的真实储电量，首日取附录 1 给定的 6000 kWh，这使每天的计划从真实的储能状态出发；其三，日末储电量钉回当日初值 $E_{144}^{(d)} = E_0^{(d)}$ ，即日度中性约束，防止短视的 LP 把储能放空、把缺口推给次日。完整模型为

$$\begin{aligned} \min \quad & F^{(d)} = \sum_{t=1}^{144} \lambda_t (a_t + b_t) \Delta t \\ \text{s.t.} \quad & a_t + g_t + d_t = \hat{L}_t, \quad g_t + c_t + q_t = \hat{P}_t, \\ & E_t = E_{t-1} + 0.9(b_t + c_t) \Delta t - \frac{d_t}{0.9} \Delta t, \\ & 1200 \leq E_t \leq 10800, \quad b_t + c_t \leq 5000, \quad d_t \leq 5000, \\ & E_0^{(d)} = E_{144}^{(d)}, \quad a_t, b_t, g_t, c_t, d_t, q_t \geq 0, \\ & t = 1, \dots, 144. \end{aligned} \quad (17)$$

求解流程与问题 1 相同：SOC 消元后为 864 个决策变量、289 个等式约束与 576 个不等式约束，调用 HiGHS 求解器逐日滚动执行 334 天，能量守恒、无同段充放与储电量带宽三项校验全部沿用并通过。三点执行细则保证结算口径与题面一致：其一，购电

量按计划值 $(a_t + b_t)\Delta t$ 计费，与实际执行无关；其二，放电严格按照计划执行，仅当储电量触及 1200 kWh 底线时截断，全天储电量恒在 [1200, 10800] kWh 内；其三，充电由计划购电充电量与实现的光伏盈余构成，受功率与容量上限截断。

6.5 紧急购电的执行与结算

题面要求微网提供的电能不可低于小区负载，这条不可违约的可行性要求使紧急购电成为结算期的硬约束而非决策变量：计划在 0:00 全天锁死，日内除紧急购电兜底外不存在任何调整。记第 t 时段的实际供给为

$$S_t = a_t + g_t^r + d_t, \quad g_t^r = \min(g_t, P_t), \quad (18)$$

其中 P_t 为该时段光伏实际功率， g_t^r 表示实际光伏先满足计划直供，不足部分即是缺口的来源之一。缺口与紧急购电费为

$$e_t = \max(0, L_t - S_t), \quad \text{紧急费用} = 5\lambda_t e_t \Delta t, \quad (19)$$

连续缺口时段合并为同一区间记账。此外，实际光伏超出计划直供的部分并入充电，受功率与容量上限截断，装不下的部分弃掉。

6.6 结果与分析

表 7 给出三组预测来源在统一管线与结算口径下的全年对比，图 5 为对应的柱状对比。三组的计划层 LP 与结算规则完全相同，唯一的差别是预测曲线的来源，因此表中的费用差异全部来自预测质量的差异。

表 7: 三组预测来源的同口径全年对比（2025.2.1–12.31，费用单位：万元）

方案	紧急费	总费用	缺口/kWh
模型池组	413.7	1638.7	95.3
XGBoost 对照组	492.8	1709.5	112.0
LSTM 组	1632.9	2835.7	366.0

三组模型来源的对比结论明确：模型池集成是决策意义下最优的预测来源，总费用 1638.7 万元，比 XGBoost 对照组省 70.8 万元，比 LSTM 组省 1197 万元。这一排序与三组的预测误差排序一致（负载 MAE 依次为 162.99、175.41 与 682.08 kW），但幅度差异巨大：LSTM 的负载 MAE 约为集成的 4.2 倍，总费用却差 73%。LSTM 组的结构更值得展开：它的计划费 1202.8 万元是三组模型来源中最低，预测失准使 LP 系统性少买，缺口按 5 倍价收回 1632.9 万元，总费用反超最优组 1197 万元。计划买得少不等于省钱，评价预测必须回到费用口径，这是本节把预测比较放到结算层做的直接依据。

图 6 的月度紧急费用对比补充了组间差异的季节结构：三组的紧急费都在夏季抬升，6 月同时达到峰值，对应全年最强的预测误差期。LSTM 组即便在误差较小的 8 月，紧急费也高于模型池组，说明其缺口的多少并不依赖季节。模型池组对 XGBoost 对照




图 5: 三组预测来源的同管线全年总费用对比

组的优势集中在 2 月与 10 月，紧急费分别低 27.6 万与 13.6 万元，其余月份两组接近，11 月与 12 月 XGBoost 对照组反超。




图 6: 三组预测来源的月度紧急购电费用对比

6.7 模型评价

本问方法的优点有三：计划层与问题 1 完全同构，模型与程序直接复用；紧急购电按题面以硬约束结算，费用口径与真实计费一致；

6.8 模型评价

本问方法的优点有三。计划层与问题 1 完全同构，模型与程序直接复用；紧急购电按题面以硬约束结算，费用口径与真实计费一致；三组预测来源在同一结算层上横向比较，选择依据是费用而非预测误差。缺点同样具体。三组预测直喂时紧急购电费仍达 413.7 万元，占模型池组总费用的 25.2%，缺口时段占 52.9%，6.3 节的分位数修正尚未纳入本节对比。分位覆盖率 75.0% 略低于名义 80%，保守修正后缺口仍会有残余。固定的分位档跨季节不自适应，夏季与冬季需要的保守度并不相同。这三点的改进方向一致，加密分位档并按季节或预测置信度自适应，问题 3 的日内滚动预报是自然的延伸。

7 问题 3 模型的建立与求解

8 问题 4 模型的建立与求解

9 模型评价与总结

参考文献

- [1] 王先齐, 吕智林, 汤泽琦. 基于分时电价机制的并网型微网多目标动态优化调度 [J]. 电力系统保护与控制, 2017, 45(4). DOI: 10.7667/PSPC160250.
- [2] 袁龙. 分布式光伏发电与储能协同调度模型研究 [D]. 济南: 山东大学, 2018.
- [3] Sioshansi R, Denholm P, Jenkin T, et al. Estimating the value of electricity storage in PJM: Arbitrage and some welfare effects[J]. Energy Economics, 2009, 31(2): 269-277.
- [4] 王凌云, 王晓敏, 胡兴媛, 等. 基于多智能体微网的需求侧分时电价优化调度 [J]. 信息与控制, 2020, 49(4): 429-435.
- [5] Boyd S, Vandenberghe L. Convex Optimization[M]. Cambridge: Cambridge University Press, 2004.
- [6] Liu B, Nowotarski J, Hong T, et al. Probabilistic load forecasting via quantile regression averaging on sister forecasts[J]. IEEE Transactions on Smart Grid, 2020, 11(1): 178-186.
- [7] Hong T, Fan S. Probabilistic electric load forecasting: A tutorial review[J]. Structural Safety, 2016, 62: 9-23.
- [8] 车泉辉, 陈建洪. 光伏功率短期预测方法研究综述 [J]. 电力自动化设备, 2022, 42(10): 12-21.
- [9] 李远成, 王守相, 郑超, 等. 基于多模型组合的光伏功率概率预测 [J]. 电力系统自动化, 2021, 45(8): 119-124.
- [10] Arrow K J, Harris T E, Marschak J. Optimal inventory policy[J]. Econometrica, 1951, 19(3): 250-272.
- [11] Cleveland R B, Cleveland W S, McRae J E, et al. STL: A seasonal-trend decomposition procedure based on Loess[J]. Journal of Official Statistics, 1990, 6(1): 3-73.
- [12] Lu J, Liu A, Dong F, et al. Learning under concept drift: A review[J]. IEEE Transactions on Knowledge and Data Engineering, 2019, 31(12): 2346-2363.

- [13] Wagner-Muns I M, Guardiola I G, Samaranayake V A, et al. A functional data analysis approach to traffic volume forecasting[J]. IEEE Transactions on Intelligent Transportation Systems, 2018, 19(3): 878-888.
- [14] Akyurek B O, Akyurek A S, Kleissl J, et al. TESLA: Taylor expanded solar analog forecasting[C]. 2014.
- [15] Mourtada J, Gaïffas S. On the optimality of the Hedge algorithm in the stochastic regime[J]. Journal of Machine Learning Research, 2019, 20(83): 1-46.
- [16] Graefe A, Küchenhoff H, Stierle V, et al. Combining forecasts: Evidence on the relative accuracy of the simple average and Bayesian model averaging[J]. Statistical Modelling, 2015.
- [17] Wang Y, Zhang N, Tan Y, et al. Combining probabilistic load forecasts[J]. IEEE Transactions on Smart Grid, 2019, 10(4): 4477-4489.
- [18] Zhang Y F, Wen Q, Wang X, et al. OneNet: Enhancing time series forecasting models under concept drift by online ensembling[C]//Advances in Neural Information Processing Systems (NeurIPS). 2023.
- [19] Sun Y, Hong Y, Lee T H, et al. Time-varying model averaging[J]. Journal of Econometrics, 2021, 222(2): 974-992.

AI 工具使用声明

（占位）本项按竞赛当期规范填写。