

基于线性规划与对偶分析的微网计划购电策略

摘 要

(占位)摘要待问题 2–4 完成后统一撰写。本问已备妥的数值结论: 全天购电 59482.7 kWh、购电费 35126.85 元, 较无储能运行节省 26.9%; 充放电启停受阈值 $1/0.81 \approx 1.235$ 支配; 规则式策略较线性规划最优贵 11.71%。

关键词: 微网; 分时电价; 储能调度; 线性规划; 对偶分析

1 问题重述

1.1 问题背景

微网是一种小型发用电系统, 其快速发展缘于可帮助光伏发电等分布式能源的本地消纳, 以及一定程度上减轻大规模并网压力。

而本题的微网与外部电网并联运行, 在外网购电的基础上调和储能储电、光伏出力与小区负载。由于外网电价通常按分时电价进行结算, 在一天之内存在峰谷。微网要在这种情况下决定每个时段向外网购入多少电、储能何时充电何时放电, 使自身提供的电能既能满足小区负载, 又尽可能节省购电费用。

低价时段存电、高价时段放电是它压降购电费的主要手段, 但同时带来的必要储能也存在能量损耗。在规划过程中还需要平衡光伏和负载在时间上的一些错位。

1.2 问题要求

本文需基于电价、光伏发电和负载数据, 在他们分别表现为固定和时变的各搭配中, 依次为四问建立并求解微网的购电及充放电策略。本题四个问均要求在每天 0:00 制定当天的策略, 在不同的小问中计划时能获取的当天信息不同。第一问可获得所有数据, 第二问开始负载和光伏只能看到日前数据, 第四问中电价也出现了波动。且第三问提出了多次预报下的初步计划与调整的问题, 并被第四问继承。

题目要求在各概况建模并对指定时间进行求解, 存入指定位置。

2 问题分析

2.1 第一小问分析

第一问给出了当天电价、负载与光伏发电功率的完整曲线, 并要求微网供电不低于负载、储能设备在 0:00 与 24:00 的储电量相同。也就是说, 制定计划时全天信息都是已知的, 本问不含任何不确定性, 要做的是把一天的电量在时间上重新分配。

观察附件数据可以判断, 电价在深夜与午间各有一处低谷, 早间与傍晚各有高峰, 峰谷价差提供了套利空间, 而 90% 的充放电效率又在每一次能量搬运上打了折扣。储能由此成为本问唯一的跨时段耦合环节, 各时刻的购电决策通过它相互牵连, 很难逐时段孤立决定; 0:00 与 24:00 储电量相同的要求则把计划闭合成一个周期, 防止模型把存量留到周期之外。

从形式上看，供电平衡、光伏的分流去向、储电量演化与界限、充放电功率上限都可以写成决策量的线性关系，购电费也是电价与购电量的线性组合，因此我们拟把本问建为线性规划模型。考虑到该模型的最优解本身还带有对偶信息，我们拟进一步做对偶分析，把容量界限与终端条件的影子价格解读为储能在各时点的边际价值，借此说明充放电时机以及跨时段搬运能量所需的价差门槛。这样处理还有一个便利，同时充放电的行为能够被对偶条件直接排除，不必为此引入整数变量。效率与功率上限在实际运行中常有偏差，我们拟再对二者做灵敏度分析，检验上述结构的稳定性。

2.2 第二小问分析

第二问保持电价不变，让负载与光伏发电功率随时间变化，且二者的当日真值在 0:00 制定计划时并不可知；一旦供电低于负载，缺口须按交易时刻电价的 5 倍向外网紧急购电。本问由此从完全信息下的确定性优化，转成先预测、再计划的决策过程。

两个预测目标的性质并不相同。负载带有强烈的周周期，工作日与周末之间、不同季节之间存在明显的水平漂移；光伏则受天文与天气共同支配，日内起落规律稳定，主要噪声来自云量。这样的差异说明用一套结构同时拟合两条曲线并不合适，单一模型也很难在全年各个季节都保持精度。我们拟据此构造由不同机制成员组成的模型池，再以逐日更新的时变权重把它们组合起来，使预测在季节切换时仍能跟上数据的变化。

进入计划层后，购电代价的两侧并不对称。少购一度要多付四倍于原价的紧急费用，多购一度却只按原价结算，余量还能存入储能供之后使用，因此计划量应当适度偏多。我们拟在预测输入进入优化之前做偏向保守的分位修正，修正幅度交由全年结算费用确定。计划层本身沿用第一问的供电平衡、光伏分流与储能动态，只把负载与光伏换成预测值，并解除每日 0:00 与 24:00 储电量相同的约束。

解除这条约束会引出一个新问题。单日模型在午夜前放空储能便能压低当日费用，而半夜恰是低电价时段，这样的策略显然违背微网运行的常识。跨日耦合又不能简单地吧模型跨度拉长到全年，因此需要设法让模型自己意识到日末存量仍有价值。至于预测层是否合格，我们认为应当把它放进同一套结算规则里，与另外两种预测来源比较全年费用，而不只看预测误差本身。

2.3 第三小问分析

2.4 第四小问分析

3 模型假设

1. 储能设备按照充、放电效率各取 90%，往返效率 81% 的思路理解。
2. 功率上限按照 5000 kW 指储能设备并网侧而非电池侧理解。即考虑为其充、放电功率在发生电能损失之前的最大功率。
3. 购电量与放电量均非负，不向外网反送电；光伏盈余只能充电或弃掉，弃光不计费用，以与题面“购电量”的记账方向一致。

4 符号说明

符号	说明
Δt	单时段长度, 10 min
λ_t	时段 t 的外网电价, 元/kWh
L_t	时段 t 的小区负载, kW
P_t^{pv}	时段 t 的光伏发电预测功率, kW
a_t, b_t	时段 t 购电功率中直供部分 / 充电部分, kW
g_t, c_t	时段 t 光伏功率中直供部分 / 充电部分, kW
q_t	时段 t 光伏弃光功率, kW
d_t	时段 t 储能放电功率, kW
E_t	时段 t 末储电量, kWh
S_t	时段 t 末的净充电累计量, $E_t = 6000 + S_t$, kWh
η	充放电效率, 取 0.9
$E_0, E_{\min}, E_{\max}$	储电量初值与界限: 6000、1200、10800 kWh
$P_{\max}$	并网侧充放电功率上限, 5000 kW
γ_t, σ_t	节点边际价值 / 边际供电成本, 元/kWh
$\hat{L}_t, \hat{P}_t$	问题 2 中时段 t 经选定分位档修正的负载 / 光伏预测, kW
P_t	问题 2 结算用的光伏实际功率, kW
g_t^r	问题 2 结算期实际光伏直供功率, $\min(g_t, P_t)$, kW
R_t	问题 2 时段 t 实际总供给, $a_t + g_t^r + d_t$, kW
e_t	问题 2 时段 t 供电缺口, kW
C_t^e	问题 2 时段 t 紧急购电费, 元
$E_0^{(d)}$	第 d 日 0:00 储电量, 滚动取前一日执行期末值, kWh
$F^{(d)}$	第 d 日计划购电费, 元
$w_{t,i}$	第 t 日模型 i 的 EGD 集成权重
$\tilde{\ell}_{t,i}$	模型 i 第 t 日的局部核加权损失
μ	EGD 权重更新学习率, 取 0.005
α	权重重初始化的混合系数
τ	决策分位, 负载取 P_τ 、光伏取 $P_{1-\tau}$
C_u, C_o	购电低估 / 高估的单位成本, $5\lambda_t / \lambda_t$

5 问题 1 模型的建立与求解

对于电价、负载和光伏发电量等所有数据已知的第一问，我们分析题目和数据信息，建立了简单的 LP 模型并求解严格最优解。在完成了最优解的结果分析后，我们还通过对偶分析和最优性证明，以及本场景恰当的灵敏度分析保证了模型的合理和稳健。具体流程如下图所示：




图 1: 问题 1 的建模与求解流程

5.1 LP 模型建立

首先可对附件 1 中的数据做简要预分析。

本题把每日划成 144 个时段 $I_k = [10(k-1), 10k) \text{ min}$, $k = 1, \dots, 144$ 。 I_1 取附件的第 144 行，该行标记的是次日 0:00 起的 10 分钟，由假设 1 的周期性，其数值与当日 0:00 至 0:10 相同； I_2 至 I_{144} 依次取当天的第 1 至第 143 行。可以简要分析出，电价在深夜与午间各有一个低谷，早 8 时前后与 19 时至 22 时各有一个高峰，双谷双峰的形态给储能低充高放留出了空间。

在本问的微网为小区负载的场景下，构建每个时刻的电能流是理解各购电、充放电和供电的关键所在：

外网购电 作为最基本的电能来源，可以规划从外界直接购入的购电量，并在较长的时间窗口满足外界总购电量略多于总负载的用电量，稍多的部分会在储能设备转化时损耗。外网购电可能根据存贮计划分流，一部分可转向储电设备并以 90% 的效率存储 b_t ，另一部分考虑可以直接转向小区负载供电 a_t 以减少损耗率；

光伏发电 类似的，小区内光伏发电的功率同样进行拆分，拆成直供负载的 g_t 与储能充电 c_t 两路，后者同样存在 90% 效率的能量转换。而由于光伏发电为被动来源，在储能设备几乎存满且负载低的极端情况下，可能出现废弃的光能功率，光伏与储能的协同调度正是处理这类消纳问题的常见框架 [2]。

储能供电 储能设备可以将通过外购和光伏存入的能量再以 90% 的效率输出，为小区负载供电。我们记放电总功率为 d_t 。同时，每个时刻的储电量 E_t 由充放电累计得到 全天购电费为各段电价乘以购电量之和，针对购电成本的目标函数为

$$\min F = \sum_{t=1}^{144} \lambda_t (a_t + b_t) \Delta t. \quad (1)$$

本场景中涉及的基本约束包括：

供电平衡 考虑到微网供给不得低于负载，又由于多供无益。在所有时刻维持总供电刚好满足需求负载，取等式

$$a_t + g_t + d_t = L_t. \quad (2)$$

光伏电量平衡 根据电能流的梳理，光伏发电分流到直供负载、储电以及极端情况的废弃量，即

$$g_t + c_t + q_t = P_t^{\text{pv}}. \quad (3)$$

储能动态 对于储能设备而言，每一个时刻的储电量变化需考虑所有充放电路径。由于其充放电效率为 90%，迭代时注意存在损耗，即

$$E_t = E_{t-1} + 0.9(b_t + c_t)\Delta t - \frac{d_t}{0.9}\Delta t, \quad (4)$$

储电量约束 为保护设备在长期运转的健康水平，每个时刻的储电量需要避免过高或过低

$$1200 \leq E_t \leq 10800 \quad (5)$$

同时，充放电在单位时间的功率也存在界限，采用行业常用的并网侧约束，即损耗之前进行约束 $b_t + c_t \leq 5000$ 、 $d_t \leq 5000$ kW。

周期边界条件 场景已经给定 2025 年 1 月 1 日 0:00 的储电量为 6000 kWh，且要求每天储能设备在 0:00 与 24:00 的储电量相同，故每晚午夜储电量均为 6000 kWh，计划逐日执行时第 k 天 0:00 的节点 E_{144k} 都取该值；罐内储电量本身仍随充放电在界限内波动，该要求在单日模型中表现为首末两端

$$E_0 = E_{144} = 6000 \text{ kWh}. \quad (6)$$

其中，变量非负隐含 $d_t \leq L_t$ ，放电不会超过负载，不发生向外的反送。

合并式 (1) 至式 (6)，问题一的完整 LP 为：

$$\begin{aligned} \min \quad & F = \sum_{t=1}^{144} \lambda_t (a_t + b_t) \Delta t \\ \text{s.t.} \quad & a_t + g_t + d_t = L_t, \quad g_t + c_t + q_t = P_t^{\text{pv}}, \\ & E_t = E_{t-1} + 0.9(b_t + c_t)\Delta t - \frac{d_t}{0.9}\Delta t, \\ & 1200 \leq E_t \leq 10800, \quad b_t + c_t \leq 5000, \quad d_t \leq 5000, \\ & E_0 = E_{144} = 6000, \quad a_t, b_t, g_t, c_t, d_t, q_t \geq 0, \\ & t = 1, \dots, 144. \end{aligned} \quad (7)$$

5.2 LP 模型求解

式 (4) 中的储电量 E_t 并非独立的决策量, 任一时刻的储电量都由之前的充放电决策唯一确定, 求解时把它消去, 改记业内常见的净充电累计量 SOC

$$S_t = \sum_{s \leq t} \left[0.9 (b_s + c_s) - d_s / 0.9 \right] \Delta t, \quad (8)$$

以 $E_t = 6000 + S_t$ 代入, 容量界限与终端条件都化为对 S_t 的直接约束。这一消元可提前省去 144 个状态变量及其对应的 144 条递推等式。虽然 S_t 的界限行带前缀求和, 非零元随时段增多, 约束矩阵变得更稠密, 但这在 144 段的规模下不构成负担。

最终交给求解器的是 864 个决策量、289 个等式约束与 576 个不等式约束。在实际求解中, 容量界限行与终端归零行的对偶变量合成了各时点的节点边际价值, 5.4 节的 γ 递推将直接构造自这组输出。求解调用 `scipy.optimize.linprog` 接口的 HiGHS 求解器, 容差沿用默认设置, 单次求解约 0.25 s。

求解器在返回最优解的同时给出全部对偶变量, 5.4 节的影子价格直接取自这一输出; 求解前后还通过了以下三类自检:

全天能量守恒 购电量加光伏发电量应等于负载、弃光、充电损耗与放电损耗之和, 两侧相差 1.5×10^{-11} kWh, 即恒等式累积误差完全为运算精度误差;

购电策略合理 最优的购电策略应该是利用本题数据的双谷双峰形态, 在低电价时购入并存储并在高电价时取用, 这导致解的外网购电存在分块特征。具体分析见 5.3 节的表 2 与图 2;

无同时充放电记录 同时充放电这一理论上绝非最优的策略在解中并未出现。从实际情况考虑, 对储能设备同时充放电更易由于总功率较高而造成损伤; 同时从优化模型上考虑, 发生同时充放电时将其相互抵消, 即可省下存储 90% 所带来的能量损失, 这在理论上可降低成本, 严格的论证见 5.4 节。

5.3 模型结果分析

全天购电 59482.7 kWh、购电费 35126.85 元; 无储能运行时按逐段缺口 $\max(0, L_t - P_t^{\text{PV}}) \Delta t$ 购电需 48052.05 元, 储能低充高放节省 12925.20 元、降幅 26.9%, 数据见表 1。六个指定时段里, 10:00-10:10、14:00-14:10 与 20:00-20:10 的购电量均为 0, 这些时刻光伏加储能足以覆盖负载。

计划购电量按模板逐行填写, 第 2 至第 144 行依次对应 I_2 至 I_{144} , 末行填 I_1 的数值, 即次日首段的计划。

表 1: 微网指定时间段微网购电量及全天购电情况

时间段	购电量/kWh	时间段	购电量/kWh
10:00-10:10	0.00	16:00-16:10	394.93
12:00-12:10	486.40	18:00-18:10	636.98
14:00-14:10	0.00	20:00-20:10	0.00
全天购电量	59482.7	全天购电费/元	35126.85

表 2 按四小时块汇总，汇总块来自 I_{24k+1} 至 I_{24k+24} 逐段统计。

表中可见，充电集中在 0:00-4:00、12:00-16:00 与 20:00-24:00 三个块，放电主力在 4:00-8:00 与 16:00-20:00；这一特征结果高度符合数据分析中描述的峰谷特征，该策略为 LP 的核心特征。

表 2: 储能设备在指定时间段的充放电量及 0:00 和 24:00 的储电量

时间段	充电量/kWh	放电量/kWh
0:00-4:00	4500.00	0.00
4:00-8:00	833.33	5947.42
8:00-12:00	3954.63	2121.42
12:00-16:00	6119.37	91.10
16:00-20:00	0.00	5068.69
20:00-24:00	5333.33	3571.31
0:00 与 24:00 储电量	6000	

下图给出了储能设备的储电量变动情况与各时段功率。日循环呈两充两放结构，0:00-1:00 以 5000 kW 顶格充电 4500 kWh，5:40-5:50 抓住全日最低价 0.3713 元/kWh 补充 833.3 kWh，储电量触及上限 10800 kWh；早峰 6:00-9:40 放电 8068.8 kWh，恰好覆盖全部负载，这三个多小时内购电为零；午间由光伏盈余充电并在低价段补购；晚峰 18:50-20:50 放电 8530.7 kWh，电价最高的 1.3952 元/kWh 时段购电为零；22 时起分批回充，24:00 回到 6000 kWh 闭环。特别的，外购充电全部落在 0.371 至 0.479 元/kWh 的时段里，放电时段的电价最低也有 0.690 元/kWh；另外，全天弃光为零，光伏发电量被负载与储能完全使用。




图 2: 解的储能状态与各时段购电、充电及放电功率

5.4 对偶分析及最优性证明

LP 的对偶变量给出比数值解更深一层的解释。我们给各类约束挂上影子价格，据此定义节点边际价值 γ_t ：在时段 t 末白得 1 kWh 储能，全天购电费能省下多少。 γ 沿时间轴满足递推

$$\gamma_t = \gamma_{t+1} - \eta_t + \theta_t, \quad (9)$$

其中 η_t 、 θ_t 是储电量上、下限约束的对偶变量。内点节点上 γ 逐段不变，能量躺在罐里不生息；满罐节点 γ 下移 η_t ，空罐节点 γ 上移 θ_t 。由 KKT 互补松弛条件可得充放电的三条启停判据，对偶理论见文献 [5]。充电段满足 $\lambda_t = 0.9\gamma_t$ ，功率顶格段另加正的影子溢价；放电段满足 $\sigma_t = \gamma_t/0.9$ ， σ_t 为该段边际供电成本；空闲段的价格落在 $0.9\gamma_t$ 与 $\gamma_t/0.9$ 之间的迟滞带内。把充、放电段的等式联立，可得跨窗口搬运能量的门槛，放电价与充电价之比须不低于

$$\frac{1}{0.81} \approx 1.235. \quad (10)$$

说白了，价差比不到 1.235 的两段之间，LP 一千瓦时也不会搬。同一段内边充边放的情形可以先用损耗的账排除。取充分小的 δ ，若某段同时有 $b_t > 0$ 与 $d_t > 0$ ，把充电减 δ 、放电减 0.81δ 、直购增 0.81δ ，储电量轨迹逐点不变，购电费净省 $0.19\lambda_t\delta\Delta t$ ，只要电价为正，原解就还不是最优。对偶条件给出同一结论，边充边放要求 $\lambda_t = 0.9\gamma_t$ 与 $\lambda_t = \gamma_t/0.9$ 同时成立，推出 $\gamma_t = 0$ 且 $\lambda_t = 0$ ，与恒正的电价矛盾。故最优解中不存在同段充放，无需为排除该行为引入 0-1 变量，这与文献 [1] 用状态变量处理储能充放互斥的做法形成对照。

图 3 画出 γ 与 λ 的全天对比，底色可区分出充放电窗口，有以下两处结构值得讨论。

首先是，两个放电大窗口 6:00-9:40 与 18:50-20:50 内 σ 分别为 0.591 与 1.256 元/kWh，都低于当时的电价，储能把两个价格峰完全削平，窗口内购电为零。

其次是，15:10-18:30 储电量顶在 10800 kWh 的平台期， γ 从 0.733 爬升至 1.130 元/kWh，每经过一个满罐节点上移一点，罐容稀缺的影子价随放电极近在累积。最优性方面，互补松弛条件在全时段的违约不超过 1.4×10^{-17} 元/kWh，节点价值的有限差分重解与对偶值偏差为 1.2×10^{-12} ，两条独立途径相互印证。




图 3: 储能节点边际价值 γ 与电价 λ 的全天对比

5.5 模型灵敏度分析

除了对本 LP 结果的理论分析，还可以从灵敏度进行评价。

本问选择了 $\eta, P_{\max}$ 这两个行业内通常不固定的指标，尝试进行灵敏度分析。虽然本题给定了具体数值，但我们认为如果在给定值的邻域波动参数也能通过灵敏度检验，则可以较好的说明模型稳健性；其次，我们选择了问题在业界的常见方案做结果的对比，以体现模型的优越性。

充放电效率 η ，本题在储能设备参数处给定 $\eta = 90\%$ ，但是在实际生产中同一批储能设备的参数都可能存在误差，且在使用、老化的过程中，电机的效率损失几乎是必然的；此外，该参数在模型的求解过程中及其重要。由于 η 决定套利阈值 $1/\eta^2$ ，效率越低，值得搬运能量的价差组合越少，解的结构就会随之改变。

所以本文围绕 90%，扫描取 0.85 至 0.95 共五档，每档重新求解完整的规划，结果见表 3。成本随 η 单调下降，每提高 0.01 仅约降 0.8%，并未出现较大敏感波动。

失效边界在 $\eta \approx 0.841$ 。早峰 6:00-9:40 需要储能送出 8068.8 kWh，满电自 10800 kWh 放至下限 1200 kWh 最多送出 9600η kWh， η 低于 $8068.8/9600 \approx 0.841$ 后单个日循环放不满早峰缺口，必须在午间以更高的电价二次回充，成本曲线在此转陡。

表 3: 充放电效率 η 的敏感性扫描

η	阈值 $1/\eta^2$	购电费/元	较 $\eta = 0.90$
0.85	1.384	36603.21	+4.20%
0.88	1.291	35696.82	+1.62%
0.90	1.235	35126.85	题面取值
0.92	1.182	34575.53	-1.57%
0.95	1.108	33767.02	-3.87%

功率上限 $P_{\max}$ 分析可得，解中有 19 个时段的充电功率顶在 5000 kW，该约束频繁激活，值得单独查验。把 $P_{\max}$ 放宽到 6000 kW 重解，成本仅降 0.12%。其看可能的原因是低价时段的总电量足以把储能设备充满，上限改变的只是充电在时段之间的分布，而不是充入的总量；放电峰值功率 4294 kW 从未触顶，两个方向中只有充电侧受到约束。而假设 3 中我们对于 $P_{\max}$ 的并网侧理解与“电池侧”，认为时电池实际存入或输出的功率可达 $P_{\max}$ ，对结果的影响同样被限制在这一量级。

6 问题 2 模型的建立与求解

问题 2 继承了问题 1 构建的 LP 模型，但是有三个条件改动。

日前预测必要性 负载与光伏逐日变化，考虑当日真实值在制定计划时不可知，这里便衍生出了基于日前信息进行时间序列预测的需求。同时，考虑到负载和光伏发电数据的波动特征等可能存在差异，在建模时需要通过不同的方法学习不同特征。

紧急购电 由于计划依据的数据来源于预测，执行过程中因误差导致的若供电不足，须按交易时刻电价的 5 倍向外网紧急购电。

取消日起储能限制 当第二问不再要求每天 24:00 匹配 00:00 的 6000kWh 电量，跨度为每日的 LP 模型一定會在午夜之前将储能电量全部放完以最小化当日成本，但这在

长期看来是绝对不可取的。午夜之前的低价时段不外购充电，反而放电，该策略是完全不符微网场景逻辑的。但由于每天的预测和计划独立，不能直接将 LP 的时间跨度提到一年。故，文本将储电量根据当前电价，作为减项折算到成本中。这可以从 LP 根本上杜绝其自发在午夜前放电的行为。

据此，本问的求解框架分为日前预测部分及 LP 求解部分，具体流程如下图。




图 4: 问题 2 的建模与求解流程

6.1 日前预测模型的建立

预测层需在每日 0:00 时刻，利用截止前一日的全部历史数据，对当日 144 个 10 分钟间隔时点的小区负载功率与光伏发电实际功率进行日前预测。同一天预测值不考虑带回增量训练以避免误差累积。

考虑到从 31 天数据的冷启动到后期数百天的数据跨度，以及季节性的峰值等特征可能漂移，我们认为预测层实际的关键在于在不同数据量情况、两种不同预测目标特征、季节性趋势明显、特殊的噪声和信号识别上的高自适应能力，该模型同时还需要兼顾短时天气变化的快速响应。可见，这种多环境的自适应需求很难由单 ML 模型满足，故我们拟采用多模型互补的思路，通过高度灵活的方法调整模型权重，尝试达到在不同场景的高预测性能。

6.1.1 两目标时序特性分析

在多模型的组合构建前，需要分别分析小区负载和光伏发电量的时序特性，方便后续进行更加具备科学性的模型选择。纳入不足或者偏向明显的组合，可能导致模型池不擅长一些情境的信息捕捉；而纳入过多各类模型，会使得求解效率低下，而同类模型特性互相叠加影响，类似共线性的效应严重影响求解效率。

小区负载 对其日总量的自相关分析显示，滞后 7 阶自相关系数达 0.988，滞后 1 阶仅 0.374、滞后 2 阶为负，表明周周期为首要周期成分。此外观察到周内模式呈现显著分化，周一至周四及周日日均负荷约 5165 kW，但周五、周六骤降 36.8% 至 3265 kW，反映了工作日与周末的居民用电行为差异，符合生活常识。而在日级别方差分解中，周季节成分占 89.3%，趋势占 14.1%，残差仅 4.4%，进一步验证了周周期的主导地位。日内峰谷比在 [1.80, 2.11] 中，峰值时点存在季节漂移，由 1 月 09:00 对应早高峰的峰值，7 月漂移至 17:30 对应晚高峰，月度均值极值比为 1.23。

光伏发电 类似的, 日总量滞后 1 阶自相关系数为 0.964、滞后 2 阶仍有 0.957, 而滞后 7 阶为 0.878, 表明日连续性远强于周周期, 不同于负载特征。同时, 工作日与周末的表现无显著差异, 符合自然特征。月度均值极值比达 1.93, 这由气候缘故决定。且光伏发电的物理约束明确, 即夜间功率恒为 0、峰值恒在 12:00 前后, 日出日落时点由天文规律确定。故, 天气是主要噪声来源, 且日间变异系数在区间 $[0.06, 0.11]$ 。

上述特性直接驱动了模型选型策略。负载需重点建模周周期与季节漂移, 光伏需重点建模日连续与年周期, 并利用物理约束强制夜间置零。考虑到两个序列的显著时序特性差异, 采用独立模型组合而非统一模型池。

6.1.2 异构模型池构建

单一模型的归纳偏置固定, 全年周期不同阶段的表现此起彼伏, 本文据此构建机制差异化的异构模型池。选型遵循三条原则, 成员之间机制互补, 周周期、趋势、曲线形态、相似日与非线性交互各有人管; 误差高度相关的冗余成员剔除在外; 全部成员在滚动设定下运行, 只使用预测日之前的观测。

模型池的构建经过实证精简。负载池初始纳入 7 个模型, 全量消融实验 (见 6.1.4 节) 显示函数型主成分分析 (FPCA) 与谐波回归 (HarmonicReg) 的边际贡献为负, 两者全期 MAE 分别为 258.32 与 353.82, 移除后集成 MAE 反而降 0.2 0.4, 夏季 6 7 月改善 1 3%。负载池因此定为 5 个成员, 光伏池保留 5 个。

负载模型池

(1) 季节朴素法 (SeasonalNaive) 取上周同一时点的实际值。它不设参数, 取同一时相令周周期成分在误差中抵消, 只留下天气突变等非时令因素带来的非周期起伏。附件中上周同日与今日的归一化曲线距离只有 0.218, 前一日为 0.309; 周五、周六日均比工作日低 36.8%, 春节、国庆、端午比同月普通工作日再低 9.4%、9.8%、11.0%, 池中的周周期基准因此由它来立。

(2) 月度均值预测 (HistMean) 取近 4 周同一时点的平均。多周观测平均到一处, 随机的单日起伏被抹平。附件中负载日总量的变异系数为 19.6%, 极值日 7 月 3 日与 4 月 18 日的日总量相差 1.98 倍, 这些跳变多来自用电随机性与测量误差, 多周平均正是抑制这类扰动的直接手段, 本文据此把它留作池中的平滑基准。

(3) STL 分量预测以 7 天为周期把历史序列分解为趋势、季节与残差三部分, 趋势分量以阻尼系数 0.8 外推, 季节取上一周同相位值, 残差置零。它专门处理月度均值接不住的水平迁移, 趋势项阻尼外推既能跟进漂移, 又不受单日异常拖累。附件中日均峰值时点 1 5 月、9 12 月停在 09:00 09:50 的早高峰, 6 8 月整体移到 16:40 17:40, 7 月与 11 月的曲线相差 23.0%, 清明日均又低于同月普通工作日 25.9%, 水平迁移与异常值同时出现的序列正适合交由分解处理 [8], 两池的趋势成分都落在它身上。

(4) kNN 相似日以昨日完整曲线为基准, 在近 60 天历史中取归一化欧氏距离最近的 3 个同星期几的日子, 按距离倒数加权搬用它们的次日曲线 [11]。此方法可以降低次日曲线单步 MAE, 负载侧的相似日匹配交给它。

(5) LightGBM 是池中唯一的非线性成员, 用 18 维日历与滞后特征训练梯度提升

树，取强正则，即 600 棵树、学习率 0.03、叶数 15、最小叶样本 30、子采样与列采样 0.7、L1 与 L2 惩罚 1.0 与 5.0、早停 50 轮，防止小样本过拟合。树结构可以表达特征之间的交互，空调季、周末、午间三者组合出的模式是周期模型写不出的。附件中周内降幅本身随时段变化，白天 41.8%、夜间 26.6%，日历特征与滞后特征的交互有数据可依，负载侧的非线性成分可以由其处理。

光伏模型池

(1) Persistence 取昨日同刻值。光伏的日连续性远强于负载，取昨日曲线即可跟上天气惯性，不做平滑反而对阴晴突变响应最快。附件中相邻两日日总量的相对变化中位数只有 3.2%、90% 分位 8.8%；归一化曲线距离上，今日与昨日为 0.095、与上周同日为 0.096，日期的身份几乎不影响曲线形状，故以此方法为基准应用在光伏模型池中。

(2) kNN 相似日沿用负载模型池中的做法，但不限定星期几，光伏不受作息支配。天气在光伏上留下的痕迹比在负载上清楚得多。附件中最近 3 个近邻的曲线距离比候选池平均低 41.7%；出力最高与最低的一成日子白天均值相差 1.97 倍，形状归一化后仍差 12.2%，正午平台时长相差 80 分钟；用 3 个相似日的次日曲线预测，单步 MAE 从 326.8 降到 208.1，光伏侧的相似日匹配同样由它负责。

(3) STL 分量预测沿用负载模型池中的分解逻辑。与负载不同，这里趋势项承担的是辐照水平的季节缓升缓降，在日总量方差中占 87.1%，而周季节仅 2.9%。附件中月度日均从 12 月的 1514 kW 升到 8 月的 2916 kW，相差 1.93 倍，其中 6 月因梅雨回落到 2370 kW、低于 7 月的 2723 kW，这种爬升只有趋势项跟得住，光伏侧的水平分量因此选它。

(4) FPCA 对近 14 天的白天曲线做低秩重构，再把公共形态与最近一日的偏差按阻尼系数 0.4 融合，预测值截断为非负。它只跟踪少数几个模态的幅度，就能兼顾曲线共性与近期天气。其可以清晰刻画光伏模型池的形状主线。

(5) LightGBM 的特征工程与负载模型池中的一致，并直接利用夜间恒零的物理约束，把 06:00 前与 20:00 后的预测强制置零。光伏侧的非线性部分也补在这里。

方法取舍 两个模型池中的 STL 都选用经典 STL，而非 CEEMDAN、VMD 等模态分解方法。后者需要在全局数据集上分解，滚动设定下会把预测日之后的信息带进训练窗；STL 仅在训练窗内分解，不使用未来信息。

口径说明 池内成员的全期 MAE 汇总于表 5。上文的单步 MAE 与近邻距离改善 41.7% 取自附件上的一次单步检验，表内的全期 MAE 来自 334 天滚动执行，两者口径不同，不做互相比较。

6.1.3 EGD 时变权重集成

在完成了两预测指标的模型池搭建后，需要为池中的各成员分配合适的权重。权重怎么定，取决于固定权重是否够用，而答案是否定的，原因是结构性的：后文响应月度及季节检验一节将给出漂移存在的证据——不同阶段的主导因素并不相同，夏季空调负荷期最可信赖的成员与秋季平稳周期里最可信赖的成员并不一样，一组全年不变的权重向量本身无法随阶段切换；若改用一个能力强大的元学习器按全期误差定一组权重，全

期误差又只是各阶段表现的平均，同样给不出当前由哪类因素主导的答案；再退一步，为每个阶段人工设定并维护一套权重，也远超日前预测任务应当承担的调参负担。

故，我们考虑动态地为成员赋权：权重逐日在线更新、完全由近期数据驱动，使模型池在所有场景下自动机动调整预测倾向，全程无需人工介入。

指数梯度下降的权重更新 记第 t 日模型 i 的权重为 $w_{t,i}$ ，当日预测误差结算完毕后按指数梯度下降更新

$$w_{t+1,i} = \frac{w_{t,i} \exp(-\mu \tilde{\ell}_{t,i})}{\sum_j w_{t,j} \exp(-\mu \tilde{\ell}_{t,j})}, \quad (11)$$

其中 $\tilde{\ell}_{t,i}$ 为模型 i 的局部核加权损失；学习率 μ 不作人工搜索，按指数加权策略的理论最优量级 $\mu^* = \ln N/T$ 由问题维度直接确定，其中 $N = 5$ 为池内成员数、 $T = 334$ 为评估天数， $\ln 5/334 \approx 0.0048$ ，故取 $\mu = 0.005$ （该取值不敏感的实证见过拟合检验一节）。

上式的逻辑和效果直白，即指数地压低当日误差大的成员，使误差小的成员份额上升，并将分母归一化以保证权重始终构成一个概率分布。其中，学习率取得较小，以保证让权重随时间的漂移速度不能过快，避免某一日的偶然大误差把某个成员一脚踢出。

该时变权重集成的框架来自于在线学习里 Hedge 算法的指数加权策略 [15]，且其已经被证明具有最优 regret 界 [12]。在该框架下，累积损失至多比事后最优的成员多出 $O(\sqrt{T \log N})$ 量级。所以，即使伴随季节切换及其引发的权重迁移，EGD 时变赋权下的总损失与日前已知当日数据的理想情形，只存在一个随天数缓慢增长的小量差距，这对赋权提供了极佳的稳健性支撑。

损失的局部核加权 考虑到单日误差的噪声有较大波动，直接拿当日损失更新权重可能引发权重随天气等波动特征产生严重波动。故采用 EGD 将最近 30 天的窗口内对历史损失做指数衰减加权

$$\tilde{\ell}_{t,i} = \frac{\sum_{s=t-29}^t 0.95^{t-s} \ell_{s,i}}{\sum_{s=t-29}^t 0.95^{t-s}}, \quad \ell_{s,i} = \text{MAE}(y_s, \hat{y}_{s,i}), \quad (12)$$

其中，衰减系数取 0.95 会导致当天的权重约为 30 天前的四倍。这可以让模型池更倾向通过近期的场景特征来选择赋权策略，同时也保留稍远时点，如一两周前的影响。这一局部窗加权的思路取自时变模型平均 TVJMA [16]，它用每个时点附近的局部信息挑选合成权重，而不是在全样本上定一套固定权重，与我们逐日更新的需求达成好匹配。

在算出日均损失后对每日做归一化，以避免在光伏误差整体偏大的阴雨月份，损失的量级主导权重更新，从而直接覆盖模型池成员之间的相对优劣。

周期性的重初始化 这一套 EGD 持续更新权重也存在代价，权重可能会停留在旧模式里，无法做出积极的策略变化。若某个成员模型在夏季被压到很低的份额，此后即便秋天的数据重新对它有利，指数更新也较缓慢的只能把它往回拉，这不能满足一些情况下的快速响应需求。为此，我们每隔 7 天将模型重训：

$$w_t \leftarrow \alpha w_{\text{init}} + (1 - \alpha) w_t, \quad \alpha = \max(0.05, 0.5 \exp(-(N - 35)/60)), \quad (13)$$

其中， N 为已训练天数。在最初的冷启动阶段，由于数据太少 $N < 35$ ， α 偏大权重被

拉回一个偏向简单方法的起点；而随着数据量的增加啊，后续的 α 衰减到 0.05 的下限，只保留一点微弱的复位，不再打扰已经学稳的权重。即长线的在线更新负责跟踪学习，周期性的复位负责切换 [15]

冷启动权重与滚动训练 在初始训练时只有 31 天数据，机器学习成员模型学习效果不佳，而简单平均在高不确定性下反而更稳 [13]。故据此让初始权重偏向简单方法，具体冷启动结果见下表。

表 4: 冷启动阶段两模型池的初始权重

模型成员	负载池	光伏池
季节朴素法 / Persistence	0.25	0.30
月度均值预测 / kNN	0.20	0.20
STL 分量预测	0.20	0.15
kNN / FPCA	0.20	0.15
LightGBM	0.15	0.20

结合上文周期性重初始化考量，将 LightGBM 每 7 天重训一次，与上面的权重复位同步；而在训练过程中我们不考虑将训练出来的当日时间预测值作为新输入，增量训练并预测当日后时间的目标。这会极大程度上扩大噪声，尤其在本题时间点分段较多的场景下。

6.1.4 预测模型检验

训练数据取自附件 2 全年 365 天、每天 144 个时点的记录，2025 年 1 月的 31 天作初始训练数据，滚动预测点逐天预测。

对于性能的评价，本文取指标 MAE、RMSE 与 MAPE，光伏另计仅统计 06:00–20:00 的白天 MAPE，排除夜间零值对百分比的失真。

同时，我们还选取了两模型池中涉及的所有单个模型进行指标对比，以证明模型池的优异表现并不是单个强大模型主导的，而是不同特征模型的搭配互补。

集成优于单模型 这一验证使模型池方法涉及的核心。从表 5 中可以分析出，对池内成员，负载集成 162.99 把最优单模型 LightGBM 的 172.71 再降 9.72，优于全部成员，光伏集成 165.96 虽高于最优单模型 FPCA 的 160.71，但优于其余全部成员。光伏白天 MAPE 由 7.83% 升至 8.85%，是 5 6 月阴雨月份误差结构变化所致，全期 MAE 仍明显占优。

LSTM 对比 为更加直接的表名本日前预测模型的优越性，我们直接选用了工程上的常用 ML 模型 LSTM，对相同的数据集进行训练。

其训练结果表现明显更差，负载 MAE 为 682.1，为本模型的 4.2 倍，光伏 MAE 443.4 为 2.7 倍，在 6 7 月与 10 11 月的季节变更厂家下 MAE 也出现了明显的短期激增。其可能问题在于纯序列缺少星期几、季节这类日历特征，即使 LSTM 拥有长期记忆识别和短期预测的优秀能力，其固定的训练窗口也跟不上季节模式的切换。而本文特征工程后基于 EGD 加权的模型池，在小数据与一些信息漂移的场景里反而稳健。

表 5: 池内单模型与 EGD 集成的全期 MAE

负载模型	MAE	光伏模型	MAE
LightGBM	172.71	FPCA	160.71
SeasonalNaive	176.80	Persistence	185.35
STL	178.59	LightGBM	192.14
kNN	188.80	kNN	205.04
HistMean	188.88	STL	212.73
EGD 集成	162.99	EGD 集成	165.96

消融实验 通过控制变量下除去特定模型，可以直观反映池内五个模型成员是否都有存在理由。

逐一移除成员并重跑 EGD 权重更新,结果见表 6。负载池的答案是 STL 与 LightGBM 不可或缺,移除后 MAE 分别上升 4.75 与 2.52; 季节朴素法与历史均值移除后集成反而略优 0.13 与 0.35,但二者是周周期的强基准与对照,保留的代价不足 0.4。光伏池中 FPCA 一家独大,移除后 MAE 上升 18.56,其余成员的贡献都不超过 1: 光伏各模型间的误差相关性高达 0.984 0.998,天气噪声主导下所有模型在同样的日子犯错,其余成员的价值在于 FPCA 失效的极端天气日提供修正。

表 6: 预测模型池消融实验 (MAE 单位 kW, 变化为相对完整模型的差值)

负载消融方案	负载 MAE	变化	光伏消融方案	光伏 MAE	变化
完整 5 模型	162.82	基准	完整 5 模型	159.77	基准
去掉 STL	167.57	+4.75	去掉 FPCA	178.33	+18.56
去掉 LightGBM	165.34	+2.52	去掉 Persistence	160.55	+0.78
去掉 kNN	163.00	+0.18	去掉 STL	160.32	+0.55
去掉 SeasonalNaive	162.69	-0.13	去掉 kNN	159.71	-0.06
去掉 HistMean	162.47	-0.35	去掉 LightGBM	159.60	-0.17

响应月度及季节检验 权重能否跟随季节,月度误差先给出了漂移存在的证据。负载 MAE 在 6、7、9 月达 208.5、272.9 与 256.7,对应夏季空调高峰与季节转换期,4 月、11 月仅 97.4 与 106.6,对应模式稳定的春秋季节; 光伏在 5 6 月阴雨期达 201.9 与 236.7,12 月天气稳定且功率本身低,最低至 82.6。面对这样的起伏,EGD 权重的轨迹显示模型确实在换挡,负载 LightGBM 权重夏季升至 0.80 0.83 抓住空调负荷的非线性,秋季自动回落、由权重 0.41 的 STL 与 0.38 的季节朴素法接管,光伏 FPCA 全年 0.89 0.99 稳定主导。整个切换由式 (11) 自动完成,无需人工干预: 哪类潜在因素当前占主导,权重就自动向对该因素最敏感的成员倾斜,这正是选择在线权重而非人工定权的理由。

分时段看,集成相对对照方法的优势在全年并不同质 (图 5): 以 XGBoost 对照为例,负载侧 2-4 月 (春季平稳期) MAE 为 117.4 对 148.0,优势约两成; 5-12 月 (含夏秋漂移期) 收窄为 179.6 对 185.4,仍稳定为正; 光伏侧两窗分别为 157.2 对 178.5 与 169.2 对 187.1,优势全程保持在一成上下。平稳期优势大、漂移期收窄的结构与概念漂移的机理一致,也说明集成的优势并非由某一段数据单独撑起。

过拟合检验 较优的结果也可能来自对评估数据的记忆,本文把这一疑虑拆成参数、




图 5: 两个时段上本文集成与对照方法的 MAE 对照（左：负载，右：光伏）

权重与设计三层，分别给出证据。

参数层 用时序切分查验机器学习成员是否记住了训练噪声：前 70% 训练、后 30% 测试，负载训练与测试 MAE 为 261.6 对 321.3，比值 1.23，光伏为 190.0 对 207.6，比值 1.09；不加正则的历史配置过拟合比达 4.83，强正则加 50 轮早停把它压低约 75%。作为补充，把叶数上限从 15 放宽到 31 重新滚动全年，负载全期 MAE 仅从 162.99 变为 163.80——放宽容量并未换来记住更多噪声的收益，记忆训练噪声并非性能来源。其余成员为无参数或低参数的统计模型，无此风险。

权重层 权重更新只使用截止前一日的误差，这里再用一个信息上界做机械性核验（图 6）：倘若每天都能在事后从池中挑出当日最优成员——这是任何在线方案都无法企及的理想情形——其全期 MAE 也不过 139.6（负载）与 140.2（光伏）；本文集成的 162.99 与 165.96 距该上界尚有 17%–18% 的差距。偷看未来的集成只会向上界逼近，绝不可能比它差出这么多，这从机制上排除了权重更新泄漏未来信息的可能。再对优于对照的结论做统计检验：与 XGBoost、LSTM 的按日损失差经 Newey–West HAC (lag 7) 修正后做 Diebold–Mariano 检验，四个对比全部显著——光伏对 XGBoost $p \approx 1.0 \times 10^{-4}$ ，负载对 XGBoost $p = 0.024$ ，对 LSTM 两对象均 $p < 10^{-24}$ 。

设计层 最难自证清白的是设计阶段的自由度：超参数与池构成都是在看过全年表现之后敲定的，直接报告的指标因此带有选择性乐观。本文的处理是先诚实声明，再量化其影响。超参数可分三类：学习率 μ 由 $\ln N/T$ 从问题维度推出，STL 周期 7、光伏夜间置零等由数据结构与物理规律决定，均不含人为自由度；其余常数（kNN 的 k 与窗口、FPCA 阻尼、LightGBM 正则）取保守中庸值。随后做两项复核：其一，把负载池恢复为精简前的 7 模型重新滚动全年，5–12 月 MAE 仅从 179.6 变为 180.6 (+0.6%)，说明池构成的精简并未按答案挑成绩；其二，对上述常数逐项拧偏一档重跑全年，样本外（5–12 月）MAE 的相对变化全部落在 $\pm 2\%$ 内（图 7），不存在只有看完整年答案才能找到的针尖参数。三层合看，本方法的较优表现来自池内机制互补与保守稳健的常数取值，而非对评估数据的记忆。

泄漏核验：集成远低于“逐日事后挑最优成员”的信息上界




图 6: 泄漏核验：逐日事后最优成员构成信息上界，本文集成距上界尚有 17%–18% 的差距（左：负载，右：光伏）

关键设计自由度扰动后的样本外表现：波动均在 $\pm 2\%$ 内




图 7: 设计层敏感性：关键常数逐项拧偏一档后，样本外（5–12月）MAE 相对基准的变化全部在 $\pm 2\%$ 内（左：负载，右：光伏）

6.2 考虑紧急购电的 LP 模型

6.2.1 分位数预测的必要性与决策分位

6.1 节的 EGD 集成预测对每个时点输出对应的预测值。题面对两类预测误差的计价并不对称：某时段少购 1 kWh，供电不足的缺口须按交易时刻电价的 5 倍向外网紧急购电；而多购电仍按原价结算，且多余的购电或光伏还能充入储能，留待之后的时段使用。因此计划层应当适度偏多购电。若直接把这份集成预测输入计划层，相当于用同一标准处理低估和高估，容易低估缺口的经济损失。模型池组的集成预测直接进入计划层时，全年 48096 个时段中有 25466 个时段出现缺口，紧急购电费为 413.39 万元。

分位调整只作用于计划层的输入，不改变 6.1 的预测本身。EGD 集成仍然给出负荷和光伏的基本走势，对每个时点，修正量取该时点过去 30 天预测残差的经验分位数，修正后的预测为

$$\hat{y}_t^{(q)} = \hat{y}_t + Q_q(\{y_s - \hat{y}_s\}_{s=t-30}^{t-1}), \quad (14)$$

其中 Q_q 为该时点残差样本的 q 分位数。由于不同购电计价的不对等，负荷向上取较高分位以减少低估，光伏向下取较低分位以减少高估。

曲线的实际分位与名义分位存在偏差：名义 80% 的中间区间在负荷和光伏上的实际覆盖率为 75.0% 和 74.3%，名义 16.7% 的上侧分位实际被超过 19.3% 和 19.1%，残差分位整体偏激进，因此保守修正之后仍会留下缺口。

分位数越高，负荷侧预测通常越大、光伏侧预测通常越小，计划购电费随之增加，紧急购电费则下降，二者之间存在费用平衡点。设低估 1 kWh 的边际代价为 $C_u = 5\lambda_t$ ，高估 1 kWh 的边际代价为 $C_o = \lambda_t$ ，代价比对应的参考分位为

$$q^{\text{ref}} = \frac{C_u}{C_u + C_o} = \frac{5\lambda_t}{5\lambda_t + \lambda_t} = \frac{5}{6} \approx 0.833. \quad (15)$$

6.2.2 紧急购电与结算

计划在每日 0:00 锁定，日内不再根据实际负荷和光伏调整。当计划供给不足时，紧急购电承担供电平衡的硬约束。记实际光伏功率为 P_t ，计划光伏直供为 g_t ，实际供给量为

$$S_t = a_t + g_t^r + d_t, \quad g_t^r = \min(g_t, P_t), \quad (16)$$

其中 P_t 为该时段光伏实际功率， g_t^r 表示实际光伏先满足计划直供，不足部分即是缺口的来源之一。缺口与紧急购电费为

$$e_t = \max(0, L_t - S_t), \quad C_t^e = 5\lambda_t e_t \Delta t, \quad (17)$$

连续缺口时段合并为同一区间记账。此外，实际光伏超出计划直供的部分并入充电，受功率与容量上限截断，装不下的部分弃掉。全年能源支出为计划购电费与紧急购电费之和，净成本再减去期末储能价值。

6.2.3 计划购电模型

计划层沿用问题 1 的供需平衡、光伏分流和储能动态关系，但取消每天 24:00 的储电量必须回到 00:00 的约束。设 $E_0^{(d)}$ 为第 d 天初始储电量，首日取 6000 kWh，之后取前一日实际执行期末的储电量。日末储能仍可供后续时段使用，按日末时刻电价与 90% 的可利用率估计其价值 $0.9\lambda_{144}E_{144}^{(d)}$ ，并从当日计划购电成本中扣除，使 LP 不会为了压低当日成本而在午夜前放空储能。这项扣除是优化模型对剩余电量的估值，并非向外网售电，题面也没有给出售电价格，储能中的电量只能在之后的时段放电使用。供需平衡、光伏分流、储能动态与各类界限约束均同式 (7)，仅把实际值 L_t 、 P_t^{pv} 换成经分位修正的预测 $\hat{L}_t$ 、 $\hat{P}_t$ ，并把周期边界 $E_0 = E_{144} = 6000$ 换成逐日滚动初值，目标函数改为

$$\min F^{(d)} = \sum_{t=1}^{144} \lambda_t (a_t + b_t) \Delta t - 0.9 \lambda_{144} E_{144}^{(d)}. \quad (18)$$

SOC 消元后，每日 LP 含 864 个决策变量、288 个等式约束与 576 个不等式约束，用 HiGHS 逐日滚动求解 334 天。储能价值只对日末存量计一次，不把每个时段的 E_t 逐项计入目标，否则同一批电量会因在储能中停留而被重复扣减。计划购电量按 $(a_t + b_t)\Delta t$ 计费，实际执行后的期末 SOC 直接作为次日初值；放电按计划执行，仅在触及 1200 kWh 底线时截断，全天储电量保持在 [1200, 10800] kWh 内；充电由计划购电充电量与实现的光伏盈余构成，受功率与容量上限截断。求解中对同段充放的退化解加极小吞吐项，该项不计入报告成本。

6.2.4 决策分位的确定

式 (15) 只计入单个时段的购电代价，没有包含储能跨时段传递、光伏弃电、SOC 上下限与日末存量价值，因此不能直接当作全年费用最优值。式 (14) 在任意分位处都可取值，分位可以连续搜索，不必绑定到某几个固定档位，分位档的最终取值因此由全年费用回溯确定：令负载取 P_τ 、光伏取 $P_{1-\tau}$ ，对每个候选 τ 重新执行 334 天计划求解与实际数据结算。以 0.833 为中心、步长 0.02 遍历 0.733 0.933，再在 0.78 0.86 内以 0.01 为步长细化，净成本在 $\tau = 0.81$ 处最低，为 1495.38 万元，按费用最低的原则取 $\tau = 0.81$ 作为决策分位，0.833 只作为单时段代价比给出的参考值。

6.3 模型对比

三组预测来源使用同一个计划 LP 和同一套实际数据结算规则，表 7 比较其全年净成本与紧急购电缺口。模型池组、XGBoost 对照组与 LSTM 组的净成本分别为 1638.75、1710.30 与 2829.85 万元，完美预见下界为 1225.12 万元，模型池组比下界多支出 413.63 万元。三组的差别只有预测曲线来源，因此表中的费用差异全部来自预测质量。

模型池组的净成本最低，为 1638.75 万元，比 XGBoost 对照组低 71.55 万元，比 LSTM 组低 1191.10 万元。XGBoost 对日历、滞后量等表格特征的非线性关系处理直接，净成本仅为模型池组的 1.044 倍，说明通用的梯度提升模型仍能保持接近集成模型的结果。LSTM 具备提取长短期序列依赖的能力，但本题纯时序基线的负载 MAE 为 682.08 kW，

表 7: 三组预测来源的全年模型对比（2025.2.1–12.31，费用单位：万元）

方案	紧急费	净成本	缺口/kWh
模型池组	413.39	1638.75	953,922
XGBoost 对照组	492.92	1710.30	1,120,334
LSTM 组	1633.96	2829.85	3,661,104

模型池组为 162.99 kW；缺少日历特征且训练窗口固定，使其在 6 7 月与 10 11 月的季节切换期误差进一步放大，计划层系统性少购电，紧急购电费升至 1633.96 万元。

从费用构成看，模型池组的计划购电费为 1225.41 万元、紧急购电费为 413.39 万元；XGBoost 对照组为 1217.43 万元与 492.92 万元；LSTM 组为 1195.94 万元与 1633.96 万元。LSTM 的计划费是三组中最低，却因缺口多付了数倍于计划费节省的紧急费用，净成本反而最高。计划买得少不等于总成本低，预测模型的比较必须放到结算后的费用上。

图 8 给出三组预测来源的月度紧急购电费用。三组的紧急费都在夏季抬升，6 月同时达到峰值，对应全年预测误差最强的时段；LSTM 组在各月的紧急费都明显高于另外两组，说明其缺口并不集中在某几个月，而是全年持续存在。




图 8: 三组预测来源的月度紧急购电费用对比

7 问题 3 模型的建立与求解

8 问题 4 模型的建立与求解

9 模型评价与总结

参考文献

- [1] 王先齐, 吕智林, 汤泽琦. 基于分时电价机制的并网型微网多目标动态优化调度 [J]. 电力系统保护与控制, 2017, 45(4). DOI: 10.7667/PSPC160250.
- [2] 袁龙. 分布式光伏发电与储能协同调度模型研究 [D]. 济南: 山东大学, 2018.
- [3] Sioshansi R, Denholm P, Jenkin T, et al. Estimating the value of electricity storage in PJM: Arbitrage and some welfare effects[J]. Energy Economics, 2009, 31(2): 269-277.
- [4] 王凌云, 王晓敏, 胡兴媛, 等. 基于多智能体微网的需求侧分时电价优化调度 [J]. 信息与控制, 2020, 49(4): 429-435.
- [5] Boyd S, Vandenberghe L. Convex Optimization[M]. Cambridge: Cambridge University Press, 2004.
- [6] 车泉辉, 陈建洪. 光伏功率短期预测方法研究综述 [J]. 电力自动化设备, 2022, 42(10): 12-21.
- [7] Arrow K J, Harris T E, Marschak J. Optimal inventory policy[J]. Econometrica, 1951, 19(3): 250-272.
- [8] Cleveland R B, Cleveland W S, McRae J E, et al. STL: A seasonal-trend decomposition procedure based on Loess[J]. Journal of Official Statistics, 1990, 6(1): 3-73.
- [9] Lu J, Liu A, Dong F, et al. Learning under concept drift: A review[J]. IEEE Transactions on Knowledge and Data Engineering, 2019, 31(12): 2346-2363.
- [10] Wagner-Muns I M, Guardiola I G, Samaranayake V A, et al. A functional data analysis approach to traffic volume forecasting[J]. IEEE Transactions on Intelligent Transportation Systems, 2018, 19(3): 878-888.
- [11] Akyurek B O, Akyurek A S, Kleissl J, et al. TESLA: Taylor expanded solar analog forecasting[C]. 2014.
- [12] Mourtada J, Gaïffas S. On the optimality of the Hedge algorithm in the stochastic regime[J]. Journal of Machine Learning Research, 2019, 20(83): 1-46.
- [13] Graefe A, Küchenhoff H, Stierle V, et al. Combining forecasts: Evidence on the relative accuracy of the simple average and Bayesian model averaging[J]. Statistical Modelling, 2015.
- [14] Wang Y, Zhang N, Tan Y, et al. Combining probabilistic load forecasts[J]. IEEE Transactions on Smart Grid, 2019, 10(4): 4477-4489.
- [15] Zhang Y F, Wen Q, Wang X, et al. OneNet: Enhancing time series forecasting models under concept drift by online ensembling[C]//Advances in Neural Information Processing Systems (NeurIPS). 2023.
- [16] Sun Y, Hong Y, Lee T H, et al. Time-varying model averaging[J]. Journal of Econometrics, 2021, 222(2): 974-992.

AI 工具使用声明

（占位）本项按竞赛当期规范填写。