

分类号_____

U D C _____

密 级 _____

学 号 201010522208

华北水利水电大学

North China University of Water Resources and Electric Power

硕士学位论文

中长期电力负荷预测的研究与应用

(题目和副题)

侯永辉

(作者姓名)

导师姓名、职称 许强教授

申请学位 工学硕士 学科名称 水利水电工程

提交论文日期 _____ 答辩日期 2013-5-14

学位授予单位、授予日期 华北水利水电大学

独立完成与诚信声明

本人郑重声明：所提交的学位论文，是本人在指导教师的指导下，独立进行研究工作所取得的科研成果并撰写完成的。没有剽窃、抄袭等违反学术道德、学术规范的侵权行为。文中除已经标注引用的内容外，本学位论文中不包含其他人或集体已经发表或撰写过的研究成果，也不包含为获得华北水利水电大学或其它教育机构的学位或证书所使用过的材料。对本文的研究做出重要贡献的个人和集体，均已在文中作了明确的说明并表示了谢意。本人完全意识到本声明的法律后果由本人承担。

学位论文作者签名：侯永辉

保证人（导师）签名：许强

签字日期：2013.6.2

签字日期：2013.6.4

学位论文版权使用授权书

本人完全了解华北水利水电大学有关保管、使用学位论文的规定。特授权华北水利水电大学可以将学位论文的全部或部分内容公开和编入有关数据库提供检索，并采用影印、缩印或扫描等复制手段复制、保存、汇编以供查阅和借阅。同意学校向国家有关部门或机构送交论文原件或复印件和电子文档。（涉密的学位论文在解密后应遵守此规定）

学位论文作者签名：侯永辉

导师签名：许强

签字日期：2013.6.2

签字日期：2013.6.4

分类号:

密 级:

UDC:

单位代码: 10078

华北水利水电大学硕士学位论文

中长期电力负荷预测的研究与应用

RESEARCH AND APPLICATION OF MID-LONG TERM
POWER LOAD FORECASTING

研 究 生 姓 名: 侯 永 辉
指 导 教 师: 许 强 教授
专 业 名 称: 水 利 水 电 工 程
所 在 学 院: 电 力 学 院

2013 年 5 月

中长期电力负荷预测的研究与应用

摘 要

电力系统中长期负荷预测是电力系统规划和运行研究的重要内容，它是保证电力系统可靠和经济运行的前提，同时也是电网规划建设的依据和基础。随着国民经济受电力工业的发展影响越来越大，电力负荷的正确预测愈发显得重要，因此电力行业的投资、网络布局和运行的合理性很大程度上取决于负荷预测精度的高低。

负荷预测会受到许多不确定因素不同程度的影响，不同的预测模型都有自己所适应的范围，很难应用于所有的情况。所以到目前为止，还不能找到一种预测方法在任何情况下能够保证获得令人满意的预测结果，所以在进行中长期负荷预测时，要学会结合当地的实际情况，选用多种不同的预测方法，将预测的结果进行相互对比校核，确定最终的预测值。

电力负荷总量的预测属于战略性的预测，它是将规划地区的整体负荷作为研究的对象，为电网的规划提供了必要的基础数据，负荷总量的预测结果对城市电网的规划具有非常重要的指导意义，也为城市的供电电源点的确定提供了重要依据。

本文研究了多种不同的中长期负荷预测理论方法及其应用，并简要介绍了电力系统中长期负荷预测的目的和意义，国内外的发展现状及展望，然后比较系统的阐述了各种预测理论方法，并结合中长期电力负荷预测的具体实际情况，较为深入地分析了各种不同预测理论应用于电力系统的具体实现方法，通过对不同的中长期负荷预测方法的仿真实验，包括单模型、改进模型、综合模型以及组合模型，比较分析各种不同方法的预测结果，或者运用几种方法的组合进行预测，或者将整体分割为部分，对各个部分应用合适的模型，经过系列的联合应用，使预测的精度最高，误差最小。

关键词：电力系统；中长期负荷预测；神经网络；灰色预测；组合预测；联合应用

RESEARCH AND APPLICATION OF MID-LONG TERM POWER LOAD FORECASTING

ABSTRACT

Mid-long term load forecasting of power system is an important content in the research of power system planning and running, it is the premise to ensure reliable and economic operation of the power system, basis and also the power grid planning and construction. With the development of the national economy under the influence of the electric power industry is more and more big, the correct forecasting of power load becomes more and more important, so the rationality greatly power industry investment, network layout and operation depends on the precision of load forecast.

Load forecasting is affected by many uncertain factors in different degree, different models have their own applicable scope, it is difficult to apply in all cases. So far, also cannot find a prediction method can obtain satisfactory predictive results in any case, so in the medium and long term load forecasting, to learn how to combine the local actual situation, choose a different prediction method, the prediction results are compared to each other and check, determine the final prediction value.

Forecasting of power load forecasting total belong to strategic planning, it is the overall load area as the research object, to provide basic data for network planning, load forecasting result has very important significance on the city power grid planning, but also provide the important basis for determining the power points of the city.

This paper studied a variety of different medium and long-term load forecasting theory and its application, and briefly introduces the purpose and significance of long term load forecasting of power system, the development status and Prospect of domestic and abroad, and then systematically expounded the theory of forecasting methods, and combining with practical situation of medium and long-term load forecasting, deeply analysis of the specific implementation methods for different prediction theory is applied in the power system, through the simulation experiment on the medium and long term load of different prediction methods, including single model, the improved model, a comprehensive model and combined model, the prediction results of comparative analysis of various methods for forecast combination, or using several methods, or for overall segmentation part of each part of the

model, application of appropriate, through the combined application of series, the forecasting accuracy of maximum, minimum error.

KEY WORDS: Power system; Medium and long term load forecasting; Neural network; Combination forecasting; Combined application

目 录

摘 要	I
ABSTRACT	III
1 绪 论	1
1.1 引言	1
1.2 本课题的背景和意义	1
1.3 国内外负荷预测技术及研究动态	2
1.3.1 经典预测方法	2
1.3.2 传统预测方法	3
1.3.3 现代预测方法	4
1.3.4 组合预测模型法	6
1.4 电力负荷的影响因素	7
1.5 本文所做的工作	7
2 中长期电力负荷预测单模型理论及其应用	8
2.1 线性回归模型	8
2.1.1 一元线性回归模型	8
2.1.2 多元线性回归模型	9
2.2 指数平滑法	9
2.2.1 二次指数平滑法	11
2.2.2 三次指数平滑法	12
2.3 灰色系统	13
2.3.1 灰色模型理论	13
2.3.2 灰色模型方法小结	17
2.4 神经网络	18
2.4.1 BP 神经网络理论	18
2.4.2 神经网络方法小结	21
2.5 模型精度检验	21
2.6 单模型的应用效果	23
2.7 本章小结	25
3 中长期电力负荷预测改进模型理论及其应用	26
3.1 改进的指数平滑模型	26
3.2 改进的灰色模型	27
3.3 改进的神经网络模型	31
3.4 改进模型的应用效果	33

3.5 本章小结	35
4 中长期电力负荷预测模型综合理论与应用	36
4.1 灰色模型与 BP 神经网络的综合	36
4.1.1 灰色模型和 BP 神经网络的优化	36
4.1.2 灰色 BP 网络模型的优化算法	37
4.2 综合模型的应用效果	39
4.3 本章小结	40
5 中长期电力负荷的组合预测模型理论及其应用	41
5.1 组合预测的研究方法	41
5.2 组合预测的权重系数	41
5.3 组合预测的最优加权模型	43
5.4 组合预测权重的正交组合	46
5.5 组合模型的应用效果	50
5.6 本章小结	52
6 中长期电力负荷预测技术的联合应用	53
6.1 联合应用算例背景	53
6.2 原始数据的分析与预测方法的选取	53
6.3 预测计算过程的实现	54
6.4 精度校验	55
6.5 预测结论	56
6.6 本章小结	56
7 结论与展望	57
攻读硕士学位期间参加的科研实践及发表的论文	59
致 谢	61
参考文献	62

1 绪 论

1.1 引言

电力系统负荷预测作为电力行业中一个热点问题至今一直备受关注,特别是近些年随着我国城市电网改造步伐的加快以及电力工业市场化营运机制的推行,电力行业中长期负荷预测成为了越来越重要的探索研究领域。精确、科学的预测是正确决策的前提和保证,电力系统负荷预测本质上是对电力市场需求的预测。在商业化的体制下,做好负荷预测尤其是中长期负荷预测的工作将直接关系到电网运行所需的成本与供电公司的经济效益。

本章简要的阐述了电力系统中长期负荷预测的研究目的、背景和意义,以及中长期负荷预测的特点与难点。综述了国内外中长期负荷预测的发展现状以及主要存在的问题,同时对不同的负荷预测方法作了简单的比较分析。

1.2 本课题的背景和意义

随着工业与农业的快速发展以及人民群众的生活水平日益提高,社会需求的用电量越来越大。为了能解决日益增大的用电量需求问题,需要不断扩大电力系统的发展规模。电力行业的发展需不仅要巨大的投资以及一次能源,还会对国民经济其它有关部门产生巨大的影响,因而电力系统规划的失误会给国家的建设带来无法估量的损失,所以对电力规划进行研究分析,并且最大限度的提高规划质量具有十分重大的意义,而电力负荷预测是现实这一目标的第一步。电力系统负荷预测的准确程度将直接关系到费用投资、网络的布局和运行合理性。

电力系统按照预测的周期一般分为三种。其中,短期负荷预测周期是指在一年以内,中期的预测周期为五到十年,长期的负荷预测周期一般是指十年甚至几十年。中长期负荷预测主要用于电力系统规划,包括发电设备和输发电设备的扩建、退役和改建计划,因此它是电力行业规划单位的重要工作。

电力系统的中长期负荷预测作为电力系统规划的基础性工作,它为电网规划的发展提供了必要的基础数据,其数据精确性将直接影响整个工作规划的优劣。准确的负荷预测是电力工作人员努力探求的目标,但想要要达到这一目确实有非常大的难度。其一是因为电量变化影响因素很复杂,实现中长期的负荷预测,仅仅在依靠电力系统自身的信息与资料是不可能完成的,同时电量和环境因素存在的联系是不能借助简单的函数表达式来描述的,它们之间一种模糊的关系,随着电力行业的迅速发展,电力系统的规模程度日趋庞大,使得更多的不确定等因素也融入到预测的背景中来,预测环境的复杂性也陡然增加;其二是一些数据资料的不完整和模糊信息的存在,使得那些传统的确定性负

荷预测的模型使用非常困难，掌握先进的负荷预测技术，将会负荷预测的精度方面得到很大的提高。

负荷预测的技术方法很多，每一种预测模型都有它的适用范围，很难做到适用任何情况，因此组合优化的预测方法成为学者们所追求的。组合预测是通过建立一个优化的组合预测模型，然后把多种单一预测方法所得结果进行分析综合，得到预测取值范围较窄的以便分析和决策使用。组合预测模型能有效的利用各种不同预测样本的信息，这比单个的预测模型分析研究问题更有系统性和全面性，它能够有成效地减少单个负荷预测模型过程中因环境随机因素造成的影响，从而进一步提高了预测的精度。

电力负荷的准确预测，能为电力行业电网管理现代化和科学化提供重要的依据，电力系统的负荷预测不仅对电力系统控制和运行起着非常重要的作用，也是电网规划的前提和基础。可靠准确地负荷预测不仅能保证电力行业运行的安全性，同时又可提高电力系统运行的经济性。

1.3 国内外负荷预测技术及研究动态

不管是从国内还是国外来看，目前短期的负荷预测技术发展要更为充分，中长期的负荷预测研究要远远少于短期的负荷预测。这主要是因为短期负荷预测数据极为丰富，并且未来某时刻的电力负荷依赖于历史的负荷序列发展，因此随着人工智能和信号处理等新学科快速发展，短期的负荷预测技术无论是在科学研究领域还是在实际的应用操作中，都得到了非常充分的发展。相反，由于中长期负荷预测所受到的影响不确定因素多，可提供参考的历史数据信息又少，各个地区的发展又不完全相同，进行准确的定量分析研究十分困难。而且，国外的负荷变化的发展规律已经趋于稳定，国内的电力行业又长期处在垄断经营的模式下，中长期的负荷预测已经长期被淡化，因此以至于这方面的研究与探讨力度相对短期要较小。

负荷预测的核心问题是建立合理的预测数学模型，随着计算机科学技术的快速提高，负荷预测的理论技术也得到了很大程度的发展，理论研究正在逐步加深，为了能找到方便、准确率高、计算速度快的负荷预测技术方法，大量学者和专家在理论以及实践上进行了较为广泛的研究与讨论。

从负荷预测技术上来看，对预测方法的研究，一直都是国内外所讨论的热点问题，到目前为止已经提出了许多种中长期负荷预测的方法，其中主要的有经典预测方法、传统的预测方法、现代预测方法以及组合预测方法，尽管如此，许多的专家和学者仍然在努力不懈，不断寻找探索新的最优的预测方法。

1.3.1 经典预测方法

严格来讲，负荷预测的经典方法并不属于真正意义上的负荷预测方法，它只是依靠专家的相关经验或者一些简单变量间的关系来对未来的负荷作出一个方向性的推测结

论, 预测的精度往往较差, 但是在实际的中长期负荷, 与工作人员的经验相结合, 可对预测的结果进行验证, 方法主要有以下几种:

(1) 单耗法

单耗法即单位产品的电耗法, 用某一工业产品的产量与平均单位产品的用电量, 来计算得到该产品的总耗电量。

这种方法需要做大量的统计和调查工作, 对近期的预测效果比较好, 但在现实中很难比较准确地求出用电的单耗, 工作量太大不经济。

(2) 弹性系数法

电力弹性系数是地区的总用电量平均年增产率和农业总产值的平均增长率的比, 它是反映国民经济发展和电力发展关系的一个宏观指标。一般来讲, 电力行业要适度超前的发展, 也就是指电力弹性系数应该大于1, 但是由于弹性系数是根据某地区的负荷结构与性质, 并对历史和各类用电比重的发展趋势慎重分析后确定的, 所以, 电力弹性系数法一般应用于校核中长期的宏观方面的负荷预测。

(3) 负荷密度法

负荷密度预测法是从地区的建筑面积(或土地面积)的平均耗用电量作为预测的依据, 先预测未来的某个时期的建筑面积(或土地面积)与单位面积的用电密度, 然后再乘以面积就可以得到用电量的预测值, 分区负荷预测密度法是考虑到近些年的发展状况、经济发展目标与电力规划的目标将需要预测的地区分为多个功能的区域, 然后再对这些功能区域用负荷密度法来进行负荷预测, 最后把预测的电量值相加得到总的用电量。

(4) 人均电量指标换算法

人均电量是综合考察一个国家以及城市经济发达程度的重要参数之一。人均电量的指标换算法是指选取某个和本地区的人文地理环境、经济发展情况和用电结构等存在相似的国内外区域作为参照的对象, 通过对比分析这两个地区过去以及现在的人均电量指标, 然后得到该地区的人均电量预测值, 再利用人口统计分析预测出总的用电量。

(5) 分类负荷预测法

分类负荷预测法是将用电负荷分为: 工业用电、生活用电、农业用电以及其它用电共计四大类, 将不同种类的负荷分别预测, 最后相加乘以比例系数得到。

分类负荷预测的优点是在某一类负荷当中, 其增长趋势的反常情况有可能被发现, 同时由于不同种类的负荷都要预测, 因此总的负荷预测结果是明确的, 缺点主要是统计信息的搜集工作比较大而复杂。

1.3.2 传统预测方法

传统预测方法包括趋势分析方法、回归分析法及时间序列分析法等。

(1) 趋势分析方法

趋势分析方法又被称之为曲线拟合或者曲线回归, 它是目前为止研究最多, 也是最

为流行的一种定量的预测方法。它是利用已知的统计历史资料来拟合一条曲线,从这条曲线上能够反映出负荷的增长趋势,然后利用这个拟合的曲线来对未来的某些点的负荷预测值进行估计。按照不同地区的负荷变化规律,可以选择不同的趋势模型,常用的有线性趋势模型、指数趋势模型、修正指数趋势模型、对数趋势模型、多项式趋势模型、幂函数趋势模型、逻辑趋势模型、龚玻兹趋势模型等。趋势模型的寻求过程是相对比较简单,它本身就是一种确定的外推,在加工过去的历史数据、拟合曲线的过程中,都不考虑其中的随机误差。选择比较合适的趋势曲线,在很多情况下,确实也都能给出比较理想的预测值,但是采用不同的模型给出的预测值相差会很大,关键是要根据地区的实际发展状况,

(2) 回归分析法

回归分析法是根据数理统计原理,用数学来处理对大量的统计数据,并确定用电负荷或用电量与其中某些自变量例如人口、国民经济产值、工农业总产值等之间的相关关系,建立起相关性较好的数学模型,并利用其外推,用来对今后的用电量进行预测。

根据统计的历史数据,选择其中最接近的曲线函数,然后应用最小二乘法使其间的偏差平方和达到最小,计算出回归系数,并且建立回归方程。当求得回归方程,把要求的未知点代入回归方程,就能够得到预测值。

因为受各种不同因素的影响,搜集和统计的历史资料往往具有模糊性,于此同时未来的某些相关的变量也只是估计数,也存在着模糊性,经典的回归模型其本身就比较难完全实现变量之间的关系,因此,便出现了模糊的线性回归分析法,它是将里面的回归系数模糊化,更能将拟合的情况接近实际。

应用回归分析法进行负荷预测时,若利用过去某些年的历史数据正处于涨快的发展时期,则预测值的趋势会越来越快,相反,正处于滞后的时期,则预测值会越来越慢。

(3) 时间序列分析法

时间序列分析法是利用负荷过去的统计数据,找到其中随时间而变化的规律,建立起时序模型,以推断出未来负荷预测值的方法。按照所用的处理方法的不同,时间序列法又可分为随机时间序列分析法和确定时间序列分析法。常用的随机时间序列分析法有 Markov 方法、Box-Jenkins 方法、状态空间方法等。常用的确定时间序列分析法有 Census-H 分解法和指数平滑法。时间序列法如果在电网正常运行的情况下,并且气候等一系列因素变化很小的时候预测的效果会较理想,但是在随机因素变化非常大或者存在一些不良数据的情况下,预测的效果会很不理想,这种方法主要用于短期的负荷预测。

1.3.3 现代预测方法

现代预测方法主要是智能预测方法,它并不需要提前知道模型的结构与参数的相关先验知识,也并不需要经过复杂的数学模型,比较适合于存在多变量、非线性、时变、随机性的电力负荷预测。主要包括人工神经网络法、专家系统法、灰色理论预测法、模糊预测法和数据挖掘技术。

(1) 人工神经网络法

人工神经网络是来源于人的脑神经系统模型，具有一定的模拟人形象思维能力，它由大量的人工神经元相互连接而成的网络。人工神经网络法是一种不依赖于某种模型的方法，它非常适合一些具有随机性或高度非线性的对象，具有很强的适应性和学习功能。当用于负荷预测时，利用人工神经网络法可以使神经网络任意逼近非线性系统，以便对过去的负荷曲线进行很好地拟合。负荷预测经常用的模型有 BP 模型、Kohonen 模型、改进的 BP 模型以及 RBF 神经网络等。由于神经网络模型需要的输入、输出历史数据都必须以精确为前提，但是在实际预测时，往往统计中存在着误差（特别是一些年度统计数据需要经过很多次的修改才能够更接近实际值），因此数据和实际值相比较会具有一定的误差，神经网络所拟合的输入、输出必然和实际也存在一定差别，这样会导致预测不够准确。这就需要针对不同特点的不同地区，对输入输出关系的选择以及样本采集信息的构成需要进行较大的调整，这就给这种方法的推广加大了难度。

到现在为止，人工神经网络的方法的主要应用在于短期的电力负荷预测，但现在也有许多人用这种方法来预测中长期负荷。可以将改进的灰色系统理论与人工神经网络方法紧密结合起来就可以进行中长期负荷预测，可以充分利用灰色理论预测需要原始数据量少以及建模过程相对简单的优点，对电力行业的中长期负荷前期进行预测，并结合神经网络处理大量的非精确性、非线性规律具有自我学习以及自适应能力的特点，在综合考虑经济因素的条件下对原始的数据进行预处理，并结合改进的 BP 算法得到理想的预测结果。

(2) 专家系统预测法

专家系统是基于知识的程序设计方案而建立起来的计算机系统，它具有某些特定领域的专家知识以及经验，并且能够像专家一样运用这些专业知识，经过推理，在这个特定的领域范围内给出智能结果推断。专家预测方法应用于中长期负荷的预测时，能够对所搜集的预测模型进行逐一的评估和决策，快速地推测出最佳的预测结果，从而避免了人工推理的繁琐以及人为的差错，进一步也克服了以前某些单一模型存在的片面性缺陷，但是对多年的历史数据进行调查搜集、分析和提取将需要花费大量的人力、物力以及财力。

现在，已经有许多技术人员将专家系统在实践中进行广泛性的尝试，除了应用于某些短期的日负荷预测当中，还可以利用模糊专家系统给初步预测的结果给以适当的修正，以及将这种方法对中长期负荷预测进行处理。

(3) 灰色理论预测法

灰色系统是指部分信息明确,另外某些部分不明确的系统。灰色理论预测法就是根据部分明确的信息，加工形成必要的有限序列以及微分方程，找出各参数之间的规律，进而推测出未知信息发展趋势的一种分析方法。

灰色系统理论首先是利用统计的负荷数据当作灰数，通过数据按照一定的规律生成得到一组新的数据列，从而减少原始数据的随机性，用此新生成的数据建立起灰色模型

开始进行预测,最后将预测的负荷值经过变换得到负荷的最终预测值。利用灰色理论进行负荷预测时,具有样本信息少、计算程序简单、精度确高和实用性强的优点。缺点是如果数据的离散程度比较大时,当数据的灰度较大预测精确度就会较差一些,所以当这种方法应用于电力系统的中长期负荷预测时,仅仅只有最近的几个数据精度较高,其它较远的预测数据只能反映出趋势值和规划值。

(4) 模糊预测法

模糊算法是利用模糊理论去探讨研究具有“模糊”特性的处理对象时,其效果会非常显著。广泛应用于负荷预测的模糊方法有模糊线性回归、模糊分行业用电模型、模糊聚类、模糊指数平滑、模糊时间序列模型等,这几种模型是在原来模型的基础上和模糊理论相结合形成了新的预测模型,它能够很好的处理模糊性变量,从而更好地解决了在电力系统负荷预测中大量信息不明确的难题,进一步提高了电力行业中长期负荷预测的精确度。但是模糊算法同样要求提供大量的原始数据,加之我国统计工作的不完善,可能造成使用上的困难以及精度方面的不精确性。

模糊预测方法并不是依靠统计的原始数据的分析,而是考虑与电力负荷相关的多种因素,把负荷和对应的环境看作一个数据的整体进行加工,便可得出负荷变化模式与对应环境因素的特征,因此可将预测年环境因素和各历史环境特征进行对比,得到所要求的负荷增长率。

(5) 数据挖掘技术

数据挖掘技术(DM,Data Mining)是将从大量的数据中提取出人们未知的但是又潜在有用的知识和信息,并把其表示成能被大家理解的模式的一种高级过程。数据挖掘非常显著地优点是它极其强大的数据处理能力,可以利用大量的数据找出有用的规则、规律、联系、模式等。

电力系统是一个极其庞大的复杂的系统,它包含的数据类型多种多样,数据的信息量非常巨大,尤其是电力进行市场化以后,数据信息量更是数倍的增长,仅仅负荷的数据域电价的数据就让人十分惊讶,处在这样的环境下,只用过去传统的处理分析方法已很难得到理想的结果。数据挖掘在解决这个难题是一个很好的处理工具。

1.3.4 组合预测模型法

由于各种预测模型方法的特点不同加之电力系统负荷的复杂性,使用单一方法的预测效果往往会“时好时坏”,不能够达到很好的预测效果,所以可以应用组合预测的方法来提高预测的精度。组合预测能够综合利用多种预测方法的预测值,用适当的加权系数进行预测。这种方法的关键在于求出各种预测方法的加权系数。电力系统负荷预测方面的组合预测一般包含两种含义:一是指利用几种预测模型得到的预测结果选用适当的权重系数进行加权平均得到满意预测结果的一种预测方法,这类方法的实质是优化确定各预测模型权重;另外一种含义对几种预测模型的结果进行对比,按照一定的准则选择,选出某一个预测模型作为最优的模型来进行预测。

1.4 电力负荷的影响因素

在电力系统负荷预测中，有很多因素不同程度地直接或间接影响着负荷的预测值。影响负荷预测的几个主要因素如下：

- (1) 经济发展水平的高低与经济结构调整的影响；
- (2) 收入增加、生活水平的提高与消费观念变动的影响；
- (3) 电力消费市场结构变动的影响；
- (4) 自然因素包括气温以及气候的影响；
- (5) 电价浮动的影响；
- (6) 电力供应侧包括电网建设、配电网改造与电力短缺状况的影响；
- (7) 电力需求侧管理采取措施包括蓄能设备、移峰填谷等影响；
- (8) 多种政策因素包括高耗电行业的优惠电价、环保要求的影响；

在影响负荷特性的很多因素当中，经济发展水平的高低与经济结构调整、电价、用电结构变化以及生活水平的提高占有很大的程度；调温负荷比较重大及经济非常发达的地区受气温气候影响较大，而拉闸限电、城农网改造和需求侧管理的影响相对比较小。

1.5 本文所做的工作

电力行业的中长期负荷预测是电网规划和运行的基础工作，其预测精度的高低将很大程度影响着整个电网规划工作的优劣。为了能够最大程度地提高电力系统中长期负荷预测的精度。本文结合电力负荷实例，综合分析当地调度部门近年来的统计负荷，考虑到经典的负荷预测模型已很难适应现代的电力负荷预测，误差较大，本文采用了传统的及现代的预测方法，选几个比较适合当地特点的预测方法（包括指数平滑法、灰色预测法、人工神经网络预测法等在内的多种单一或者经过组合加权）进行建模仿真，从误差分析方面得到适合当地负荷变化发展的最优模型，从仿真的精度方面考虑，选取较为合理的预测方法。

具体而言，需要完成以下工作：

(1) 负荷在不同的地区、行业、时间的变化规律是不一样的，很难用简单的用单一的预测模型能描述所有负荷的未来变化趋势，因此方法库的建立是非常有必要的，这样才能满足多样性不同规律的负荷发展需求。

(2) 分析该地区的用电负荷变化的特点，选取有效的预测方法并给出预测方案。

(3) 预测模型中一些与负荷相关联的因素可实现自定义，能够修改其中各个模型的有关参数，可以去定义模型的结构以及不同的预测方法。这样能满足用户充分自由的空间，把人的经验和计算机实现仿真有机结合在一起，从而提高负荷预测精度的稳定性。

(4) 建立的预测模型要有自己的特色，能够依据相关的一些历史数据信息的特性自动选取方法模型。

2 中长期电力负荷预测单模型理论及其应用

中长期的电力系统负荷预测对电力系统规划的长远发展起着非常重要的作用,有些地区正处在快速发展时期,用电量逐渐增长,并呈现出较显著的规律,这时候通过一些简单的单模型进行负荷预测既能准确给出预测结果,又能达到方便省时的效果。

2.1 线性回归模型

在客观存在的世界中,变量之间普遍存在着一定的关系。变量之间的关系,一般可以分为确定的与非确定的两大类。确定性的关系可以用函数关系表达式来表示,而非确定性的关系则不能。

2.1.1 一元线性回归模型

一般地,若普通变量 x 和随机变量 Y 之间存在着线性关系时,可通过假设

$$Y = \beta_0 + \beta_1 x + \varepsilon, \quad (2.1)$$

$\varepsilon \sim N(0, \sigma^2)$, 其中的 β_0, β_1 是待定系数。

设 $(x_1, Y_1), (x_2, Y_2), \dots, (x_n, Y_n)$ 是从总体 (x, Y) 抽取的一组样本,而 $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ 是该样本的一组观察值,在样本与其它观察值中的 $x_1, x_2, \dots, x_n$ 是取不完全一样的数值,而其中样本中的 $Y_1, Y_2, \dots, Y_n$ 为试验前的随机变量,在试验或者观测后就成为了具体的数值,通过一次抽样的结果便可以取得 n 对的数据分别为 $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$, 则有

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad i = 1, 2, \dots, n \quad (2.2)$$

其中 $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$ 之间相互独立。在线性的模型中,依据假设可知

$$Y \sim N(\beta_0 + \beta_1 x, \sigma^2), \quad E(Y) = \beta_0 + \beta_1 x \quad (2.3)$$

回归分析就是根据样本中的观察值来求出 β_0, β_1 的估计 $\hat{\beta}_0, \hat{\beta}_1$ 。

对于给定的 x 值, 把

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 x \quad (2.4)$$

视为 $E(Y) = \beta_0 + \beta_1 x$ 的估计, 方程 (2.4) 被称作 Y 关于 x 的经验公式或者线性回归方程,

它的图像被称之为回归直线, $\hat{\beta}_1$ 被称为回归系数。

$$\begin{aligned}
 S_t &= \frac{1}{n}(x_t + x_{t-1} + x_{t-2} + \cdots + x_{t-n+1}) \\
 &= \frac{1}{n} \cdot x_t + \frac{1}{n}(x_{t-1} + x_{t-2} + x_{t-3} + \cdots \\
 &\quad + x_{t-n+1} + x_{t-n}) - \frac{1}{n} \cdot x_{t-n} \\
 &= \frac{1}{n} \cdot x_t + S_{t-1} - \frac{1}{n} \cdot x_{t-n}
 \end{aligned} \tag{2.7}$$

若时间序列是相对较平稳的，则可以修改上式为

$$S_t = \frac{1}{n}x_t + S_{t-1} - \frac{1}{n}S_{t-1} = \frac{1}{n}x_t + \left(1 - \frac{1}{n}\right)S_{t-1} \tag{2.8}$$

当 $n=1$ 时， $\frac{1}{n}=1$ ；当 $n \rightarrow \infty$ ， $\frac{1}{n} \rightarrow 0$ 。

令 $a = \frac{1}{n}$ ， a 取值在 0 与 1 之间， a 称为平滑系数。指数平滑数列的一次递推公式为：

$$S'_t = ax_t + (1-a)S'_{t-1} \tag{2.9}$$

将 (2.9) 式经过递推展开得

$$\begin{aligned}
 S'_t &= ax_t + (1-a)S'_{t-1} \\
 &= ax_t + (1-a)[ax_{t-1} + (1-a)S'_{t-2}] \\
 &= ax_t + (1-a)ax_{t-1} + (1-a)^2S'_{t-2} = \cdots \\
 &= ax_t + a(1-a)x_{t-1} + a(1-a)^2x_{t-2} + \cdots + \\
 &\quad a(1-a)^{t-1}x_1 + (1-a)^tS'_0
 \end{aligned} \tag{2.10}$$

因 $0 < a < 1$ ，则随着 i 增加， $a(1-a)^i$ 将递减，即 x_t 的权数将不断的减小，最近的值 x_t 的加权系数为 a 最大， x_{t-1} 的权数为 $a(1-a)$ ，较小；越早的数据，其权数越小。所有权数之相加为 1，即

$$\sum_{n=1}^t a(1-a)^{n-1} + (1-a)^t = 1 \tag{2.11}$$

经过“加权修匀”，最近的搜集数据对未来（预测）值的会有较大影响，最早的老数据影响会很小。

当 $a=0$ 时，将有 $S'_t = S'_{t-1} = S'_{t-2} = \cdots = S'_0$ ，这说明定出 S'_0 以后，不同时点的平滑值都等于 S'_0 ，不同时点的 x_t 不能增添影响，数列遭受了严重的修匀。

当 $a=1$ 时，得 $S'_t = x_t$ ，它说明，平滑后的数列 S'_t 和原来时间序列一样，也可以看作 t 时点 S'_t 即是 x_t ，这个也是 $t+1$ 时点的预测值。

若 a 的值取得比较大时, 修匀程度将会变得较小, 比较适于变化比较大的或者趋势性比较强的序列。

若 a 值取得较小时, 修匀程度将会变得比较大, 比较适于变化比较小的或者接近平稳的序列。

从上面的讨论可知, 一次指数平滑法非常适和比较平稳的一组时间序列, 若作短期的预测, 即可以令第 t 时点的 S'_t 值视作第 $t+1$ 时点的预测值 y_{t+1} , $y_{t+1} = S'_t$ 。

因为 a 值的选取可以有多种, 所以也可以有多方案, 原则上一般采用合理的几个 a 值试算的办法, 然后计算其均方差 MSE; 或者也可以分别计算它们的平均绝对误差 MAD, 以 MSE 或 MAD 最小的作为最好的 a 值。至于此种预测是否有效, 则能借助 χ^2 检验它的误差值 e_t 数列是不是随机的; 如果是, 则是有效的预测。

不同时点的平滑预测值 y 和实际值 x 的误差值 e_t :

$$e_t = x_t - S'_{t-1} = x_t - y_t \quad (2.12)$$

平均绝对误差 MAD:

$$\text{MAD} = \frac{1}{N} \sum_{t=1}^N |e_t| \quad (2.13)$$

2.2.1 二次指数平滑法

二次指数平滑法用的是相同的平滑系数 a , 对前面的 S'_t 再经过一次指数平滑, 这样就构成了二次指数平滑数列 S''_t 。

设原始值 $S'_0 = S''_0 = x_1$, 则有

$$\begin{aligned} S'_t &= ax_t + (1-a)S'_{t-1}, \\ S''_t &= aS'_t + (1-a)S''_{t-1} \end{aligned} \quad (2.14)$$

可知, 二次指数平滑数列 S''_t 经过对原时间序列的两次修匀, 便能将不规则或者周期变动清除, 长期的趋势性能够更好地显示出来。

和一次指数平滑法相同, 恰当的 a 值的选择, 原则上也应该选用多个 a 值进行分别计算来构成不同 a 值的数列 S'_t 和 S''_t , 则可以根据均方差 MSE 的最小确定原则选出一个比较合理的 a 值。

对时间的序列进行一次或二次指数平滑时，将更加有利于显示出数列的长期趋势，所以二次指数平滑法具有线性的趋势，其线性的趋势预测模型有：

$$y_{t+T} = a_t + b_t \cdot T \quad (2.15)$$

式中 T ——从 t 时点起向前的预测时点数；

a_t, b_t ——待定系数；

$$a_t = S'_t + (S'_t - S''_t) = 2S'_t - S''_t \quad (2.16)$$

$$b_t = \frac{a}{1-a} (S'_t - S''_t). \quad (2.17)$$

有效检验预测模型的方法，与上面所陈述的有效性检验基本上原理相同。则不同时间点的误差为

$$e_t = x_t - y_t \quad (2.18)$$

需要对 e_t 数列检验自相关，如前面所述，若 e_t 数列具有随机性，表明这个预测模型有效。

2.2.2 三次指数平滑法

当时间序列呈现非线性趋势时，可用三次指数平滑法。

设时间的序列是 $x_1, x_2, \dots, x_t$ ，取 $S'_0 = S''_0 = S'''_0 = x_1$ ；且用相同的平滑系数 a ，则用下式进行逐步计算；

$$\begin{cases} S'_t = ax_t + (1-a)S'_{t-1} \\ S''_t = aS'_t + (1-a)S''_{t-1} \\ S'''_t = aS''_t + (1-a)S'''_{t-1} \end{cases} \quad (2.19)$$

同样可利用均方差 MSE 或者 MAD 取最小的原则优选一个 a 值。

以优选的 a 值计算结果 S'_t 、 S''_t 与 S'''_t 的数列为准，末期 t 的预测数据按照下列式子计算其模型系数：

$$a_t = 3S'_t - 3S''_t + S'''_t \quad (2.20)$$

$$b_t = \frac{a}{2(1-a)^2} [(6-5a)S'_t - (10-8a)S''_t + (4-3a)S'''_t] \quad (2.21)$$

$$c_t = \frac{a^2}{2(1-a)^2} (S'_t - 2S''_t + S'''_t) \quad (2.22)$$

则二次抛物线型预测的模型为：

$$y_{t+T} = a_t + b_t \cdot T + c_t \cdot T^2 \quad (2.23)$$

式中 T ——从 t 时点算起向前的预测时点数。

有效性检测和上面所述预测数学模型的方法相同,即求出预测偏差 e_t 数列和其自相关的系数 r_k ,再利用

$$|r_k| \leq \frac{1.96}{\sqrt{N}} \quad (2.24)$$

检验,或者进行 χ^2 检验

2.3 灰色系统

灰色系统理论是一门新兴的边缘学科,它既能用于社会经济,又可应用于工业控制。灰色预测理论的本质是把无规律的一些统计数据进行累加生成,可以得到规律性较强的新生数列,然后重新建立模型,利用新生成的数学模型预测得到的数据通过累减处理得到还原模型,把此模型作为负荷预测模型。

2.3.1 灰色模型理论

(1) 灰色预测模型的原理

记有一组随时间变化没有显著规律的原始数据 $X^{(0)} = [x^{(0)}(1), x^{(0)}(2), \dots, x^{(0)}(n)]$,为了使这组时间序列数据有规律,需要对其作经过一次累加生成,即令

$$x^{(1)}(t) = \sum_{n=1}^t x^{(0)}(n) \quad (2.25)$$

进而得到新的生成数列 $X^{(1)}$, $X^{(1)} = \{x^{(1)}(1), x^{(1)}(2), \dots, x^{(1)}(n)\}$,新的生成数列 $X^{(1)}$ 一般近似地服从指数变化规律. 具体的微分方程式为

$$\frac{dx}{dt} + ax = u \quad (2.26)$$

即表示变量对于时间的一阶微分方程是连续的. 对上述微分方程进行求解,解为

$$x(t) = ce^{-a(t-1)} + \frac{u}{a} \quad (2.27)$$

当 $t=1$ 时, $x(t) = x(1)$, 即 $c = x(1) - \frac{u}{a}$, 则由上述公式便可得到离散形式的微分方程具体表达式为

$$x(t) = \left(x(1) - \frac{u}{a} \right) e^{-a(t-1)} + \frac{u}{a} \quad (2.28)$$

其中, x 是 $\frac{dx}{dt}$ 的背景值, 也可以称初始值; a 与 u 是待识别的灰色参数, 其中 a 是发展系数, 能反映 x 的发展趋势; u 是灰色作用量, 反映数据之间的变化关系.

按白化导数定义有 $\frac{dx}{dt} = \lim_{\Delta t \rightarrow 0} \frac{x(t+\Delta t) - x(t)}{\Delta t}$, 当时间密化值定义为 1 时, 即 $\Delta t \rightarrow 1$ 时, 则上式可写为 $\frac{dx}{dt} = \lim_{\Delta t \rightarrow 1} (x(t+\Delta t) - x(t))$, 这说明 $\frac{dx}{dt}$ 是一次累减生成的, 因此该式可以记为 $\frac{dx}{dt} = x^{(1)}(t+1) - x^{(1)}(t)$ 。

当 Δt 取得足够小时, 变量 x 到 $x(t)$ 到 $x(t+\Delta t)$ 是不会出现突变的情况, 因此取 $x(t)$ 与 $x(t+\Delta t)$ 的平均值作为当 Δt 足够小时的背景值, 即 $x^{(1)} = \frac{1}{2} [x^{(1)}(t) + x^{(1)}(t+1)]$ 将其值带入式子, 整理后得

$$x^{(0)}(t+1) = -\frac{1}{2}a[x^{(1)}(t) + x^{(1)}(t+1)] + u \quad (2.29)$$

根据离散形式可得到矩阵:

$$\begin{pmatrix} x^{(0)}(2) \\ x^{(0)}(3) \\ \vdots \\ x^{(0)}(n) \end{pmatrix} = a \begin{pmatrix} -\frac{1}{2}[x^{(1)}(1) + x^{(1)}(2)] \\ -\frac{1}{2}[x^{(1)}(2) + x^{(1)}(3)] \\ \dots\dots\dots \\ -\frac{1}{2}[x^{(1)}(n-1) + x^{(1)}(n)] \end{pmatrix} + u \quad (2.30)$$

$$\text{令 } Y = [x^{(0)}(2), x^{(0)}(3), \dots, x^{(0)}(n)]^T, B = \begin{pmatrix} -\frac{1}{2}[x^{(1)}(1) + x^{(1)}(2)] & 1 \\ -\frac{1}{2}[x^{(1)}(2) + x^{(1)}(3)] & 1 \\ \vdots & \vdots \\ -\frac{1}{2}[x^{(1)}(n-1) + x^{(1)}(n)] & 1 \end{pmatrix}, \alpha = (a \ u)^T,$$

称 Y 是数据向量, B 是数据矩阵, α 是参数向量。则上式可以简化为线性模型:

$$Y = B\alpha \quad (2.31)$$

根据最小二乘估计方法计算得

$$\alpha = \begin{pmatrix} a \\ u \end{pmatrix} = (B^T B)^{-1} B^T Y \quad (2.32)$$

上式便是参数 a, u 的矩阵辨识算式, 上式中 $(B^T B)^{-1} B^T Y$ 实际上是数据矩阵 B 的广义逆矩阵. 将求得的 a, u 值代入微分方程的解式, 则

$$\hat{x}^{(1)}(t) = (x(1) - \frac{u}{a})e^{-a(t-1)} + \frac{u}{a} \quad (2.33)$$

其中, 上式是 GM(1,1)模型的时间响应函数形式, 将它离散化得

$$\hat{x}^{(1)}(t) = \left(x^{(0)}(1) - \frac{u}{a} \right) e^{-a(t-1)} + \frac{u}{a} \quad (2.34)$$

对序列 $\hat{x}^{(1)}(t)$ 再作累减生成可进行预测. 即

$$\begin{aligned} \hat{x}^{(0)}(t) &= \hat{x}^{(1)}(t) - \hat{x}^{(1)}(t-1) \\ &= \left(x^{(0)}(1) - \frac{u}{a} \right) (1 - e^a) e^{-a(t-1)} \end{aligned} \quad (2.35)$$

上式便是 GM(1,1)模型的预测的具体计算式。

(2) 灰色预测模型的局限性和适用范围

灰色预测虽具有要求统计的原始数据少、不考虑变化趋势及分布规律、运算方便、易于检验等优点, 但也有其自身的局限性。

通过对比原始序列 $X_i^{(0)}$ 和模拟序列 $\hat{X}_i^{(0)}$ 进行误差分析, 如果发展系数的增大, 模拟误差也就会迅速增加. 若发展系数 $-a \leq 0.3$ 时, 模拟的精度能达到 98% 以上; 若发展系数 $-a \leq 0.5$ 时, 模拟的精度能达到 95% 以上; 若发展系数 $-a > 1$ 时, 模拟的精度要低于 70%; 若发展系数 $-a > 1.5$ 时, 模拟的精确度低于 50%。

对预测误差更进一步考虑, 若发展系数 $-a < 0.3$ 时, 1 步的预测精度在 98% 以上, 2 步到的 5 步预测精度都达到 90% 以上, 10 步预测精度也高于 80%; 若发展系数 $-a > 0.8$ 时, 1 步的预测精度已经低于 70%。

通过上述分析, 可以得到以下结论:

- ① 若 $-a \leq 0.3$ 时, 此模型适用于中长期负荷预测;
- ② 若 $0.3 < -a \leq 0.5$ 时, 此模型适用于短期负荷预测, 中长期负荷预测慎用;
- ③ 若 $0.5 < -a \leq 0.8$ 时, 作短期负荷预测应十分谨慎;
- ④ 若 $0.8 < -a \leq 1$ 时, 应采用残差修正模型;
- ⑤ 若 $-a > 1$ 时, 不宜采用此模型。

为了能够拓宽灰色模型的适用范围, 必须对改进灰色预测模型, 到目前为止, 可以从三方面进行改进: 首先, 对搜集的原始数列进行改造, 其目的是削弱异常值的影响, 尽量使统计的原始数列呈指数变化规律; 其次, 对灰色模型改进, 改进的方法种类有许

多, 列如修改参数 α , 或者使用等维新息模型, 以及把中长期负荷预测中的 a, u 作为随着时间变化的灰色递阶模型; 最后建立残差修正模型。

(3) 初始数列的改造

对初始数据的改造方法有许多种, 例如滑动平均法、指数加权法、对数变换法、二次指数平滑法、加政策因子处理法、开 n 次方变换法等。

① 滑动平均法

记初始数列为 $\{x^{(0)}(k)\}, k=1, 2, \dots, n$, 且滑动平均值公式为

$$x^{(0)}(k) = \frac{x^{(0)}(k-1) + 2x^{(0)}(k) + x^{(0)}(k+1)}{4} \quad (2.36)$$

这个公式既可以使当年的数据权重系数增加, 又能避免数据的波动较大, 两端点的计算用下面公式

$$x^{(0)}(1) = \frac{3x^{(0)}(1) + x^{(0)}(2)}{4} \quad (2.37)$$

$$x^{(0)}(n) = \frac{x^{(0)}(n-1) + 3x^{(0)}(n)}{4} \quad (2.38)$$

② 指数加权法

对初始数列 $\{x^{(0)}(k)\}$ 按下列公式

$$y^{(0)}(k) = \alpha x^{(0)}(k) + (1-\alpha)y^{(0)}(k-1) \quad (k=1, 2, \dots, n) \quad (2.39)$$

生成的新的序列 $\{y^{(0)}(k)\}$ 按指数递增, 这里要求 $\{x^{(0)}(k)\}$ 均为正, 然后运用 GM 方

法预测, 可得预测新生成序列 $\{\hat{y}^{(0)}(k)\}$, 再利用下式

$$\hat{x}^{(0)}(k) = \left[\hat{y}^{(0)}(k) - (1-\alpha)\hat{y}^{(0)}(k-1) \right] / \alpha \quad (k=1, 2, \dots, n, n+1, \dots, n+l) \quad (2.40)$$

在上面所进行的计算中, 可以根据需要, 适当调整的值 α , 达到控制预测的精度, 若 $\alpha=1$, 则为原来的 GM 方法。

③ 对数变换法

若初始数列 $\{x^{(0)}(k)\} \quad (k=1, 2, \dots, n)$ 为一组不光滑的离散数据序列, 可通过对数变换转化为 $\{\ln x^{(0)}(k)\}$, 这样初始数列的光滑度, 这样利用 GM 模型预测是误差较小, 再

利用 $\{\exp x^{(0)}(k)\}$ 还原, 这样在拓宽灰色系统预测适用范围的同时, 又提高了预测的精度。

④ 二次指数平滑法

若初始数列利用下式

$$\begin{cases} S^{(1)}(k) = \alpha x^{(0)}(k) + (1-\alpha)S^{(1)}(k-1) \\ S^{(2)}(k) = \alpha S^{(1)}(k) + (1-\alpha)S^{(2)}(k-1) \end{cases} \quad (k=1, 2, \dots, n) \quad (2.41)$$

变换后得到新的序列 $\{S^{(2)}(k)\}$, 然后利用 GM 方法对 $\{S^{(2)}(k)\}$ 预测, 便可得到预测值序列 $\{\hat{y}^{(0)}(k)\}$, 再通过下列计算式

$$\begin{cases} S^{(1)}(k) = \frac{1}{\alpha} [S^{(2)}(k) - (1-\alpha)S^{(2)}(k-1)] \\ \hat{x}^{(0)}(k) = \frac{1}{\alpha} [S^{(1)}(k) - (1-\alpha)S^{(1)}(k-1)] \end{cases} \quad (k=1, 2, \dots, n, n+1, \dots, n+l) \quad (2.42)$$

还原得到 $\{x^{(0)}(k)\}$ 。

在上面所述的计算中, 可以通过改变平滑系数 α 来实现对数据的波动的控制, 这样可以减小预测误差。

⑤ 加政策因子处理法

这种方法用于处理初始数列变化太快的数列速度变慢, 设初始数列为

$X = \{x_1, x_2, \dots, x_n\}$, 令 $X_z = \{x_{1z}, x_{2z}, \dots, x_{nz}\}$, 其中

$$X_{iz} = \frac{1}{n-i+1} (x_i + x_{i+1} + \dots + x_n) \quad (i=1, 2, \dots, n) \quad (2.43)$$

⑥ 开 n 次方变换法

基本思想是通过对 $\{x^{(0)}(k)\}$ 开 n 次方变换为新数列 $\{\sqrt[n]{x^{(0)}(k)}\}$, 把变换后的形成的新数列建立灰色模型, 最后将预测值再通过求 n 次幂进行还原。

2.3.2 灰色模型方法小结

(1) 对初始数据中波动较大的进行处理, 处理的方法要根据预测地区的实际情况来定, 同时也能利用多种理论模型方法进行对比, 从中择取出一种较高精度的预测方法。

(2) 若灰色模型的精度不能达到预测要求时, 能利用残差灰色模型再次建模。

(3) 等维新息模型除去了过时的、陈旧的数据信息, 增添补充了新数据信息, 能更大程度地反映近期的情况, 有利于精度的提高。

- (4) 在 α 还有一定的修正空间时，应选用参数的修正方法
- (5) 灰色模型与所应用的环境等因素有关。

2.4 神经网络

神经网络这门交叉学科近年来发展的十分迅速，它包含大量的处理单元构成非线性大规模的自适应动力系统。神经网络具有的特点是并行处理、分布式存储、高容错能力以及良好的自适应、自学习、联想等。到现在有多种训练算法以及网络模型被提出，其中前馈型神经网络被应用的最广。

2.4.1 BP 神经网络理论

BP 网络是一种具有单向传播功能的多层前馈网络，它含有输入层、隐含层以及输出层，如下图 2-1 所示，是现在应用比较多的一种模拟模型。




图 2-1 BP 网络结构

Figure 2-1 Structure of BP network

图中： x_j 代表输入层的第 j 个变量节点的输入， $j=1, \dots, M$ ；

w_{ij} 代表隐含层的第 i 个变量节点到输入层第 j 个变量节点间的权值；

θ_i 代表隐含层的第 i 个变量节点的阈值；

$\phi(x)$ 代表隐含层的一个激励函数；

w_{ki} 代表输出层的第 k 个变量节点到隐含层第 i 个变量节点间的权值，

$i=1, \dots, q$ ；

a_k 代表输出层第 k 个变量节点的阈值, $k=1, \dots, L$;

$\psi(x)$ 代表输出层的一个激励函数;

o_k 代表输出层第 k 个变量节点的输出。

(1) 信号前向传播过程

隐含层第 i 个变量节点的输入 net_i :

$$net_i = \sum_{j=1}^M w_{ij} x_j + \theta_i \quad (2.44)$$

隐含层第 i 个变量节点的输出 y_i :

$$y_i = \phi(net_i) = \phi\left(\sum_{j=1}^M w_{ij} x_j + \theta_i\right) \quad (2.45)$$

输出层第 k 个变量节点的输入 net_k :

$$net_k = \sum_{i=1}^q w_{ki} y_i + a_k = \sum_{i=1}^q w_{ki} \phi\left(\sum_{j=1}^M w_{ij} x_j + \theta_i\right) + a_k \quad (2.46)$$

输出层第 k 个变量节点的输出 o_k :

$$o_k = \psi(net_k) = \psi\left(\sum_{i=1}^q w_{ki} y_i + a_k\right) = \psi\left(\sum_{i=1}^q w_{ki} \phi\left(\sum_{j=1}^M w_{ij} x_j + \theta_i\right) + a_k\right) \quad (2.47)$$

(2) 误差反向传播过程

误差反向传播, 即首先利用输出层开始并逐层计算每层神经元之间的输出误差, 然后利用误差的梯度下降法来处理调节各层的权值与阈值, 使修改过后的网络输出最终能接近期望值。

取样本 p 二次型误差的准则函数是 E_p :

$$E_p = \frac{1}{2} \sum_{k=1}^L (T_k - o_k)^2 \quad (2.48)$$

系统处理 P 个训练样本中总误差的准则函数是:

$$E = \frac{1}{2} \sum_{p=1}^P \sum_{k=1}^L (T_k^p - o_k^p)^2 \quad (2.49)$$

利用误差梯度下降法来依次调节输出层权值间的修正量 Δw_{ki} , 输出层阈值间的修正量 Δa_k , 隐含层权值间的修正量 Δw_{ij} , 隐含层阈值间的修正量 $\Delta \theta_i$ 。

(3) 网络的层数

理论上已证明: 具有偏差和至少一个 S 型隐含层加上一个线性输出层的网络, 能够逼近任何有理数。增加层数可以更进一步的降低误差, 提高精度, 但同时也

使网络复杂化，从而增加了网络权值的训练时间。而误差精度的提高实际上也可以通过增加神经元数目来获得，其训练效果也比增加层数更容易观察和调整。所以一般情况下，应优先考虑增加隐含层中的神经元数。

（4）初始权值的选取

初始值对于学习是否达到局部最小、是否能够收敛及训练时间的长短关系很大，一般取初始权值在 $(-1, 1)$ 之间的随机数。下图 2-2 是 BP 算法程序的流程图：




图 2-2 BP 算法程序流程图

Figure 2-2 The flowchart of the BP algorithm program

（6）学习速率

学习速率决定每一次循环训练中所产生的权值变化量。大的学习速率可能导

致系统的不稳定；但小的学习速率导致较长的训练时间，可能收敛很慢，不过能保证网络的误差值不跳出误差表面的低谷而最终趋于最小误差值。所以在一般情况下，倾向于选取较小的学习速率以保证系统的稳定性。学习速率的选取范围在 0.01-0.8 之间。

2.4.2 神经网络方法小结

- (1) 能够模拟人类的大脑进行智能化的处理数据；
- (2) 能够自适应大量的非结构性以及非精确性规律的能力；
- (3) 具有自主学习、信息记忆、知识逻辑推理以及优化计算的优点；
- (4) 无法应用已有的数据信息来确定初始值，很容易陷入局部极小状态；
- (5) 学习的速度非常慢，很难适应突发事件；
- (6) 虽然比较适合短期的负荷预测，但经过一定的改进，也能较好的适合中长期。

2.5 模型精度检验

模型精度检验包括关联度检验、残差检验、后验差检验三种检验形式。

每一种检验都有不同的功能：关联度检验从属于几何检验的范围，通过对比模型曲线和建模序列曲线几何的相似程度来进行检验，若关联度越大，表明模型越好；残差检验从属于算术检验的范围，对模型值与实际值的误差实行逐点检验；后验差检验从属于统计方面的检验。

(1) 关联度检验

关联度目的检验过程中各变化间的差别。关联系数如果越大，表明预测值与实际值越比较接近。

设 $\hat{X}^{(0)}(t) = [\hat{x}^{(0)}(1), \hat{x}^{(0)}(2), \dots, \hat{x}^{(0)}(n)]$ ， $X^{(0)}(t) = [x^{(0)}(1), x^{(0)}(2), \dots, x^{(0)}(n)]$ ，序列的关联系数作如下定义：

$$\xi(t) = \begin{cases} \frac{\min \{|\hat{x}^{(0)}(t) - x^{(0)}(t)|\} + \sigma \max \{|\hat{x}^{(0)}(t) - x^{(0)}(t)|\}}{|\hat{x}^{(0)}(t) - x^{(0)}(t)| + \sigma \max \{|\hat{x}^{(0)}(t) - x^{(0)}(t)|\}}, & t \neq 0 \\ 1, & t = 0 \end{cases} \quad (2.50)$$

式子中， $|\hat{x}^{(0)}(t) - x^{(0)}(t)|$ 为在第 t 个点 $x^{(0)}$ 与 $\hat{x}^{(0)}$ 之间的绝对误差， $\xi(t)$ 为在第 t 个数据的关联系数， ρ 称之为分辨率， $0 < \rho < 1$ ，一般情况下取 $\rho = 0.5$ 。

$x^{(0)}(t)$ 与 $\hat{x}^{(0)}(t)$ 的关联度计算式：

$$r = \frac{1}{n} \sum_{t=1}^n \xi(t) \quad (2.51)$$

精度检验等级如下表 2-1 所示:

表 2-1 关联度精度检验等级

Table 2-1 Correlation testing of the accuracy grade

精度等级	关联度	均方差比值	小误差概率
好 (1 级)	≥ 0.90	≤ 0.35	≥ 0.95
合格 (2 级)	≥ 0.80	≤ 0.50	≥ 0.80
勉强 (3 级)	≥ 0.70	≤ 0.65	≥ 0.70
不合格 (4 级)	< 0.70	> 0.65	< 0.70

(2) 残差检验

残差差值大小的检验, 即对模型值与实际值的残差逐个进行点检验。

取模拟值的残差序列是 $e^{(0)}(t)$, 有 $e^{(0)}(t) = x^{(0)}(t) - \hat{x}^{(0)}(t)$, 令 $\varepsilon(t)$ 作为残差的相对值, 即残差的百分比:

$$\varepsilon(t) = \left[\frac{x^{(0)}(t) - \hat{x}^{(0)}(t)}{x^{(0)}(t)} \right] \% \quad (2.52)$$

令 $\bar{\Delta}$ 是平均残差, $\bar{\Delta} = \frac{1}{n} \sum_{t=1}^n |\varepsilon(t)|$. 设残差方差是 S_2^2 , 则 $S_2^2 = \frac{1}{n} \sum_{t=1}^n [e(t) - \bar{e}]^2$. 故后验

差比例 C 取 $C = S_2 / S_1$, 误差频率 P 是 $P = P \{ |e(t) - \bar{e}| < 0.6745 S_1 \}$ 。

C, P 的检验指标如下表 2-2:

表 2-2 残差精度检验等级

Table 2-2 Inspection grade residual accuracy

检验指标	好	合格	勉强	不合格
P	> 0.95	> 0.80	> 0.70	< 0.70
C	< 0.35	< 0.50	< 0.65	> 0.65

(3) 后验差检验

首先取初始的时间数列 $X^{(0)} = [x^{(0)}(1), x^{(0)}(2), \dots, x^{(0)}(n)]$ 的均值与方差分别表示为

$S_1^2 = \frac{1}{n} \sum_{t=1}^n (x^{(0)}(t) - \bar{x})^2$, 计算其数列 $e^{(0)} = [e^{(0)}(1), e^{(0)}(2), \dots, e^{(0)}(n)]$ 的均值 $\bar{e}$ 及方

差 s_2^2

$$\bar{e} = \frac{1}{n} \sum_{t=1}^n e^{(0)}(t) \quad , \quad S_2^2 = \frac{1}{n} \sum_{t=1}^n (e^{(0)}(t) - \bar{e})^2 \quad (2.53)$$

其中 $e^{(0)}(t) = x^{(0)}(t) - \hat{x}^{(0)}(t)$, $t = 1, 2, \dots, n$ 是残差数列。

然后计算其后验差比值

$$C = S_2 / S_1 \quad (2.54)$$

最后计算其小误差频率

$$P = P\{|e^{(0)}(t) - \bar{e}| < 0.6745 S_1\}$$

取 $S_0 = 0.6745 S_1$, $\Delta(t) = |e^{(0)}(t) - \bar{e}|$, 即 $P = P\{\Delta(t) < S_0\}$. 后验差模型精度表参照表 2-3:

表 2-3 后验差模型精度表

Table 2-3 A posteriori error model accuracy

P	C	模型精度
>0.95	<0.35	优
>0.80	<0.5	合格
>0.70	<0.65	勉强合格
<0.70	>0.65	不合格

2.6 单模型的应用效果

(1) 应用背景

以单灰色模型的预测理论为基础, 选取某一个地区电力系统从 1998 年到 2010 年的年总用电量作为处理分析的数据, 具体数据见表 2-4。

表 2-4 某地区 1998 到 2010 年负荷数据 (单位: $\text{MkW} \cdot \text{h}$)

Table 2-4 Load date of certain area from 1998 to 2010 (unit: $\text{MkW} \cdot \text{h}$)

年 份	用电量	年 份	用电量
1998	141.910	2005	180.699
1999	146.674	2006	187.998
2000	151.807	2007	195.756

年 份	用电量	年 份	用电量
2001	156.285	2008	202.875
2002	162.771	2009	210.843
2003	168.087	2010	218.102
2004	174.144		

(2) 建立模型，实现预测

依据灰色理论,运用建立的模型对未来的负荷进行预测,得到 GM(1,1)模型的发展系数 $a = -0.0361$, 灰作用为 $u = 138.1998$, 可以得到 $\frac{u}{a} = -3829.8021$, 预测的模型方程为:

$$\hat{x}^{(0)}(t) = 140.8358e^{0.0361(t-1)} \quad (2.55)$$

根据公式 (2.62) 能够得出灰色模型的预测负荷以及与原始数据的相对误差如下表 2-5。

表 2-5 GM(1,1)模型的预测值 (单位: MkW · h)

Table 2-5 GM (1,1) model to predict the value (unit: MkW · h)

年 份	实际值	预测值	残差	相对误差绝对值/ (%)
1998	141.910	140.836	-1.074	0.757
1999	146.674	146.013	-0.661	0.451
2000	151.807	151.380	-0.427	0.281
2001	156.285	156.945	0.660	0.422
2002	162.771	162.714	-0.057	0.035
2003	168.087	168.695	0.608	0.362
2004	174.144	174.897	0.753	0.432
2005	180.699	181.326	-0.627	0.347
2006	187.998	187.991	-0.007	0.004
2007	195.756	194.902	-0.854	0.436
2008	202.875	202.066	-0.809	0.399
2009	210.843	209.494	-1.349	0.640
2010	218.102	217.195	-0.907	0.416

(3) 精度检验

根据残差检验方法中 ε 以及后验差值检验方法中的 C 与 P 三个综合指标对 GM(1,1) 模型进行检验见表 2-6

表 2-6 精度检验结果

Table 2-6 test results accuracy

模型种类	ε	C	P	精度等级
GM(1,1)模型	0.004	0.108	1	1 级 (好)

(4) 预测结论

残差检验方法中的最大相对残差误差 ε 很小, 后验差检验方法中灰色模型 $C < 0.35$, $P = 1$, 实现了精度等级 1 级“好”, 说明 GM(1,1)模型在曲线拟合与预测结果方面有良好的效果, 精度达到要求。

(5) 预测 2011 到 2020 年的负荷

由于本模型误差较小, 能很好的反映出当地负荷的实际情况, 所以可根据上面公式中提到的模型公式推出未来 10 年的负荷总量见表 2-7。

表 2-7 某地区 2011 到 2020 年负荷预测数据 (单位: $\text{MkW}\cdot\text{h}$)Table 2-7 Load date of certain area from 2011 to 2020 (unit: $\text{MkW}\cdot\text{h}$)

年 份	实际值	年 份	实际值
2011	225.1788	2016	269.7228
2012	233.4562	2017	279.6377
2013	242.0380	2018	289.9170
2014	250.9352	2019	300.5742
2015	260.1594	2020	311.6232

2.7 本章小结

中长期负荷预测的单模型原理比较容易, 模型比较简单, 能够快速的给出负荷预测的结果, 综合分析当地多年的负荷使用状况以及电力特点, 合理的选出最佳负荷预测的单模型, 能在符合精度等级要求的同时, 又能达到人们满意的预测效果, 但是波动大、规律性弱的电力系统单模型已很难适应。

3 中长期电力负荷预测改进模型理论及其应用

在现代的电力系统中,电力系统整体上表现出增长的趋势,许多地区的负荷并不能呈现出一定的变化规律,所以未经过改进的单一指数平滑模型、灰色模型以及神经网络模型预测的精度会非常低,下面简单介绍一下几种改进模型的原理,以改进残差灰色模型为例,说明当单一模型无法很好预测过大波动的负荷时,经过模型的改进可以提高预测的精度。

3.1 改进的指数平滑模型

传统的指数变化法只能适用于负荷变化不是太大而是相对比较平稳的时间序列,如果时间序列上面的预测值发生较大变化时,特别是有突然地变化时,预测的结果会很不理想,有可能在很长的一段时间都不能与实际的数据达到一个比较吻合的状态,为了能够使这类的问题得到解决,可以引进一种追踪信号来实现对时间序列的跟踪,如果追踪的信号一旦反映出在预测的过程中出现了大的系统偏差现象,就可以通过重现调整平滑常数来实现减少系统误差的目的,这样就是说平滑值是随着时间序列的实际的观测值的变化而随之变化的,不再像前面提到过的指数平滑值是一个固定不变的常数。

改进算法的步骤有以下几步:

(1) t 年值时刻的预测平滑误差

$$E_t = \beta e_t + (1 - \beta)M_{t-1} \quad (3.1)$$

上述公式中 e_t 为 t 年预测值的误差, E_t 为 $t-1$ 年预测值的平滑误差, β 是用来计算推导平滑的误差,其中第二种平滑常数通常取 0.1 或者 0.2。

(2) 计算出 t 年值时刻的预测绝对平滑的误差

$$E_t = \beta |e_t| + (1 - \beta)M_{t-1} \quad (3.2)$$

上述公式中 M_{t-1} 为 $t-1$ 年预测值的绝对平滑误差。

(3) 追踪信号的计算

$$T_t = E / M_t \quad -1 \leq T_t \leq 1 \quad (3.3)$$

(4) t 年预测值的平滑参数 α 的计算

当采用这样的一种模型时,在实际的计算中,平滑参数 α 的值将会随着预测值的变化而变化,系统的误差 T_t 绝对值随着 t 的数值增大而变大,也就是使近期的观测值前面的权重增加,因而达到使预测值能够更快地与时间序列的改变相适应,如果两者能够很

好地适应后,平滑误差也就会变得很小,便有跟踪信号 T_t 的绝对值也会减小,进而有利于减少预测过程中的误差。

$t+1$ 年预测值的计算

$$F_{t+1} = \alpha_t X_t + (1 - \alpha) F_t \quad (3.4)$$

如果实际的原始时间序列能被预测值很好地反映,这时的平滑误差就会很小,跟踪信号值就会比较接近零,相反,若预测的结果存在较大的系统误差,跟踪信号的取值将会与-1或者1接近。

3.2 改进的灰色模型

有时某些地区的负荷变动较大,并不能呈现出一定的变化规律,这样会导致灰色模型失效,有时陈旧的信息对中长期的负荷预测没有太大的意义,这时候就需要从收集的数据中去除增加新的信息,以便能使预测的精度更高,所以灰色模型有时需要改进,改进的种类主要有以下几种。

(1) 改进的残差灰色模型

若初始数据时间序列建立的 GM(1,1)模型检验满足要求时,可以使用 GM(1,1)残差模型来修正. 若初始序列建立的 GM(1,1)模型不足够精确,同样也可以使用 GM(1,1)残差模型来提高预测的精度。

若用初始序列 $X^{(0)}$ 建立的 GM(1,1)模型

$$\hat{x}^{(1)}(t+1) = [x^{(0)}(1) - \frac{u}{a}]e^{-at} + \frac{u}{a} \quad (3.5)$$

可以获得新生成的序列 $X^{(1)}$ 的预测值,定义残差序列 $e^{(0)}(k) = x^{(0)}(k) - \hat{x}^{(0)}(k)$. 如果取 $k=t, t+1, \dots, n$, 则所对应的残差序列是 $e^{(0)}(k) = \{e^{(0)}(1), e^{(0)}(2), \dots, e^{(0)}(n)\}$, 计算其生成的残差序列 $e^{(1)}(k)$, 并由此建立起相应的 GM(1,1)模型

$$\hat{e}^{(1)}(t+1) = [e^{(0)}(1) - \frac{u_e}{a_e}]e^{-a_e k} + \frac{u_e}{a_e} \quad (3.6)$$

得到修正模型

$$x^{(1)}(t+1) = \left[x^{(0)}(1) - \frac{u}{a} \right] e^{-ak} + \frac{u}{a} + \delta(k-t)(-a_e) \left[e^{(0)}(1) - \frac{u_e}{a_e} \right] e^{-a_e k} \quad (3.7)$$

其中 $\delta(k-t) = \begin{cases} 1 & k \geq t \\ 0 & k \leq t \end{cases}$ 为修正参数。

应用此模型时需要考虑：一般只是使用局部残差数据来建立模型，修正模型所代表的是差分微分方程，其修正作用与 $\delta(k-t)$ 中的 t 的取值有关。

改进模型的关键是把残差的数列绝对值视为初始数列的模型，然后利用马尔可夫这个过程来获取残差预测值的符号，令残差 $e^{(0)}(k) = x^{(0)}(k) - \hat{x}^{(0)}(k)$ ，其余的同理，可以得到改进后的模型是

$$\hat{x}^{(0)}(k+1) = (1 - e^{-a}) \left(x^{(0)}(1) - \frac{u}{a} \right) e^{-a} + m(k+1) \hat{e}^{(0)}(k+1) \quad (3.8)$$

其中的符号函数 $m(k)$ 是

$$m(k) = \begin{cases} 1 & x^{(0)}(k) - \hat{x}^{(0)}(k) \geq 0 \\ -1 & x^{(0)}(k) - \hat{x}^{(0)}(k) < 0 \end{cases} \quad (3.9)$$

由此可知，能够正确的预测 $k \geq n$ 时符号 $m(k)$ 的值成为了预测的关键，这时就需要引入马尔可夫的过程。

马尔可夫链的分析法是以概率论和随机理论为基础，依据随机的数学模型来处理客观对象发展变化中的数量关系，是一种统计分析的方法，它可以比较方便地确定出不同状态间的相互转移概率。

(2) 等维新息模型

传统的灰色模型利用陈旧的原始数据进行中长期负荷预测必然会产生较大的误差，为了将未来的一些因素考虑进来，需要将新产生的每一个数据加入到原始数列当中，重新建立 GM(1,1)，这就是新息模型，如果随着时间的向后推移，陈旧数据的意义就降低很多，所以要每次补充新信息的同时，去除掉前面最老的一个数据，以保持这组数据序列的维数，这样形成的模型就是等维新息模型。

设原始数列为 $X^{(0)} = [x^{(0)}(1), x^{(0)}(2), \dots, x^{(0)}(n)]$ ，作等维新息处理后便可得到 $X^{(0)} = [x^{(0)}(2), x^{(0)}(3), \dots, x^{(0)}(n+1)]$

(3) 参数修正模型

前面已经提及，发展系数对灰色模型的预测精度有很大影响，并不能简单的直接令 $\alpha = 0.5$ ，如果 α 比较大的时候，必须对 α 进行计算修正，所以提出了 α 的参数修正模型。

具体的计算算法如下：

对初始的时间数据序列 $X^{(0)} = [x^{(0)}(1), x^{(0)}(2), \dots, x^{(0)}(n)]$ 进行 1—GAO 处理后得

$X^{(1)} = [x^{(1)}(1), x^{(1)}(2), \dots, x^{(1)}(n)]$, 其中

$$x^{(1)}(k) = \sum_{i=1}^k x^{(0)}(i) \quad (k=1, 2, \dots, n) \quad (3.10)$$

由此得到的序列 $Z^{(1)} = [z^{(1)}(1), z^{(1)}(2), \dots, z^{(1)}(n)]$ 变为

$$z^{(1)}(k) = \alpha x^{(1)}(k-1) + (1-\alpha)x^{(1)}(k) \quad (k=2, 3, \dots, n) \quad (3.11)$$

在第一次处理计算时可以取 $\alpha=0.5$, 取白化的微分方程为

$$\frac{dx}{dt} + \alpha x^{(1)} = u \quad (3.12)$$

然后运用最小二乘法求出其中的未知参数 a 和 u 。

$$\alpha = \begin{pmatrix} a \\ u \end{pmatrix} = (B^T B)^{-1} B^T Y, \quad B = \begin{pmatrix} -z^{(1)}(2) & 1 \\ -z^{(1)}(3) & 1 \\ \vdots & \vdots \\ -z^{(1)}(n) & 1 \end{pmatrix}$$

则 $x^{(1)}$ 的灰色理论预测模型应为

$$x^{(1)}(k+1) = \left[x^{(0)}(1) - \frac{u}{a} \right] e^{-ak} + \frac{u}{a} \quad (k=0, 1, 2, \dots) \quad (3.13)$$

则 $x^{(0)}$ 的灰色理论预测模型应为

$$\hat{x}^{(0)}(k+1) = (1 - e^{-a}) \left(x^{(0)}(1) - \frac{u}{a} \right) e^{-a} \quad (k=0, 1, 2, \dots) \quad (3.14)$$

将计算得到的参数 α 代入 $\alpha = \frac{1}{\alpha} - \frac{1}{e^a - 1}$, 再次计算 α , 另记作为 $\alpha(m+1)$ 。

然后将 $\alpha(m+1)$ 和 $\alpha(m)$ 进行计算比较, 若 $|\alpha(m+1) - \alpha(m)|$ 比给定的阈值大, 则说明 α 仍有可修正的空间, 能再进一步提高预测的精度。

(4) GM(1,N)模型的建立

若系统中含有多个相关的变量, 数据序列的一阶差分并且都大于零, 将会有具有显著的上升趋势, 这样就能够利用多变量的模型 GM(1,N)来进行建模分析。

取 $X_1^{(0)} = (X_1^{(0)}(1), X_1^{(0)}(2), \dots, X_1^{(0)}(n))$ 作为系统的特征数据序列, 然而

$$\begin{aligned} X_2^{(0)} &= (X_2^{(0)}(1), X_2^{(0)}(2), \dots, X_2^{(0)}(n)) \\ X_3^{(0)} &= (X_3^{(0)}(1), X_3^{(0)}(2), \dots, X_3^{(0)}(n)) \\ &\dots \qquad \dots \\ X_N^{(0)} &= (X_N^{(0)}(1), X_N^{(0)}(2), \dots, X_N^{(0)}(n)) \end{aligned}$$

作为相关的影响因素序列, $X_i^{(1)}$ 是 $X_i^{(0)}$ 的 1-AGO 序列 ($i=1, 2, \dots, N$), $Z_1^{(1)}$ 是 $X_1^{(1)}$ 的紧邻均值处理生成的新序列, 则称

$$x_1^{(0)}(k) + az_1^{(1)}(k) = \sum_{i=2}^N b_i x_i^{(1)}(k) \quad (3.15)$$

这就是 GM(1,N) 模型。

在 GM(1,N) 模型中, a 被称作为系统发展的系数, $b_i x_i^{(1)}(k)$ 被称作为驱动项, b_i 被称作为驱动系数, $\hat{a} = [a, b_1, b_2, \dots, b_N]^T$ 被称作为参数列。

上述 $X_1^{(0)}$ 作为系统特征时间序列, $X_i^{(0)}$ ($i=2, 3, \dots, N$) 作为相关的影响因素序列, $X_i^{(1)}$ 是 $X_i^{(0)}$ 的 1-AGO 序列, $Z_1^{(1)}$ 是 $X_1^{(1)}$ 的紧邻均值处理生成的新序列, 则

$$B = \begin{bmatrix} -z_1^{(1)}(2) & x_2^{(1)}(2) & \dots & x_N^{(1)}(2) \\ -z_1^{(1)}(3) & x_2^{(1)}(3) & \dots & x_N^{(1)}(3) \\ \vdots & \vdots & \ddots & \vdots \\ -z_1^{(1)}(n) & x_2^{(1)}(n) & \dots & x_N^{(1)}(n) \end{bmatrix}, \quad Y = \begin{bmatrix} x_1^{(0)}(2) \\ x_1^{(0)}(3) \\ \vdots \\ x_1^{(0)}(n) \end{bmatrix}$$

则 $\hat{a} = [a, b_1, b_2, \dots, b_N]^T$ 的最小二乘估计需要满足下列计算

$$\hat{a} = (B^T B)^{-1} B^T Y$$

(3.16) 令 $\hat{a} = [a, b_1, b_2, \dots, b_N]^T$, 则称

$$\frac{dx^{(1)}}{dt} + ax_1^{(1)} = b_2 x_2^{(1)} + b_3 x_3^{(1)} + \dots + b_N x_N^{(1)} \quad (3.17)$$

式 (3.17) 是 GM(1,N) 模型 $x_1^{(0)}(k) + az_1^{(1)}(k) = b_2 x_2^{(1)}(k) + b_3 x_3^{(1)}(k) + \dots + b_N x_N^{(1)}(k)$ 的影子方程, 也称白化方程. 根据 $\hat{a} = [a, b_1, b_2, \dots, b_N]^T = (B^T B)^{-1} B^T Y$, 则白化方程

$\frac{dx^{(1)}}{dt} + ax_1^{(1)} = \sum_{i=2}^N b_i x_i^{(1)}$ 由差分法进行离散, 得到的解为

$$\begin{aligned}
x_1^{(1)}(t) &= e^{-at} \left[\sum_{i=2}^N \int b_i x_i^{(1)}(t) e^{at} dt + x_1^{(1)}(0) - \sum_{i=2}^N \int b_i x_i^{(1)}(0) dt \right] \\
&= e^{-at} \left[x_1^{(1)}(0) - t \sum_{i=2}^N b_i x_i^{(1)}(0) + \sum_{i=2}^N \int b_i x_i^{(1)}(t) e^{at} dt \right]
\end{aligned} \quad (3.18)$$

若 $X_i^{(1)} (i=2,3,\dots,N)$ 变化幅度很小时, 可视 $\sum_{i=2}^N b_i x_i^{(1)}(k)$ 为灰常量, 则 GM(1,N)模型

$x_1^{(0)}(k) + az_1^{(1)}(k) = \sum_{i=2}^N b_i x_i^{(1)}(k)$ 的近似响应时间式为 ($x_1^{(1)}(0)$ 取为 $x_1^{(0)}(1)$)

$$\hat{x}_1^{(1)}(k+1) = (x_1^{(1)}(0) - \frac{1}{a} \sum_{i=2}^N b_i x_i^{(1)}(k+1))e^{-ak} + \frac{1}{a} \sum_{i=2}^N b_i x_i^{(1)}(k+1) \quad (3.19)$$

经过作累减还原处理得式

$$\hat{x}_1^{(0)}(k+1) = a^{(1)} \hat{x}_1^{(1)}(k+1) = \hat{x}_1^{(1)}(k+1) - \hat{x}_1^{(1)}(k) \quad (3.20)$$

则 GM(1,N)模型的模拟式表示为

$$\hat{x}_1^{(0)}(k) = -az_1^{(1)}(k) + \sum_{i=2}^N b_i \hat{x}_i^{(1)}(k) \quad (3.21)$$

(5) 灰色模型群的建立

建立灰色模型群的主要思想是, 从不同的角度、不同的方面创建多个模型, 同一时间进行对比预测, 这样方便验证。从细的方面来说, 首先先确定主系统的研究对象, 分析其所含的部门及行业的相关情况, 适当归类, 形成若干个子系统, 构成多个 GM(1,1)模型。其次, 运用关联分析法, 找出变量的主要因素, 创建 GM(1,N)模型。再次, 创建主系统和各个子系统的混合模型, 最后, 将上面所综述的多个不同模型进行预测, 加以定性分析, 协调综合, 最终确定出恰当的预测区间。

3.3 改进的神经网络模型

(1) 附加动量法

附加动量法在进行网络修正它的权值系数时, 不仅要充分考虑误差作用在梯度上的效果, 而且还要考虑误差曲面上发生变化趋势的影响。若不存在附加动量的辅助作用, 网络很有可能陷入一种浅的局部极小值状态, 若是采用附加动量方法, 通过它的作用, 模型很大程度能滑过这其中的极小值。

这种方法是利用在反向传播方法的基础上同时又在每一个模型的权值的变化上附加上于前一项正比变化量的值, 并依据反向传播方法来计算出一些新的权值系数的变化。

附加动量因子权值与阈值调节的公式为:

$$\Delta w_{ij}(k+1) = (1-mc)\eta\delta_i p_j + mc\Delta w_{ij}(k) \quad (3.22)$$

$$\Delta b_i(k+1) = (1-mc)\eta\delta_i + mc\Delta b_i(k) \quad (3.23)$$

上面公式中的 k 是训练的次数， mc 是动量因子，取值一般在 0.95 左右。

附加动量方法的本质是利用最后一次的权值变化影响，通过附加一个动量的因子来实现传递。动量因子的取值是零的时候，权值的变化仅仅是依据梯度下降方法产生的；当动量因子的取值是 1 时，新权值的变化则是应用最后一次的权值变化，但是忽略了梯度法所产生变化的部分。利用此种方式，若增加了动量项以后，将促进权值调节朝着误差曲面的底部平均方向上发生变化，若网络得权值进入误差曲面得底部平坦区域时， δ_i 将会变得非常小，便有了 $\Delta w_{ij}(k+1) = \Delta w_{ij}(k)$ ，进而防止出现 $\Delta w_{ij} = 0$ 的情况，这样很有利于使网络从误差的曲面局部极小值状态中滑出。

依据附加动量方法的一些设计原则，若修正的权值会导致误差过大的增长结果的时候，新的权值也应该被确定取消而不是被采用，并相应的使动量方法不起作用，目的使网络模型不要进入较大的误差曲面；若新误差的变化率相对其以前的旧值超过提前设定最大误差的变化率时，也需要取消其所推算出的权值变化。其最大误差的变化率可以取任何大于等于 1 的数。典型的可以取 1.04。因此，在利用附加动量方法的训练一些程序设计的时候，必须依据加进的条件来判断，以达到能够正确运用其权值的修正公式。

训练的程序设计中运用动量方法的判断条件是：

$$mc = \begin{cases} 0 & E(k) > E(k-1) * 1.04 \\ 0.95 & E(k) < E(k-1) \\ mc & \text{其它} \end{cases}, \quad E(k) \text{ 是第 } k \text{ 步误差的平方和} \quad (3.24)$$

(2) 自适应的学习速率

对于每一个特定的问题，想选择适当的学习速率并不是一件非常容易的事情。通常需要凭借着经验与实验获取，但是即使通过这种方法，一些初期看起来功效比较好的学习速率，并不一定适合后来的训练。为了能够处理这样的问题，人们便很自然地想到在训练的过程中，通过自动调节来改变学习的速率。通常自动的调节学习速率准则是：检查其权值是不是真的一定程度上降低了误差函数，若确实如此，就表明了所选取的学习速率小了，可以恰适的增加一个量；若情况不同，而是产生了过调，就应该用减慢学习速率的方法。下面的式子列出了自动调节适应学习的速率调整公式：

$$\eta(k+1) = \begin{cases} 1.05\eta(k) & E(k+1) < E(k) \\ 0.7\eta(k) & E(k+1) > 1.04E(k) \\ \eta(k) & \text{其它} \end{cases}, \quad E(k) \text{ 是第 } k \text{ 步误差的平方和} \quad (3.25)$$

初始学习的速率 $\eta(0)$ 的取值范围存在很大的随意性。

(3) 动量-自适应学习速率调整算法

当运用前面所述的动量方法时, BP 算法能够找到全局的最优解, 而若采用自适应的学习速率方法时, BP 算法能够缩短训练的时间, 运用上述的两种方法都可以用来对神经网络进行训练, 这种方法也被称之为动量-自适应学习速率调整算法。

3.4 改进模型的应用效果

(1) 应用背景

以北方某地区 1995 年到 2002 年的历史用电量为背景, 利用改进残差灰色模型与传统灰色模型进行预测, 然后对比分析, 用电量见表 3-1:

表 3-1 某地区 1995 年到 2002 年的用电量 (单位: 亿 kW·h)

Table 3-1 electricity consumption of certain area from 1995 to 2002 (unit: 10^8 kW h)

年 份	用电量	年 份	用电量
1995	178.99	1999	211.19
1996	189.82	2000	234.05
1997	193.21	2001	247.94
1998	192.57	2002	274.39

(2) 建立模型, 实现预测

依据统计的用电量数据, 利用传统灰色模型得到的预测方程是

$$\hat{x}^{(0)}(1) = 178.99 \quad (3.26)$$

$$\hat{x}^{(0)}(k+1) = 2554.98(1 - e^{-0.067442})e^{0.067442k} \quad k = 1, 2, \dots, n \quad (3.27)$$

依据统计的用电量数据, 利用改进残差灰色模型得到的预测方程是

$$\hat{x}^{(0)}(1) = 178.99 \quad (3.28)$$

$$\hat{x}^{(0)}(k+1) = 2554.98(1 - e^{-0.067442})e^{0.067442k} + m(k+1)\hat{e}^{(0)}(k+1) \quad k = 1, 2, \dots, n \quad (3.29)$$

根据公式 (3.26) 到 (3.29) 能够得出 GM(1,1) 模型与改进残差灰色模型的预测值, 计算结果如表 3-2, 表 3-3, 仿真对比图见 3-1。

表 3-2 GM(1,1)模型的预测值 (单位: 亿 kW · h)

Table 3-2 GM (1,1) model to predict the result (unit: $10^8 \text{kW} \cdot \text{h}$)

年份	原始数据	预测值	残差	相对误差绝对值/ %	最终精度/%
1995	178.99	178.99	0.00	0.00	100.00
1996	189.82	178.26	11.56	6.09	93.91
1997	193.21	190.69	2.52	1.30	98.70
1998	192.57	204.00	-11.43	5.94	94.06
1999	211.19	218.23	-7.04	3.33	96.67
2000	234.05	233.46	0.59	0.25	99.75
2001	247.94	249.75	-1.81	0.73	99.27
2002	274.39	267.17	7.22	2.81	97.19

表 3-3 改进残差灰色模型的预测值 (单位: 亿 kW · h)

Table 3-3 improved residual grey model predicted result (unit: $10^8 \text{kW} \cdot \text{h}$)

年份	原始数据	预测值	残差	相对误差绝对值/ %	最终精度/%
1995	178.99	178.99	0.00	0.00	100.00
1996	189.82	189.82	0.00	0.00	100.00
1997	193.21	197.04	3.83	1.98	98.02
1998	192.57	197.23	4.66	2.41	97.59
1999	211.19	211.02	0.17	0.08	99.92
2000	234.05	241.15	7.10	0.13	99.87
2001	247.94	241.55	6.39	3.03	96.97
2002	274.39	275.91	1.51	0.55	99.45




图 3-1 灰色模型与改进残差灰色模型仿真效果

Figure 3-1 grey model and improved residual grey model simulation results

(3) 精度检验

根据残差检验方法中 ε 以及后验差值检验方法中的 C 与 P 以及关联度四个综合指标对 GM(1,1)与改进残差灰色模型进行检验对比见表 3-3

表 3-3 两种模型精度对比

Table 3-3 Contrast of precision of two models

模型种类	ε	C	P	关联度
GM(1,1)模型	0.21	0.0372	0.95	0.9170
残差改进模型	0.11	0.0108	0.99	0.9934

(4) 预测结论

由表 3-3 可以看出，残差改进模型的精度要明显优于传统的灰色模型，所以当有时候初始数据不具有显著地规律时，可以利用残差来找其规律，再加之改进，会得到更好的预测效果。

3.5 本章小结

单一的模型虽然有原理简单，编程容易的特点，但是它的应用有确着很大的局限性，当电力系统的某些地区负荷增长不能进行简单的预处理的话，必须经过模型的改进才能使数据呈现出一定的特点，这样能使预测的精度更高一点，满足要求。

4 中长期电力负荷预测模型综合理论与应用

近些年来电力行业快速发展,随之出现了大量新的用电设备,电力系统的负荷呈现新的特点,有时传统的单一模型预测效果已很难适应现代电力的发展,所以针对这种现状,研究除了许多新的综合模型来处理这种问题,下面以灰色模型和 BP 神经网络的综合为例,说明此综合模型的优点。

4.1 灰色模型与 BP 神经网络的综合

灰色模型虽然有要求数据少的优点,但是对没有系统变化规律的离散数据预测的精度很低, BP 神经网络可以对原来的历史数据进行较好的拟合,但其预测的外推性较差,但两者相结合,该方法可以充分发挥灰色模型利用少数初始数据建模的特点和神经网络精度可以控制的优点,来提高中长期的负荷预测。实现这种方法的步骤和算法如下:

4.1.1 灰色模型和 BP 神经网络的优化

根据灰色模型在时间序列 t 时刻的取值为

$$\begin{aligned} y^{(0)}(t) &= \hat{x}^{(0)}(t) = \hat{x}^{(1)}(t) - \hat{x}^{(1)}(t-1) \\ &= \left(x^{(0)}(1) - \frac{a}{b} \right) (1 - e^a) e^{-a(t-1)} \end{aligned} \quad (4.1)$$

因此从拟合的角度出发,可以利用上式(4.1)来拟合出原始的离散数据序列,估计出公式中的参数 a 与 b 是关键,依据数据拟合的参数估计一般的评价准则,函数误差做如下定义

$$\frac{1}{2n} \sum_{t=1}^n (y^{(0)}(t) - x^{(0)}(t))^2 \quad (4.2)$$

将上式(4.1)变形为下式:

$$y^{(0)}(t) = \left[\left(x^{(0)}(1) - \frac{a}{b} \right) (1 - e^a) - \left(x^{(0)}(1) - \frac{a}{b} \right) \frac{1}{1 + e^{-a(t-1)}} + \left(x^{(0)}(1) - \frac{a}{b} \right) e^a \frac{1}{1 + e^{-a(t-1)}} \right] (1 + e^{-a(t-1)}) \quad (4.3)$$

上式(4.3)映射到 BP 神经网络,网络的结构如下图 4-1:




图 4-1 灰色神经网络结构

Figure 4-1 grey neural network structure

其中的网络权值和灰色参数对应关系如下

$$\begin{aligned}\omega_{11} &= a, \omega_{21} = \frac{b}{a} - x^{(0)}(1) \\ \omega_{22} &= (x^{(0)}(1) - \frac{b}{a})e^a \\ \omega_{31} &= \omega_{32} = 1 + e^{-a(t-1)}\end{aligned}\quad (4.4)$$

$y^{(0)}(t)$ 的阈值可设为:

$$\theta = (1 + e^{-a(t-1)})\left(\frac{b}{a} - x^{(0)}(1)\right)(1 - e^a) \quad (4.5)$$

取 LB 层的神经元传递函数为 $f(x) = \frac{1}{1 + e^{-x}}$, 其它层的神经元传递函数可取成线性

的函数 $f(x) = x$, 由图 4-1 可知, 上面所述的方法将灰色模型完整的映射到了 BP 神经网络, 该网络的权值与灰色模型的灰色微分方程参数有着对应的关系, 网络的模型结构相对简单, 可以应用灰色系统的可知数据实现对 BP 神经网络的训练, 若 BP 神经网络处于收敛的时候, 可获得网络的权值, 进一步可得到优化过的灰色参数。

4.1.2 灰色 BP 网络模型的优化算法

(1) 选用两个比较小的值选为 a, b 的初值, 对其中的样本 $x^{(0)}(t)$ 定义误差函数

$$e = \frac{1}{2}(y^{(0)}(t) - x^{(0)}(t))^2, t = 1, 2, \dots, n \quad (4.6)$$

给定需要的计算精度 ε 以及最大的学习次数为 M 。

(2) 依据网络的权值定义可计算 $\omega_{11}, \omega_{21}, \omega_{22}, \omega_{31}, \omega_{32}$ 。

(3) 对每一个样本 $(t-1, x^{(0)}(t)), t = 1, 2, \dots, n$, 可进行下面操作, 实现前推回馈的过程:

① 将 $t-1$ 输入到 LA 层的节点, 依次从前往后对 LB, LC, LD 层节点之间输出计算如下:

$$\text{LB 层: } d = f(\omega_{11}(t-1)) = \frac{1}{1 + e^{-\omega_{11}(t-1)}} \quad (4.7)$$

$$\text{LC 层: } c_1 = d\omega_{21}, c_2 = d\omega_{22} \quad (4.8)$$

$$\text{LD 层: } y^{(0)}(t) = \omega_{31}c_1 + \omega_{32}c_2 \quad (4.9)$$

② 从后往前, 求出误差函数对每个神经元偏导数, 根据 LD 层的传递函数 $f(x) = x$,

$f'(x)=1$ ，所以 LD 层的神经元偏导数是：

$$\delta = f'(y^{(0)}(t))(y^{(0)}(t) - x^{(0)}(t)) = y^{(0)}(t) - x^{(0)}(t) \quad (4.10)$$

LC 层的传递函数是 $f(x) = x$ ，所以误差函数的 LC 层两个神经元偏导数是：

$$\delta_1 = f'(c_1)\delta\omega_{31} = \delta(1 + e^{-a_{11}(t-1)}) \quad (4.11)$$

$$\delta_2 = f'(c_2)\delta\omega_{32} = \delta(1 + e^{-a_{11}(t-1)}) \quad (4.12)$$

LB 层的传递函数是 $f(x) = \frac{1}{1 + e^{-x}}$ ，所以误差函数对其中的神经元偏导数是：

$$\delta_3 = f'(d)(\delta_1\omega_{21} + \delta_2\omega_{22}) = \frac{1}{1 + e^{-a_{11}(t-1)}}(1 - \frac{1}{1 + e^{-a_{11}(t-1)}})(\delta_1\omega_{21} + \delta_2\omega_{22}) \quad (4.13)$$

③ 调整 LB 与 LC 之间的连接权值：

$$\omega_{31}(t) = \omega_{31}(t-1) - \mu\delta_1d \quad (4.14)$$

$$\omega_{32}(t) = \omega_{32}(t-1) - \mu\delta_2d \quad (4.15)$$

④ 调整 LA 层与 LB 层之间的连接权值：

$$\omega_{11}(t) = \omega_{11}(t-1) - \alpha(t-1)\delta_3 \quad (4.16)$$

上式中， α 是学习率，取值在 (0,1) 之间。

⑤ 调整阈值 $\begin{cases} \omega_{11} = a \\ \omega_{22} = (x^{(0)}(1) - \frac{b}{a})e^a \end{cases}$ 来获得 LD 层的神经元阈值的调整公式：

$$\theta = -(1 + e^{-a_{11}(t-1)})\omega_{22}e^{-a_{11}}(1 - e^{a_{11}}) \quad (4.17)$$

(4) 计算总的误差

$$\frac{1}{2n} \sum_{t=1}^n (y^{(0)}(t) - x^{(0)}(t))^2 \quad (4.18)$$

(5) 根据误差公式来判断网络的误差能否达到设定的要求，若 $E < \varepsilon$ ，或者学习的数比设定最大的次数 M 大，则算法结束，否则的话，将重复步骤(4.2)，一直到全部的 $t(t=1,2,\dots,n)$ 都达到要求。

应用上面所述的算法，可以将误差的函数式(4.2)最小化，获得初始数列的灰色预测值，符合模型的拟合评价准则，不仅在方法上避开了灰色模型微分方程参数的辨识选取背景值问题，并且还不用对初始数据进行处理累加生成，网络在训练的过程中，权值在不断的修正过程中也是在灰参数不断求精的过程，灰色模型在这个过程中的预测能力会

得到不断加强。

4.2 综合模型的应用效果

(1) 建立模型，实现预测

以某地区 1999 年到 2005 年的年实际用电量作为训练的样本，预测这个地区的 2006 年用电量。建立灰色模型与 BP 神经网络模型相结合的综合模型，综合模型的预测结果见表 4-1,仿真见图 4-2。

表 4-1 综合模型的预测结果（单位：亿 kW · h）

Table 4-1 Comprehensive model predicted results (unit: 10⁸kW · h)

年份	实际值	灰色预测	相对误差绝对值/ %	综合模型	相对误差绝对值/ %
1999	77.6628	79.7284	2.6598	81.4712	4.9038
2000	91.4389	88.5371	3.1734	88.3448	3.3837
2001	97.9987	98.3189	0.3267	96.8863	1.1350
2002	108.5024	109.1814	0.6258	107.3427	1.0687
2003	119.7362	121.2441	1.2593	119.9110	0.1460
2004	132.1800	134.6394	1.8607	134.6894	1.8985
2005	152.8890	149.5147	2.2070	151.6244	0.8270
2006	171.6323	166.0335	3.2620	170.4668	0.6790




图 4-2 综合模型预测的仿真效果

Figure 4-2 comprehensive simulation results of the model predictions

对收集到的历史数据按照下式进行处理:

$$\bar{x}^{(0)}(t) = \frac{x^{(0)}(t)}{10^m}, t=1, 2, \dots, 7 \quad (4.19)$$

其中的 $x^{(0)}(t)$ 代表原始的数据, m 是原始的数据里面最大值整数位数, 这个模型中的 $m=7$, 通过实验表明对样本进行预处理不仅能够加快整个网络训练的速度, 并且可以提高模型的预测精度。

这种方法建立了三个隐层的 BP 网络, 其中第一层与第三层都只有 1 个节点, 第二层含有 2 个节点, 除了第一层使用 Log-Sigmoid 型的传递函数, 其它层都使用线性的传递函数, 最大的训练步数取 $M=900$, 最大的允许误差设定为 $E=0.000005$, 运用 LM 来作为网络训练算法。

采用 Matlab 编程, 当网络的精度满足要求的时候, 就可以得到灰色的 BP 神经网络模型, 取得的权值与阈值为: $\omega_{11}=-0.1494, \omega_{21}=-0.4316, \omega_{22}=-0.3717, \omega_{31}=\omega_{32}=2.348, \theta=0.9192$ 。

(2) 精度比较

和传统的灰色预测方法比较, 这种综合模型的方法使预测相对误差的绝对值从原来的 3.262% 逐渐降低为 0.679%, 表现出很强的泛化能力。

(3) 预测结论

这种方法从连续的角度出发, 把灰色模型通过一定的数学关系映射到神经网络, 把一些离散的数据通过拟合得到一定变化规律的函数。上面的预测效果进一步说明了灰色 BP 的神经网络模型具有合理的结构, 不仅融合了灰色模型处理样本少的特点, 还发挥出了神经网络良好的非线性逼近以及容错能力较强的特点, 比较适合应用于样本数据呈现指数增长态势变化但样本数目相对较少的中长期负荷预测。

4.3 本章小结

电力系统是一个庞大的复杂系统, 当对电力系统中长期负荷预测时, 若某地区的实际用电负荷经过建模改进修正仍然不能达到满意的效果, 可以通过当地电力系统的特点 (本章例子中的特点数据较少、系统不能呈现明显的规律) 运用几种模型的各自优点交叉综合运用, 来达到提高中长期负荷预测精度的目的。

5 中长期电力负荷的组合预测模型理论及其应用

在预测的实践中,常常对待同样的一个问题,我们也经常采用不相同的预测方法来处理。不同种类的预测方法它们的预测精度往往也有很大差异。通常采用预测误差平方和的方法来判定精度的高低,然后从同种的预测方法中挑选出预测误差平方和相对最小的预测方法。应用不相同的预测方法常常能获得不相同的有价值信息,如果简单地将预测误差平方和较大的方法舍弃,这样也并不一定科学,并不能只通过简单的一种精度评价方法来确定方法的优劣,何况负荷本身的变化就带有很大的随机性。科学的作法是通过利用不同种类的预测方法来进行适当的加权组合,能使预测的误差达到最小,这样就形成了组合预测的方法。主要目的是综合应用各种不同的预测方法所得到的数据信息,通过合理的处理,形成了电力预测的组合模型,以提高预测精度。下面简单介绍一下加权系数确立的方法,

5.1 组合预测的研究方法

(1) 最优组合的预测方法

最优组合的预测方法,它的基本思想是依据“过去某一段时间内的组合预测误差值最小”的这个原则来确定求取每个单项预测方法前面的权重系数的。这种方法主要存在两个问题:第一是有时候可能会计算出负的极重;第二是计算求出的权重并不一定就是最优的。

最优组合的预测方法的最主要关键点是选取恰当的组合权重系数,为了得到最优权重系数,提出了不同种类的确定组合权重系数的方法,同时也制定出了各种不相同的优化标准。

(2) 变权重组合预测方法

应用组合预测的方法,变权重的方法明显要优于保持不变权重的方法。因为不管对于任何一种单模型的预测方法来讲,它经常出现“时好时坏”的特征。不管怎样,但是因为应用变权重组合预测的方法相对复杂,所以到现在为止对变权重组合的预测方法研究并不是很多。

(3) 其它一些方法

这一类方法是利用不同种类的数学方法来对权重系数进行求解,其所用的算法复杂程度会有所不同,可以从各种不相同的侧面来处理相同的一个问题。但是由于这类方法的运算量非常大,并且有没有把权重的变化考虑进来,从而会很大程度地影响这类方法在实际当中的应用。

5.2 组合预测的权重系数

组合预测的最为关键的要点是来确定出每一个个预测方法的具体加权系数。设对于

同样的一个预测问题有 $(n \geq 2)$ 种的预测方法。给出下列记号： y_t 为实际的搜集数值； f_{it} 则为运用第 i 种方法得到的预测值； $e_{it} = y_t - f_{it}$ 则为第 i 种方法所计算得到的预测误差； k_i 则为第 i 种方法计算得到的加权系数， $\sum_{i=1}^n k_i = 1$ ； $f_t = \sum_{i=1}^n k_i f_{it}$ 是运用组合预测方法所得的预测值； $e_t = y_t - f_t$ 运用组合预测方法所得的预测误差，于是 $e_t = y_t - f_t = \sum_{i=1}^n k_i e_{it}$ 。其中， $i = 1, 2, \dots, n$ ； $t = 1, 2, \dots, N$ 。

记组合预测的方法所得预测误差平方和为 $J = \sum_{t=1}^N e_t^2$ ，则有

$$J = \sum_{i=1}^n \sum_{j=1}^n \left[k_i k_j \left(\sum_{t=1}^N e_{it} e_{jt} \right) \right] \quad (5.1)$$

记组合预测的方法预测加权系数向量是 $\mathbf{K}_n = [k_1, k_2, \dots, k_n]^T$ ，第 i 种的预测方法可得预测误差向量是 $\mathbf{E}_i = [e_{i1}, e_{i2}, \dots, e_{iN}]^T$ ，预测误差的矩阵是 $\mathbf{e} = [\mathbf{E}_1, \mathbf{E}_2, \dots, \mathbf{E}_n]$ ，于是

$$J = \mathbf{e}^T \mathbf{e} = \mathbf{K}_n^T \mathbf{E}_{(n)} \mathbf{K}_n \quad (5.2)$$

中

$$\mathbf{E}_{(n)} = \begin{bmatrix} E_{11} & E_{12} & \cdots & E_{1n} \\ E_{21} & E_{22} & \cdots & E_{2n} \\ \vdots & \vdots & & \vdots \\ E_{n1} & E_{n2} & \cdots & E_{nn} \end{bmatrix}$$

而 $E_{ij} = E_{ji} = \mathbf{E}_i^T \mathbf{E}_j$ ， $E_{ii} = \mathbf{E}_i^T \mathbf{E}_i = \sum_{t=1}^N a_{it}^2$ 。 E_{ii} 是得到第 i 种的预测方法预测误差的平方和。

$\mathbf{E}_{(n)}$ 则是反映各种不同预测方法所得到的预测误差信息，被称之为预测误差的信息矩阵。

记 $\mathbf{R}_n = [1, 1, \dots, 1]_{n \times 1}^T$ ，有加权系数的约束条件 $\sum_{i=1}^n k_i = 1$ 需改变为 $\mathbf{R}_n^T \mathbf{K}_n = 1$ 。可见，组

合预测问题也就变成了非线性规划模型：

$$\min J = \mathbf{K}_n^T \mathbf{E}_{(n)} \mathbf{K}_n \quad (5.3)$$

$$\text{s.t.} \begin{cases} \mathbf{R}_n^T \mathbf{K}_n = 1 \\ \mathbf{K}_n \geq 0 \end{cases} \quad (5.4)$$

5.3 组合预测的最优加权模型

(1) 最优加权模型原理

最优加权法依据的基本原理是应用某种最优准则来构造目标函数 Q ，在约束的条件（记为 s.t.）下来极小化 Q 可得到综合模型的各个加权系数，这些得到的权重系数也就是每一个模型的最优权。

设 $\{x_t\}, t=1, 2, \dots, N$ 作为观测序列，总共有有 J 个不同的预测模型对它进行预测，拟合值分别记为 $\{\hat{x}_t(j)\}, j=1, 2, \dots, J, t=1, 2, \dots, N$ ，则可知最优加权模型组合的权重系数 $w_j, j=1, 2, \dots, J$ ，应该是下列规划问题的解：

$$\begin{cases} \min Q = Q_0(w_1, w_2, \dots, w_J) \\ \text{s. t.} \end{cases} \quad (5.5)$$

其中 Q 是目标函数，s. t. 为这个规划问题所限定的约束条件。在某些实际的问题中有时候还同时要求 w_j 非负，即。

$$\sum_{j=1}^J w_j = 1, w_j \geq 0, j=1, 2, \dots, J \quad (5.6)$$

目标函数 Q 要根据误差统计量和极小化准则类型来确定，误差统计量常用的指标如下：

拟合误差

$$\begin{aligned} e_t &= x_t - \hat{x}_t = x_t - \sum_{j=1}^J w_j \hat{x}_t(j) \\ &= \sum_{j=1}^J w_j (x_t - \hat{x}_t(j)) = \sum_{j=1}^J w_j e_t(j) \end{aligned} \quad (5.7)$$

相对误差

$$e_t / x_t \quad (5.8)$$

对数误差

$$e'_t = \log x_t - \log \hat{x}_t \quad (5.9)$$

目标函数的极小化准则含有多种形式，最经常用的分别是最小一乘准则、最小二乘准则以及极小极大化的准则，分别构成的目标函数如下列形式：

$$Q = \sum_{j=1}^J (e_t^*)^2 \quad (5.10)$$

$$Q = \sum_{t=1}^N |e_t^*| \quad (5.11)$$

$$Q = \max_{1 \leq t \leq N} e_t^* \quad (5.12)$$

上式中的误差统计量可以从 (3.10) 到 (3.12) 式子中选取。上面的准则有时还需考虑有加权的情形。

选择第一个目标函数, 把拟合误差作为误差的统计量, 利用最小二乘准则, 便能够得到最优加权系数的解。

(2) 最小二乘准则下的最优加权系数

把拟合误差 e_t 作为误差的统计量, 这时的规划模型变为

$$\begin{cases} \min Q & Q = \sum_{t=1}^N e_t^2 \\ \text{s. t.} & \sum_{j=1}^J w_j = 1 \end{cases} \quad (5.13)$$

为了求出 $w_j, j=1, 2, \dots, J$, 可将上式转换为矩阵的形式, 令

$$\begin{aligned} W &= (w_1, w_2, \dots, w_J)^T, \quad R = (1, 1, \dots, 1)^T \\ e_j &= (e_1(j), e_2(j), \dots, e_N(j))^T \\ e &= (e_1, e_2, \dots, e_N)^T, \quad j=1, 2, \dots, J \\ e_{ij} &= e_i^T e_j = \sum_{t=1}^N e_t(i) e_t(j), \quad E = (e_{ij})_{J \times J} \end{aligned} \quad (5.14)$$

$J \times J$ 矩阵 E 是正定对称的, 称之为信息阵, 由上面的式子可得:

$$e_t = x_t - \hat{x}_t = \sum_{j=1}^J w_j e_t(j) = (e_t(1), e_t(2), \dots, e_t(J))W \quad (5.15)$$

$$e = \begin{bmatrix} e_1 \\ \vdots \\ e_N \end{bmatrix} = \begin{bmatrix} e_1(1) & \cdots & e_1(J) \\ \vdots & \ddots & \vdots \\ e_N(1) & \cdots & e_N(J) \end{bmatrix} W = (e_1, e_2, \dots, e_J)W \quad (5.16)$$

(3.13) 式的变化矩阵形式也可以表示为:

$$\begin{cases} \min Q & Q = e^T e = W^T E W \\ \text{S. t.} & R^T W = 1 \end{cases} \quad (5.17)$$

引入 Lagrange 剩子 λ ，使 Q 取得极小值的必要条件是： $EW - \lambda R = 0$, $W = \lambda E^{-1}R$

又由 $\frac{d}{d\lambda}(W^T E W - 2\lambda(R^T W - 1)) = 0$ ，得 $R^T W = 1$ 即 $R^T(\lambda E^{-1}R) = 1$ 可解得 Lagrange 乘子为： $\lambda = (R^T E^{-1}R)^{-1}$ ，从而得到最优权， W_0 与最小 Q 值 Q_0

$$\begin{cases} W_0 = (R^T E^{-1}R)^{-1} E^{-1}R \\ Q_0 = (R^T E^{-1}R)^{-1} \end{cases} \quad (5.18)$$

Q_0 是最优的综合模型误差平方和。为了能保证 E^{-1} 存在，这就要求模型的误差向量 e_j 都线性无关。

(3) 最小二乘准则下最优加权模型的精度分析

应用最小二乘法所得到的最优综合模型其精度与最小的目标函数 Q_0 主要含有下列结论：

① 最小二乘法计算得到的误差平方和值最小，因此它是最优的，它的精度比其中的任何一个单一模型或者综合模型都要高。

记 Q_0, W_0 与最优综合模型所对应； Q, W 与任意一个综合模型相对应； $Q_{(j)}, W_{(j)}$ 与参加综合的第 j 个模型相对应，考虑到目标函数 Q 要保证模型的精度， Q_0 是 Q 的极小值，便得到 $Q \geq Q_0$ ，又因为 $W_{(j)} = (0, \dots, 0, 1, 0, \dots, 0)^T$ ，依据最优解存在唯一性的原理知，只有当 $W_{(j)} = W_0$ ，否则必定有 $Q > Q_0$ ，所以便能得到上面的结论。

② 记 $\lambda_{\min}$ 与 $\lambda_{\max}$ 是正定对称矩阵的最小以及最大特征值，则有最优综合模型误差平方和 Q_0 需要满足：

$$\lambda_{\min} / J \leq Q_0 \leq \lambda_{\max} / J \quad (5.19)$$

上面的式子其中的 J 是参与综合模型的个数，这个不等式能表明，当 J 越大， Q_0 的变化取值范围会越小，但 Q_0 绝对不可能减小到 $\lambda_{\min} / J$ 以下，同时也不可能增加到 $\lambda_{\max} / J$ 以上。

③ $Q_0 \leq \text{tr}E / J$, $\text{tr}E = \sum_{j=1}^J e_{jj}$ ，其中 $\text{tr}E$ 是矩阵 E 的迹，根据矩阵迹的定义知，

$\text{tr}E = \sum_{j=1}^J e_{jj} = \sum_{j=1}^J \lambda_j$, $\lambda_1, \dots, \lambda_J$ 是 E 阵的非负特征根，便有：

$$Q_0 \leq \lambda_{\max} / J \leq (\sum_{j=1}^J \lambda_j) / J = \text{tr}E / J \quad (5.20)$$

④ 当综合的模型参与个数从 J 种增加一种变为 $J+1$ 种时，则有最优综合模型预测的误差平方和需要满足不等式：

$$Q_{J+1} \leq Q_J \quad (5.21)$$

上面的式子其中等号成立的条件是

$$W_J^T \alpha = Q_J, \alpha = (e_{1,J+1}, e_{2,J+1}, \dots, e_{J,J+1}) \quad (5.22)$$

5.4 组合预测权重的正交组合

由于采用最小二乘准则有时可能得到的最优权重为负值，这有时候经常与实际可能要求的不符。所以要经常在约束的条件中通过增加正权重约束来得到以次优的正权重组合，达到提高整个预测精度的效果。

(1) 正权组合的类型

① 算术平均法

$$w_j = \frac{1}{J}, j = 1, 2, \dots, J \quad (5.23)$$

这种方法同时被称作等权平均法。算术平均法的最大特点就是每一个模型同等的看待，并给它们一样的权重，往往在对各模型的应用性缺乏深度认识时常用。该算法比较简单，且其中的加权系数能够自动满足所需要的非负条件，所以它被应用的范围也非常广。

② 方差倒数法

$$w_j = D_j^{-1} / \sum_{j=1}^J D_j^{-1}, j = 1, 2, \dots, J \quad (5.24)$$

式子中 D_j 是第 j 个模型计算出的误差平方和，应用该法用高权重赋予误差平方和比较小的模型

$$D_j = \sum_{t=1}^N (x_t - \hat{x}_t(j))^2 \quad (5.25)$$

这种方法与下面所提及的几种方法和算术平均法不相同，它们要求对各个模型要有一定程度的了解。

③ 均方倒数法

$$w_j = D_j^{-1/2} / \sum_{j=1}^J D_j^{-1/2}, j = 1, 2, \dots, J \quad (5.26)$$

④ 简单加权法

$$w_j = j / \sum_{j=1}^J j = 2j / (J(J+1)), j = 1, 2, \dots, J \quad (5.27)$$

式中 J 个模型以误差平方和 D_j 的降序进行排列, 其基本思想也是用高权重赋予误差平方和比较小的模型。

⑤ 二项式系数法

$$w_j = C_{J-1}^{j-1} / 2^{J-1}, j = 1, 2, \dots, J \quad (5.28)$$

式中 C_{J-1}^{j-1} 是二项式系数, 该种法需要模型按 $\frac{1}{L} \sum_{l=1}^L \hat{x}_{N+l}(j)$ 进行增序排列, 上式中能给在排序中间的一些预测值较大的权重系数。下式是利用改进的二项式系数法来确定权重来保证预测的高精度:

$$w_j = C_{2J-1}^{j-1} / 2^{2(J-1)}, j = 1, 2, \dots, J \quad (5.29)$$

此处的模型以误差平方和 $\{D_j\}$ 的降序排列, 该权重和 $\{D_j\}$ 反序, 依据下列式子可以得到

$$\sum_j^J w_j = 1: 1 = \left(\frac{1}{2} + \frac{1}{2}\right)^{2J-1} = \sum_{j=0}^{2J-1} C_{2J-1}^j \left(\frac{1}{2}\right)^{2J-1} \quad (5.30)$$

(2) 正权组合模型误差平方和的界限

依据信息阵 E 中的元素 e_{ij} 定义可知, 当 $i = j$ 时, e_{ij} 则是第 j 个模型误差平方和。正权组合模型误差平方和 Q 需满足下列不等式:

$$\lambda_{\min} / J \leq Q_0 \leq Q \leq \sum_{j=1}^J w_j e_{jj} \leq \max_{1 \leq j \leq J} \{e_{jj}\} \quad (5.31)$$

可知正权组合模型具有以下共同特性:

① 正权组合模型误差平方和具有相同的界限

② 正权组合模型有可能是次优的 ($Q \geq Q_0$)

③ 正权组合模型要比精度最差的单个模型预测效果好 ($Q \leq \max_j e_{jj}$)

④ 任何一种组合预测的方法误差平方和小于或者等于每一个单种模型的预测值误差平方和的加权平均

(3) 正权组合模型精度

① 算术平均法

$$W_A = \frac{1}{J} (1, 1, \dots, 1)^T = \frac{1}{J} R \quad (5.32)$$

$$Q_A = W_A^T E W_A = \frac{1}{J^2} R^T E R < \frac{1}{J} \sum_{j=1}^J e_{jj} = U_A \quad (5.33)$$

上式中 Q_A 是算术平均组合方法的误差平方和, U_A 是 Q_A 的上界。很显然, U_A 是每一个单模型预测的误差平方和加权平均。算术平均法预测值的误差平方和要小于每一个单模型预测的误差平方和最大者但确不能保证小于其中的最小者。

② 均方倒数加权法

记

$$W_B = \left(\sum_{j=1}^J \sqrt{e_{jj}^{-1}} \right)^{-1} (\sqrt{e_{11}^{-1}}, \sqrt{e_{22}^{-1}}, \dots, \sqrt{e_{JJ}^{-1}})^T \quad (5.34)$$

则

$$\begin{aligned} Q_B &= W_B^T E W_B \leq \sum_{j=1}^J W_j e_{jj} = \sum_{j=1}^J (\sqrt{e_{jj}^{-1}} / \sum_{j=1}^J \sqrt{e_{jj}^{-1}}) e_{jj} \\ &= \sum_{j=1}^J \sqrt{e_{jj}} / \sum_{j=1}^J \sqrt{e_{jj}^{-1}} = U_B \end{aligned} \quad (5.35)$$

U_B 是 Q_B 的上界。则有

$$\frac{U_B}{U_A} = \frac{\sum_{j=1}^J \sqrt{e_{jj}} / \sum_{i=1}^J \sqrt{e_{ii}^{-1}}}{\frac{1}{J} \sum_{j=1}^J e_{jj}} = \frac{\sum_{i=1}^J \sqrt{e_{ii}} \cdot J}{\sum_{j=1}^J e_{jj} \sum_{j=1}^J \sqrt{e_{jj}^{-1}}} \quad (5.36)$$

根据 Shwarz 不等式有 $J^2 = (\sum_{j=1}^J \sqrt{\alpha_j \alpha_j^{-1}})^2 \leq \sum \alpha_j \sum \alpha_j^{-1}, \alpha_j > 0, j = 1, 2, \dots, J$ 令

$\alpha_j = \sqrt{e_{jj}}$, 可得

$$\begin{aligned} \frac{U_B}{U_A} &= \frac{\sum_{j=1}^J \sqrt{e_{jj}} \cdot J^2}{J \sum_{i=1}^J e_{ii} \sum_{j=1}^J \sqrt{e_{jj}^{-1}}} \leq \frac{\sum_{j=1}^J \sqrt{e_{jj}} (\sum_{j=1}^J \sqrt{e_{jj}} \sum_{j=1}^J \sqrt{e_{jj}^{-1}})}{J \sum_{j=1}^J e_{jj} \sum_{j=1}^J \sqrt{e_{jj}^{-1}}} \\ &= \frac{(\sum_{j=1}^J \sqrt{e_{jj}})^2}{J \sum_{j=1}^J e_{jj}} \leq \frac{J \sum_{j=1}^J e_{jj}}{J \sum_{j=1}^J e_{jj}} = 1 \end{aligned} \quad (5.37)$$

上式 ($U_B \leq U_A$) 说明均方倒数加权的模型误差平方和的上界比算术平均的组合模型要小, 前者精度要比后者高。

随意选取的 J 种不同预测方法，都会有 $Q_A < U_A, Q_B < U_B, U_B < U_A$ ，虽然并不能保证一定存在 $Q_B < Q_A$ 的关系，但是它是加权原则的一种方法，可能选择加权系数向量 W_B 会比取 W_A 更好一些，由于前者推出来的组合预测方法预测误差平方和含有比较小的上界。

③ 方差倒数加权法
记

$$W_c = \left(\sum_{j=1}^J e_{jj}^{-1} \right)^{-1} (e_{11}^{-1}, e_{22}^{-1}, \dots, e_{JJ}^{-1})^T \quad (5.38)$$

则

$$Q_c = W_c^T E W_c \leq \sum_{j=1}^J W_j e_{jj} = J / \sum_{j=1}^J e_{jj}^{-1} = U_c \quad (5.39)$$

根据 Shwarz 的不等式可得：

$$\frac{U_c}{U_B} = \frac{j \cdot \sum_{j=1}^J \sqrt{e_{jj}^{-1}}}{\sum_{j=1}^J e_{jj}^{-1} \sum_{j=1}^J \sqrt{e_{jj}}} \leq \frac{(\sum_{j=1}^J \sqrt{e_{jj}^{-1}})^2}{J \sum_{j=1}^J e_{jj}^{-1}} \leq \frac{J \sum_{j=1}^J e_{jj}^{-1}}{J \sum_{j=1}^J e_{jj}^{-1}} = 1 \quad (5.40)$$

便可以得到 $U_c \leq U_B \leq U_A$ ，反映出均方倒数组合模型的精度要比算数平均组合模型的精度高，方差倒数组合模型精度又要比前两种组合模型都高。

④ 简单加权法
记

$$W_D = \frac{2}{J(J+1)} (1, 2, \dots, J)^T \quad (5.41)$$

则

$$Q_D = W_D^T E W_D \leq \sum_{j=1}^J W_j e_{jj} = \frac{2}{J(J+1)} \sum_{j=1}^J j e_{jj} = U_D \quad (5.42)$$

则可以得到 $U_D \leq U_A$ 。

⑤ 二项系数法
记

$$W_E = 2^{-2(J-1)} (C_{2J-1}^0, C_{2J-1}^1, \dots, C_{2J-1}^{J-1})^T \quad (5.43)$$

$$\text{则} \quad Q_E = W_E^T E W_E \leq \sum_{j=1}^J W_j e_{jj} = 2^{-2(J-1)} \sum_{j=1}^J C_{2^{J-1}}^{j-1} e_{jj} = U_E \quad (5.44)$$

可以得到 $U_E \leq U_D \leq U_A$ 。

由常用的五种正权综合方法（分别记为 A、B、C、D、E）的精度比较可以看出，后面 4 种方法所得到的综合模型的精度都比算述平均模型高，但是，算术平均法用的最多。为提高综合预测的精度，研究其它正权综合方法也很有必要。

(4) 正权组合方法的改进

应用递归的技巧，能够更进一步的提高正权组合模型的预测值精度，递归技巧的实施步骤如下：

① 利用 J 个初始模型的拟合 $|X_t|, t=1, 2, \dots, N$ ，然后计算其每个模型误差的平方

$$\text{和 } e_{jj} = \sum_{t=1}^N (x_t - \hat{x}_t(j))^2, j=1, 2, \dots, J。$$

② 按照 J 个模型误差平均和的降序排列，记作 $e(1) \geq e(2) \geq \dots \geq e(J)$ ，则有

$$e(1) = \max_{1 \leq j \leq J} \{e_{jj}\}, e(J) = \min_{1 \leq j \leq J} \{e_{jj}\}。$$

③ 给定一个定值的迭代精度 ε ，若 $\Delta = e(1) - e(J) < \varepsilon$ ，则表明终止迭代。模型 (J) 相应的初始模型的加权系数就是所要求的，否则继续作下一步。

迭代精度 ε 的选取可依据实际的需要以及计算的能力来决定，该递归的方法对于任何一种的正权方法都能适用，这是因为保证了每一轮的递归中误差平方和都必须满足不等式 $0 \leq e(*) \leq e(1)$ ，所以递归程序一定收敛，并且精度要优于非递归的情形。所以递归正权组合的决策能够进一步的提高组合模型的可靠性。

5.5 组合模型的应用效果

(1) 建立模型，实现预测

以我国南方某市区 2005 年到 2009 年的用电量为历史数据，利用线性回归模型、灰色模型以及指数平滑模型建立组合模型，实现预测。南方某市区历史数据及各个单模型预测值见 5-1。

表 5-1 南方某市区实际用电量及各单模型的预测值 (单位: 亿 kW · h)

Table 5-1 Southern an urban electricity consumption and the predictive result of the single model(unit: 10^8 kW · h)

年 份	实际值	线性回归模型	指数平滑模型	灰色模型
2005	14.87	15.46	15.63	14.24
2006	16.66	17.06	16.13	16.46
2007	19.10	18.66	18.80	19.78
2008	20.56	20.26	20.99	20.72
2009	22.32	21.86	23.73	23.01

(2) 利用正权组合方法, 找出权重系数

根据历史数据及各个单模型的预测值, 利用改进的正权组合方法, 找出各个单模型的权重系数见表 5-2。

表 5-2 各个单模型的权重系数

Table 5-2 Individual single model weighting coefficient

模 型	线性回归模型	指数平滑模型	灰色模型
权重系数	0.157	0.202	0.641

(3) 实现组合预测

根据各个单模型的权重系数, 可得到组合模型的预测值见表 5-3。

表 5-3 组合模型的预测值 (单位: 亿 kW · h)

Table 5-3 Combined model predicted values (unit: 10^8 kW · h)

年份	2005	2006	2007	2008	2009
预测值	14.71	16.49	19.09	20.70	22.97

(4) 精度比较

为了能够方便地比较, 各个单模型以及优化组合的预测模型误差平方和见表 5-4, 各个单模型以及优化组合的预测模型效果见图 5-1。

表 5-4 各个单模型及优化组合的预测模型误差平方和

Table 5-4 single model and the optimal combination forecast model error sum of squares

模 型	线性回归模型	指数平滑模型	灰色模型	组合模型
误差平方和	1.42	3.12	1.00	0.49




图 5-1 各个单模型及优化组合的预测模型预测效果

Figure 5-1 Single model and the optimal combination forecasting model prediction

(5) 预测结论

由表 5-4 可以看出, 经过加权优化的组合模型误差更小, 精度更高。

(6) 预测南方某地区 2010 年到 2020 年的用电负荷。

表 5-5 南方某地区 2010 年到 2020 年的用电预测值 (单位: 亿 kW · h)

Table 5-5 Southern region from 2010 to 2020, electricity predictive value (unit: $10^8 \text{ kW} \cdot \text{h}$)

年 份	组合预测值	年 份	组合预测值
2010	26.675	2016	60.385
2011	31.631	2017	64.606
2012	37.387	2018	69.640
2013	43.929	2019	74.630
2014	50.227	2020	80.286
2015	55.608		

5.6 本章小结

组合预测模型的关键是如何确定加权系数, 经过组合优化的模型往往比单个模型的预测精度要高。依据已有的历史数据, 仔细分析它们的特点, 选取合理的方法, 确定各个模型的权重系数, 这样组合模型的精度将会达到令人满意的效果。

6 中长期电力负荷预测技术的联合应用

到目前为止，中长期电力负荷预测的方法有许多，可是每一个单独的模型却都有自己的一定应用范围，即便是改进模型、综合模型或者组合模型也是如此，很难应用于所有的情况，这时就需要仔细电力系统的各个产业的特点，抓住它们内在的规律，选用不同的负荷预测模型进行预测，这时候有可能出现同一地区，使用单一模型、改进模型、综合模型以及组合模型的联合应用，最终来保证该地区的负荷预测精度，以河南省新乡市近些年的历史负荷数据为依据，通过实际算例的检验，结果表明，中长期电力负荷预测技术的联合应用效果令人满意。

6.1 联合应用算例背景

选取河南省新乡供电系统从 2004 年到 2010 年的第一产业年用电量、第二产业年用电量、第三产业年用电量、全行业年用电量、城乡居民生活用电以及全社会年用电量等相关的数据作为原始的数据见表 6-1，用联合预测的方法对该地区进行负荷预测。

表 6-1 河南省新乡供电系统的各项用电量指标（单位：亿 kW·h）

Table 6-1 Xinxiang, Henan power supply system, the electricity consumption indicators
(unit: $10^8 \text{ kW}\cdot\text{h}$)

年份	第一产业 年用电量	第二产业 年用电量	第三产业 年用电量	全行业年 用电量	城乡居民 生活用电	全社会年 用电量
2004	4.3813	49.3730	5.0991	58.8534	8.4012	67.2546
2005	5.2525	54.4840	7.2635	67.0000	9.3250	76.3250
2006	6.8565	60.7782	7.4634	75.0981	11.8508	86.9489
2007	6.1553	71.6725	7.6499	85.4777	12.7617	98.2394
2008	9.8167	85.1950	7.9062	102.9179	14.9666	117.8845
2009	8.7994	92.7295	7.7009	109.2299	18.8252	128.0551
2010	6.1881	106.0835	10.1631	122.4347	21.5837	144.0184

6.2 原始数据的分析与预测方法的选取

仔细分析表 6-1 可知，第一产业的年用电量从 2004 年到 2008 年呈现出增长的趋势，但是从 2008 年以后呈现出了下降的趋势，具有一定的随机波动性，第二产业的年用电量呈现出一直增长的趋势，第三产业相对平稳，但在 2010 年出现了较大的增长，由于新乡地区是一个中小城市，工业不是非常发达，预计第三产业在今后几年会有一定程度的提高，纵观 2004 年到 2010 年的全行业用电量呈现出较稳定的增长趋势，表明第二产业在全行业用电量的比重占据较大，直接影响着全行业用电量的增长趋势，近些年来，新乡市城乡居民生活用电也是一直攀升，所以全社会用电量增幅较大。

依据上面的分析可知,第一产业的年用电量可以应用 BP 神经网络模型来进行预测,因为神经网络具有良好的内插效果,且对一些随机的变化预测比较准,考虑到这些年来新乡农业的发展相对稳定,不会出现大的负荷变动,所以选用 BP 神经网络比较合适,第二产业的年用电量一直呈现增长的趋势,可以用线性回归模型与灰色模型来进行预测,第三产业前些年用电量变化不大,但 2010 年发生了突变,预示新乡地区第三产业的发展将会进入新的阶段,可以用指数平滑法来进行适当处理,全行业年用电量可以用前三个产业用电量的和相加,同时也能用自身的变化规律来处理,可以用改进残差灰色模型来进行处理,城乡居民生活用电可以用等维新息灰色模型、线性回归模型来进行预测,全社会年用电量可以用全行业年用电量与城乡居民生活用电相加,也可以应用加权组合模型或者与变化规律相当的单模型进行预测

6.3 预测计算过程的实现

利用初步选定的预测方法,应用相应的模型来处理数据,预测的结果见表 6-2。

表 6-2 初步所选模型预测结果 (单位: 亿 kW·h)

Table 6-2 Preliminary selected model predicts results (unit: $10^8 \text{ kW} \cdot \text{h}$)

年份	第一产业年用电量 BP 网络模型	第二产业年用电量 灰色模型	第三产业年用电量 指数平滑模型	城乡居民生活用电 线性回归模型
2004	4.3813	49.3730	5.0991	7.3524
2005	5.2525	54.6527	6.8306	9.5547
2006	6.8565	62.4779	7.6831	11.7570
2007	6.1553	71.4236	8.1041	13.9593
2008	9.8167	81.6501	8.3880	16.1616
2009	8.4357	93.3409	8.2561	18.3639
2010	7.6284	106.7056	9.4652	20.5662

全行业年用电量可以利用前面三个产业预测值组合相加求和的方法,也可以利用发现其自身规律的方法利用综合模型来进行预测,全社会的年用电量也能利用全行业年用电量与城乡居民生活用电模型相加求和来处理,或者利用等维新息灰色模型来处理,这样能使预测的精度可能会更高点。全行业年用电量与全社会年用电量的各种模型预测值见表 6-3 与 6-4。

表 6-3 全行业年用电量预测值 (单位: 亿 kW·h)

Table 6-3 Industry-wide annual electricity consumption forecasting value (unit: 10^8 kW·h)

年份	全行业年用电量						
	实际值	累加求和模型	相对误差 (%)	改进灰色模型	相对误差 (%)	组合模型	相对误差 (%)
2004	58.8534	58.8534	0	58.8534	0	58.8534	0
2005	67.0000	66.7358	-0.3943	67.8088	1.2072	66.8968	-0.1541
2006	75.0981	77.0175	2.556	76.4940	1.8588	76.9390	2.4512
2007	85.4777	85.6830	0.2402	86.2916	0.9522	85.7743	0.3470
2008	102.9179	99.8548	-2.9763	97.3441	-5.4158	99.4782	-3.3422
2009	109.2299	110.0327	0.7350	109.8122	0.5331	109.9996	0.7047
2010	122.4347	123.7992	1.1114	123.8773	1.1783	123.8109	1.1240

表 6-4 全社会年用电量预测值 (单位: 亿 kW·h)

Table 6-4 The whole society electricity demand forecasting value (unit: 10^8 kW·h)

年份	全社会年用电量						
	实际值	累加求和模型	相对误差 (%)	改进灰色模型	相对误差 (%)	组合模型	相对误差 (%)
2004	67.2546	66.2058	-1.5594	67.2546	0	67.4536	0.2959
2005	76.3250	76.2905	-0.0452	77.2202	1.1729	76.4179	0.1217
2006	86.9489	88.7745	2.100	87.6365	0.7908	87.7681	0.9421
2007	98.2394	99.6423	1.4280	99.4579	1.2403	99.3654	1.1462
2008	117.8845	116.0164	1.5847	112.8739	4.2504	116.4782	1.1930
2009	128.0551	128.3966	0.2667	128.0995	0.0347	128.1639	0.0850
2010	144.0184	144.3654	0.2409	145.3790	0.9447	144.3107	0.2030

6.4 精度校验

利用相对误差的绝对值和来校验全行业年用电量以及全社会年用电量预测值的精度高低见表 6-5 和 6-6。

表 6-5 全行业年用电量各种模型预测相对误差绝对值和

Table 6-5 Industry-wide annual electricity consumption of various models to predict the absolute value of relative error

模 型	累加求和模型	改进灰色模型	组合模型
相对误差绝对值和	8.0132	11.1454	8.1232

表 6-6 全社会年用电量各种模型预测相对误差绝对值和

Table 6-6 The whole society annual electricity consumption of various models to predict the absolute value of relative error

模 型	累加求和模型	改进灰色模型	组合模型
相对误差绝对值和	7.2294	8.4338	3.9869

6.5 预测结论

以河南省新乡地区的用电量为历史依据,对应三种产业以及城乡居民生活用电分别建立不同的模型,可以依据全行业年用电量以及全社会年用电量的结构组成进行累加求和,也可以应用该地区实际值依据改进模型或者组合模型进行建模,从全行业年用电量三种预测模型的比较可知,累加求和模型要优于改进灰色模型和组合模型,但在全社会年用电量的预测中,组合模型要优于累加求和模型与改进灰色模型,也就是说每种预测方法都有自己的局限性,即使是组合模型也不一定最优。

6.6 本章小结

根据一个地区的负荷可以选用多个预测方法进行预测,但无论是单模型、改进模型、综合模型都有自己的适用范围,即使是组合模型预测值也不一定是最优的,这时候就需要联合应用,通过对比几种模型的预测结果,选出精度最高的模型可作为本地区的预测模型。

7 结论与展望

本文论述了许多种负荷预测的方法，每一种方法都有自己的优点与适用范围，着重研究了不同种中长期负荷预测方法在电力系统中的应用，主要分为单模型、改进模型、综合模型、组合模型以及联合应用理论，通过对各个模型的理论方法分析和研究，归纳出一下结论：

(1) 单模型预测法原理比较简单，不必考虑太多的复杂因素，并且过去的历史负荷数据有一定的规律性，能较准确地反映出负荷的发展趋势，它包含的方法有回归分析法、灰色模型法、指数平滑法、神经网络法等，每一种单模型都有自己的优点和适用范围，依据负荷数据，选出合理的单模型，在满足预测精度的前提下，既能节约时间又能减少费用。

(2) 改进模型预测法是在单模型对已有的历史数据负荷预测不适合的前提下提出的，有时候无论任何一个单模型都不能满足负荷预测精度的要求，这时候就需要对原模型进行改进，比如若已有历史数据本身无一定的规律，但它们各年的负荷之差即残差呈现出一定的规律，这时候运用改进残差灰色模型就能够很好地预测出规划年的负荷数据，为该地区电力系统规划打好基础。

(3) 综合模型预测法并不是简单地利用一种模型来对统计数据进行简单处理，它首先是依据数据的特点选出几个模型进行综合，如可以利用指数平滑法对波动的数据进行预处理得到一组新的数据，再利用数据呈现指数增长的特点，利用灰色模型来进行预测，这样预测的数据较前两种单模型都要好，当然这种方法也有自己的适用范围，并不是综合模型就一定比单模型要好，主要还是依据负荷的特点来进行合理地选取。

(4) 组合模型是针对同一个地区的负荷预测采用多个预测模型来处理的方法，通过选取合理的加权系数来提高负荷的预测的精度，该方法的难点是运用什么样的方法来确定加权系数，因为合理的加权系数能使负荷的预测精度达到令人满意的效果，相反，如果不能运用合理的方法确定加权系数，可能会导致组合模型的效果比一些单模型的预测效果还要差

(5) 联合应用理论是利用多种预测方法把一个整体的预测分成若部分通过构成累加实现负荷预测，这样就可以通过对各个部分的模型进行负荷分析，对每个部分都根据负荷的特点可以选用单模型、改进模型、综合模型以及组合模型来实现预测，通过把这些部分的预测值进行累加求和，得到的预测结果往往要比从整体上的预测效果要好，从而能一定程度地避免整体上规律不明显、数据不完整的缺点，通过合理分离，数据可能呈现出较好的规律性。

到现在为止，中长期的负荷预测的主要困难是需要考虑电力负荷复杂的变化因素，比如产业结构、外部经济环境以及政府政策等，当进行电力负荷预测的时候，我们几乎

不可能将所有的因素都考虑在内，仅仅是主观地选取几个有显著变化的因素，所以我们建立的预测模型只是部分因素的模型，同时有些因素是不可量化的，即便可以量化，但想准确的量化本身就是一种非常困难的事情，所以，这将会作为今后加强研究的问题，在以后中长期负荷预测的工作中，需要注意并且解决下列问题：

(1) 收集的历史数据须准确。准确的历史数据是进行确保中长期负荷预测的前提，若收集的历史数据存在较大的错误，这样会破坏原来的规律性，进一步影响到中长期的负荷预测精度。

(2) 合理选用负荷预测方法。不同地区的用电负荷可能有不相同的负荷特性，针对不同的特性应选用不同的预测方法，无论怎样，每种预测方法都有着自己的优点与适用范围，若选用不当可能会加大预测的误差。

(3) 当对数据进行预处理和建模的过程中，需要对外界存在的因素以及和未来不确定的相关因素加以充分考虑，这样才能尽量降低外界因素对中长期负荷预测的干扰。

(4) 需注意不同的模型随着环境与相关因素的变化而表现出的适应问题，并且需要注意在模型的使用过程中，可以利用预测专家长期积累的经验来加以有效分析，通过修正分析，能使中长期负荷预测的精度更高一点。

(5) 影响中长期电力负荷变化的因素有多方面，这时候可以运用各种不同的方法来预测，包括单模型、改进模型、综合模型、组合模型以及联合应用理论等来开展研究负荷预测工作。

攻读硕士学位期间参加的科研实践及发表的论文

侯永辉, 许强, 王赛爽. 边远区域电力系统中长期负荷预测方法研究[J]. 电气应用, 2012, 31 (17): 56-58

侯永辉, 武万晓, 李鹏, 王赛爽, 郭姗姗. 基于 MATLAB 实现同步电机异步并列的仿真[J]. 华北水利水电学院学报, 2011, 32 (5): 83-85

王赛爽, 侯永辉. 灰色模型在中长期电力负荷预测中的应用[J]. 华北水利水电学院学报, 2012, 33 (2): 98-100

王赛爽, 侯永辉. 基于 MATLAB 实现电力系统派克变换的仿真[J]. 中国高新技术企业, 2011, 214: 110-112

致 谢

时光飞逝，转眼间，已到了三年的研究生生涯结束的时刻。在这三年的日子里收获颇多感慨颇多，在此对在我学习、科研和生活中给予我帮助的老师、同学和亲友致以最诚挚的谢意。

本论文的工作是在导师许强教授的精心指导下完成的。在论文的选题和每个研究环节，无不倾注着导师的大量心血。许老师以他渊博的学识、高尚的人格、严谨的治学态度以及崇高的敬业精神和道德风范给我留下了深刻的印象，是我毕生学习的榜样。他不仅把我带入了科学的殿堂，教会我知识，更让我懂得了如何做人。衷心感谢导师这三年来对我始终如一的教导和关心。

读研期间，师兄武万晓，师妹陈巧玲，师弟钱俊良，同窗李鹏以及宿舍兄弟李海滨、左彦森和实验室所有一起学习的朋友们，他们都给我的生活和学习带来很大的帮助，这一路上有你们陪伴，我感到莫大的荣幸，谢谢你们！

感谢养育我的父母，在我求学路上他们默默地给予我鼓励与帮助。

感谢电力学院所有的老师和我的母校华北水利水电大学对我的大力栽培和帮助。

感谢在百忙之中评阅本论文的诸位专家！

参考文献

- 牛东晓, 曹树华等. 电力负荷预测技术及其应用(第二版)[M]. 北京: 中国电力出版社. 2009
- 康重庆, 夏清, 张伯明. 电力系统负荷预测研究综述于发展方向的探讨[J]. 电力系统自动化, 2004, 28(17): 1-11
- 黄桂华. 中长期电负荷预测方力法的简述[J]. 农村电气化, 2002(8): 8-8
- 李艳芳. 电力负荷预测[D]. 硕士学位论文. 南昌: 南昌大学, 2007
- 顾洁. 电力系统中长期负荷预测理论与方法研究[D]. [硕士学位论文]. 上海: 上海交通大学, 2002
- 杨继旺, 吴慢红. 几种负荷预测方法及其应用[J]. 农村电气化, 2004(7): 9-10
- 蒋平, 鞠平. 应用人工神经网络进行中期电力负荷预报[J]. 电力系统自动化, 1995, 6(19): 11-17
- 阮萍, 骆力明, 王华. 基于灰色系统和人工神经网络的中长期电力负荷预测[J]. 首都师范大学学报, 2004, 25(2): 22-25
- Kandil M S, EI-Debelky S M, Hasanien N E. Long-Term Load Forecasting for Fast Developing Using a Knowledge-Based Expert System[J]. IEEE Transactions on Power Systems, vol 17, NO 2, May 2002, 491-496
- 李林川, 吕东, 武文杰. 一种简化的电力系统负荷线性组合预测法[J]. 电网技术, 2002, 26(10): 10-13
- Rajesh K G. Expert systems, their implications for power systems[J]. Potentials. IEEE, Volume 16, Issue 2, Apr-May 1997, 35-37
- 熊岗. 应用灰色系统原理进行长期电力需求预测[J]. 上海交通大学学报, 1993, 27(5): 98-103
- 倪军, 杨晴志, 杨期余等. 专家系统技术应用于城两负荷预测[J]. 供用电, 1994(5): 16-19
- 肖俊, 孙德宝, 秦元庆. 灰色模型在电力负荷预测中的优化与应用[J]. 自动化技术与应用, 2005, 24(2): 19-21
- 杨实俊, 牛东晓. 基于预测模型库关联优化的电力负荷组台预测模型[J]. 华北电力大学学报, 2005, 32(1): 42—44
- 伍力, 吴捷. 负荷中长期预测中一种改进的模糊聚类算法[J]. 电网技术, 2000, 24(1): 36-38
- GU Zhihong, NIU Dongxiao, WANG Huiqing. Research on application of general recession neural network in short time load forecasting[J]. Electric Power, 2006, 39(4):

- 11-14.
- Thanoon B Y.Subset threshold autoregression with applications[J].J.Tims Series Anlysis. 1988, 11(1): 75-87
- 游仕洪, 程浩忠, 谢宏等. 模糊组合预测在中长期负荷预测中的应用[J]. 电力系统及其自动化学报, 2004, 16(3): 53-56
- 薛娟, 张菽慧. 两次拟合灰色预测在中长期电力负荷预测中的运用[J]. 沈阳农业大学学报, 2005, 36(6): 736-738
- 朱芸, 乐秀潘. 可变参数无偏灰色模型的中长期负荷预测[J]. 电力自动化设备, 2003, 23(4): 25-27
- YOU Shihong, CHENG Haozhong, XIE Hong. Mid and long time load forecast based onfuzzy linear regression model[J].Electric Power Automation Equipment, 2006, 26(3): 51-53.
- 顾洁. 电力系统中长期负荷预测的模糊算法[J]. 上海交通大学学报, 2002, 36(2): 255-258
- Yang Kuihe-Zhao Lingling.Load forecasting method with feedback chaos item[J] . Wireless Communications.Networking and Mobile Computing 2003.Proceedings.2005 International Conference Volume 2.23-26 Sept.2005,1379-1382
- 熊信银, 吴耀武, 遗传算法及其在电力系统中的应用. 华中科技大学出版社, 2002
- 徐光虎, 运用遗传规划法进行电力系统中长期负荷预测[J]. 继电器, 2004, 32(14): 21-24
- 韩祯祥, 文福栓. 人工神经网络在电力系统中应用的新进展(二). 电力系统自动化, 1993, 17(2): 55-62
- 刘兵军, 牛东晓. 灰色自适应滤波组合优化预测模型及其应用. 电网技术, 1998, 22(6): 27-31
- 牛东晓. 城市电力需求的灰色预测模型及其应和[J]. 水电能源科学, 1991, 9(3): 207-213
- 张焰, 陈章潮, 谈伟. 不确定性的电网规划方法研究[J]. 电网技术, 1999, 23(3): 15-18
- Doo-Hyun Choi, Se-Young Oh, A New Mutation Rule for Evolutionary Programming Motivated from Backpropagation [J]. LearningIEEE Transactions on Evolutionary , 2000,Vol.4,NO.2:188-190
- 戴文进, 付小科, 电力系统负荷预测[J]. 世界科技研究与发展, 2002, 24(3): 40-43
- 朱继萍. 长期电力负荷预测及相关因素不确定性的影响[D]. 西安: 西安科技大学, 2005
- 张大海, 史开泉, 江洪芳. 灰色负荷预测的参数修正法[J]. 电力系统及其自动化学报, 2001, 13(2): 20-22

- Bhattacharya T K, Medium Range Forecasting of Power System Load Using Modified Kalman Filter and Wash Transform[J]. International Journal of Electrical Power and Energy System, 1993, 15(2): 109-115
- 陈泽淮, 张一尧, 武志刚. 神经网络在中长期负荷预测中的应用[J]. 电力系统及其自动化学报, 2006, 18(1): 15-19
- Barakat E H, Al-rashed S A. Long Range Peak Demand Forecasting Under Conditions of High Growth[J]. IEEE Trans on Power Systems, 1992, 7(4): 1483-1486
- 黄伟, 贾维刚, 王炳革等. 模糊理论在中长期负荷预测中的应用[J]. 电力系统及其自动化学报, 1999, 11(4): 25-29
- Kandil M S, El-Debeiky S, Hansanien N E. Overview and Comparison of Long-term Forecasting Techniques for a Fast Developing Utility[J]. Part I. Electric Power Systems Research 2001, 58(1): 11-17
- 余健明, 燕飞, 杨文字等. 中长期电力负荷的变权灰色组合预测模型[J]. 电网技术, 2005, 29(17): 26-29.
- 周平, 杨岚, 周家启. 电力系统负荷灰色预测的新方法[J]. 电力系统及其自动化学报, 1998, 10(3): 45-50.
- Reddy K N, Agarwal V. Utility-Interactive Hybrid Distributed Generation Scheme With Compensation Feature[J]. IEEE trans. Energy Convers., vol.22, no.3, pp.666-673, Sep.2007.
- Chen Z, Blaabjerg F, Pedersen J K. A Multi- Functional Power Electronic Converter in Distributed Generation Power Systems[J]. Proc. of PESC, 2005: 1738-1744.
- 罗滇生, 姚建刚, 何洪英等. 基于自适应滚动优化的电力负荷多模型组合预测系统的研究与开发[J]. 中国电机工程学报, 2003, 23(5): 58-61.
- 毛李帆, 江岳春, 姚建刚等. 采用正交信号修正法与偏最小二乘法回归的中长期负荷预测[J]. 中国电机工程学报, 2009, 29(16): 82-88.
- 李春生, 王耀南, 陈光辉. 基于互信息的组合预测模型及其在电力负荷预测中的应用[J]. 湖南大学学报: 自然科学版, 2008, 35(9): 58-61.
- 牛东晓, 张博, 陈立荣等. 智能优化灰色模型在中期用电量预测中的应用[J]. 华电电力, 2006, 34(1): 8-11.
- 周平, 杨岚, 周家启. 电力系统负荷灰色预测的新方法[J]. 电力系统及其自动化学报, 1998, 10(3): 45-50.
- 陈华友. 组合预测方法有效性理论及其应用[M]. 北京: 科学出版社, 2007: 183-186.
- 康重庆, 夏清, 刘梅. 电力系统负荷预测[M]. 北京: 中国电力出版社, 2007: 112-114.
- 黄宗彬. 组合预测方法在电力系统负荷预测中的应用研究[J]. 电气开关, 2009, 47(5): 64-66.
- 谢开贵, 周家启. 变权组合预测模型研究[J]. 系统工程理论与实践, 2000, 16(7):

36-40.

Yu Zhuozhou,Liu Jianhua.Method of fault prediction in distribution networks every month by Markov chain with weights[J]. Proceedings of the CSU-EPSC,2008,20(5):97-100.

Shi Wenhui,Bie Zhaohong,Wang Xifan.Applications of Markov chain Monte Carlo in large-scale system reliability evaluation[J].Proceedings of the CSEE,2008,28(4):9-15.

黄伟, 费维刚等. 模糊理论在中长期负荷预测中的应用[J]. 电力系统及其自动化学报, 1999, 11(4): 25-29

张国忠, 熊伟, 向求新, 等. 应用人工神经网络预测电力负荷[J]. 电力自动化设备, 2002, 22(5): 20-21.

WANG Jie, WU Guozhong, LI Yanchang. Application of ant colony gray neural network combined forecasting model in load forecasting [J] Power System Protection and Control, 2009, 37 (2) : 48-52.

YU Mingsheng, FENG Guihong, YANG Xiang.Application of combined optimum grey model to mid and long term load forecasting [J]. Journal of Shenyang University of Technology, 2007, 29 (2) : 450-453.

邢棉,杨实俊,牛东晓等.多元指数加权电力负荷灰色优化组合预测[J].电网技术,2005,29(4):8-11.

安德洪,韩文秀,岳毅宏.组合预测法的改进及其在负荷预测中的应用[J].系统工程与电子技术,2006,26(6):842-844.